



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Circuiti Quantistici Variazionali per la generazione equa e interpretabile di dati sintetici

RELATORE

Prof. Fabio Palomba

Università degli Studi di Salerno

CANDIDATO

Leonardo Schiavo

Matricola: 0512110456

Anno Accademico 2025-2026

Questa tesi è stata realizzata nel

sesə^{lab}
SOFTWARE ENGINEERING
SALERNO

"When life leaves us blind, love keeps us kind"

Linkin Park, "The Messenger" (2010)

Abstract

Contesto: L'adozione di modelli predittivi in domini sensibili richiede garanzie stringenti di equità algoritmica, posizionando la generazione di dati sintetici tabulari come pilastro per la mitigazione preventiva del bias (pre-processing).

Limiti dello stato dell'arte: I generatori classici basati su LLM soffrono di opacità strutturale e rischio di allucinazioni. Sul fronte quantistico (QML), i tre pilastri di generazione, fairness e interpretabilità sono trattati in modo disconnesso.

Obiettivi: Sviluppare un framework quantistico variazionale per analizzare e ottimizzare il trade-off tridimensionale tra espressività dell'ansatz (utility), mitigazione del bias (fairness) e interpretabilità del circuito. Si propone l'integrazione di vincoli geometrici nella loss per la generazione fairness-by-design e l'estensione dei Quantum Shapley Values (SVQX) per dissezionare l'impatto causale dei singoli gate.

Risultati: L'audit empirico su tre dataset reali mostra che la configurazione Pareto-efficiente `L2_re_upload` (topologia lineare con data re-uploading) riduce dell'80% la complessità circuitale (CNOT) rispetto ai modelli all-to-all, minimizzando il collo di bottiglia fisico dei gate SWAP senza alcuna perdita statisticamente significativa di utilità predittiva downstream. Il modello stabilizza l'abbattimento della disparità statistica demografica e, tramite protocolli nativi di Bell sampling, garantisce l'assenza di coppie di bias individuali nel 96.3% dei casi valutati. Sul piano interpretativo, lo scrutinio SVQX isola l'entanglement globale come sorgente primaria di iniezione del bias, mentre il re-uploading distribuisce omogeneamente il carico causale, dimezzando la polarizzazione dell'apprendimento lungo l'ansatz.

Conclusioni: Lo studio convalida il paradigma di co-design etico-hardware, provando che la sinergia tra vincoli topologici lineari e regolarizzazione classica abilita un framework di Quality Assurance quantistico strutturalmente predisposto alla verifica formale, superando l'opacità strutturale dei modelli di linguaggio classici.

Keywords: Variational Quantum Circuits; Synthetic Data Generation; Fairness; Explainable Quantum Machine Learning.

Indice

Elenco delle Figure	v
Elenco delle Tabelle	vii
1 Introduzione	1
1.1 Contesto Applicativo	1
1.2 Motivazioni e Obiettivi	2
1.2.1 La Generazione di Dati Sintetici come Strategia Proattiva . . .	2
1.2.2 Gli LLM per la Generazione di Dati Fair: Contributi e Limiti .	2
1.2.3 I Variational Quantum Circuits: un approccio alternativo . . .	3
1.2.4 Obiettivi e contributi	4
1.3 Risultati Ottenuti	6
1.4 Struttura della Tesi	8
2 Background e Stato dell'Arte	9
2.1 Fairness nel Machine Learning	9
2.1.1 Definizioni e fondamenti concettuali	9
2.1.2 Metriche formali di fairness di gruppo	10
2.1.3 Il trade-off tra metriche di fairness	11
2.1.4 Origine del bias: dalla distribuzione dei dati al modello	11
2.2 Generazione di Dati Sintetici per la Fairness	12

2.2.1	Fondamenti della generazione di dati sintetici tabulari	12
2.2.2	Generazione di dati sintetici fair: lo stato dell'arte classico . .	15
2.2.3	Generazione di dati sintetici fair tramite LLM: il contributo di Voria et al. [1]	16
2.2.4	Limiti della generazione tramite LLM e distinzione con i VQC	17
2.3	Quantum Generative Models per Dati Tabulari	17
2.3.1	Fondamenti di calcolo quantistico per il Machine Learning . .	17
2.3.2	Architettura dei Variational Quantum Circuits	22
2.3.3	QGAN e modelli generativi quantistici per dati tabulari . . .	24
2.3.4	RepFair-QGAN e la Fairness nei modelli generativi quantistici	25
2.4	Fairness nel Quantum Machine Learning	27
2.4.1	Quantum Fair Machine Learning: il contributo di Perrier . . .	27
2.4.2	Verifica formale della fairness in QML: dalla Counterfactual Fairness al Bias Pair di Guan et al.	30
2.4.3	Quantificazione dell'Entanglement nei Circuiti Variazionali: Meyer-Wallach e libreria <code>qsalto</code>	33
2.5	Interpretabilità di VQC e XQML	34
2.5.1	Il problema dell'interpretabilità nel contesto quantistico . . .	34
2.5.2	Dalla Teoria Assiomatica dei Giochi all'Explainable AI: il Fra- mework SHAP	36
2.5.3	Quantum Shapley Values: il framework di Heese et al.	37
2.5.4	Q-LIME: spiegazioni locali per QNN	39
2.5.5	Interpretabilità strutturale dei VQC rispetto agli LLM	41
2.6	Sintesi Critica e Posizionamento della Tesi	43
2.6.1	Tre pilastri, tre filoni di ricerca separati	43
2.6.2	Mappa dello stato dell'arte	45
2.6.3	Identificazione del gap e contributo della tesi	46
2.6.4	Ingegneria del Software per il QML e Crisi di Riproducibilità	47
2.6.5	Verso il Capitolo 3	47
3	Metodo di Ricerca	49
3.1	Disegno della Ricerca e Research Questions	49

3.2	Panoramica del Processo Sperimentale	51
3.3	Dataset Benchmark e Pre-processing Sensibile ($\mathcal{S}_1$)	53
3.3.1	Feature Selection e Allocazione del Registro Quantistico	53
3.3.2	Codifica Sensibile Intersezionale	54
3.3.3	Scaling Angolare e Split Stratificato	55
3.4	Architettura del Generatore Quantistico Variazionale ($\mathcal{S}_2 - \mathcal{S}_3 - \mathcal{S}_4$)	57
3.4.1	Preparazione dello Stato ed Encoding ($\mathcal{S}_2$)	57
3.4.2	Griglia delle Configurazioni VQC	58
3.4.3	Funzione di Costo Vincolata e Parameter-Shift Rule ($\mathcal{S}_3$)	60
3.4.4	Ottimizzazione con Algebra Vettorizzata in NumPy	62
3.4.5	Ablation Study e Diagnostica di Convergenza della Loss	63
3.4.6	Valore λ_f nella funzione di costo	64
3.4.7	Misurazione e Ricostruzione Classica ($\mathcal{S}_4$)	65
3.5	Valutazione Empirica e Audit XQML ($\mathcal{S}_5$)	66
3.5.1	Profiling delle Frequenze Marginali e Intersezionali	66
3.5.2	RQ1: Utilità Predittiva Downstream (Protocollo TSTR)	68
3.5.3	RQ2: Fairness Downstream e Diagnostica Quantistica	69
3.5.4	RQ3: Quantum Explainability (SVQX), Entanglement e Complessità	70
3.6	Framework Statistico Inferenziale (Demšar [2])	73
3.7	Ingegneria del Software per la Ricerca Riproducibile	76
3.8	Delimitazione dello Scope Sperimentale	77
4	Analisi dei Risultati	79
4.1	Struttura dei Dataset Sintetici Quantistici	80
4.2	RQ1: Valutazione dell'Utilità Downstream (Performance Analysis)	86
4.2.1	Risultati dell'Audit in Cross-Validation (TSTR)	86
4.2.2	Audit Empirico nel Mondo Reale (Generalizzazione TSTR)	90
4.3	RQ2: Mitigazione del Bias ed Equità Algoritmica	93
4.3.1	Risultati dell'Audit di Fairness Downstream	93
4.3.2	Audit Inferenziale e Localizzazione del Rango	96
4.3.3	Analisi delle Metriche di Diagnostica Quantistica	99

4.4	RQ3: Analisi della Explainability (SVQX), Entanglement e Complessità	102
4.4.1	Explainability tramite Quantum Shapley Values (SVQX) . . .	102
4.4.2	Verifica della Stabilità Inter-Seed delle Spiegazioni	103
4.4.3	Caratterizzazione Inferenziale di Entanglement e Purity ($q_{\text{salt o}}$)	106
4.4.4	Mappatura delle Correlazioni Strutturali di Complessità . . .	107
5	Minacce alla Validità	111
5.1	Validità Interna (Internal Validity)	112
5.2	Validità di Costrutto (Construct Validity)	112
5.3	Validità Esterna (External Validity)	113
5.4	Validità di Conclusione (Conclusion Validity)	114
6	Conclusioni e Sviluppi Futuri	115
6.1	Discussione e Take-Away Messages	115
6.1.1	Sul Trade-off tra Utilità Downstream e Mitigazione del Bias .	116
6.1.2	Il Ruolo della Complessità e del Co-Design Etico-Hardware .	117
6.1.3	Integrazione nei Processi di Quality Assurance (QA)	119
6.2	Sviluppi Futuri	120
	Bibliografia	121

Elenco delle figure

2.1	Rappresentazione sulla Sfera di Bloch dell'evoluzione unitaria di un singolo qubit. L'applicazione di un gate quantistico (nell'esempio, l'operatore X) corrisponde a una rotazione del raggio vettore di un angolo $\theta = \pi$ che mappa lo stato iniziale $ 0\rangle$ nello stato finale $ 1\rangle$, modificando l'ampiezza di probabilità degli stati base preservando la norma unitaria del sistema [3].	20
2.2	Confronto tra il paradigma <i>semantico-linguistico</i> degli LLM e il paradigma <i>matematico-circuitale</i> dei VQC per la generazione di dati sintetici fair. Nel flusso LLM (in alto), la fairness dei dati generati emerge come proprietà indotta dal pre-training del modello e non è controllata tramite vincoli quantitativi espliciti sulla distribuzione degli attributi sensibili [1, 4]. Nel flusso VQC (in basso) la fairness diventa un vincolo strutturale del processo di ottimizzazione. Nello specifico, il paradigma VQC prevede che il vettore dei parametri addestrabili θ dell'operatore unitario parametrizzato (ovvero l'ansatz generativo $U(\theta)$) venga ottimizzato affinché il campionamento probabilistico finale dallo spazio di Hilbert globale a n qubit (indicato con $\mathcal{H}^{\otimes n}$) rispetti esplicitamente i criteri di equità definiti sugli attributi sensibili (SPD, EOD, AOD).	45

3.1	Architettura della Pipeline sperimentale $\mathcal{P}$ per la generazione di dati sintetici fair tramite VQC, valutazione downstream e audit strutturale XQML. L'implementazione della pipeline è consultabile nella nostra repository pubblica: https://github.com/KLS-01/VQC_Generator-Fair-Interpretable-Data [5]	52
3.2	Diagnostica di convergenza delle curve di loss per i dataset German Credit (sinistra), Heart Disease (centro) e Student Performance (destra) su 15 epoche con $\text{batch_frac} = 0.25$ e $\lambda_f = 5.0$. La linea blu indica la perdita totale ($\mathcal{L}_{\text{tot}}$), la linea verde tratteggiata rappresenta la componente di fedeltà statistica delle feature ($\mathcal{L}_{\text{fid}}$), e la linea rossa punteggiata evidenzia la penalità di fairness ($\mathcal{L}_{\text{fair}}$) sul qubit target. Si osserva il raggiungimento di un plateau asintotico stabile per tutti e tre i domini entro la 15-esima epoca.	64
4.1	Matrici post-hoc del test di Nemenyi (p-value pairwise corretti per test multipli) per la valutazione della significatività dell'utilità predittiva (RQ1).	88
4.2	Matrici post-hoc del test di Nemenyi (p-value pairwise corretti per test multipli) per valutare la significatività dell'abbattimento del bias nel setting intersezionale.	98
4.3	Stabilità inter-seed delle spiegazioni SVQX su German Credit.	104
4.4	Stabilità inter-seed delle spiegazioni SVQX su Student Performance.	104
4.5	Stabilità inter-seed delle spiegazioni SVQX su Heart Disease.	105
4.6	Analisi di complessità nel dominio <i>Student Performance</i> : correlazione positiva tra la densità fisica di porte CNOT nell'ansatz e la degradazione dell'equità downstream (sinistra) e accumulo sistematico di entanglement di Meyer-Wallach all'aumentare del numero di parametri variazionali (destra).	108

Elenco delle tabelle

2.1	Confronto tra paradigmi di interpretabilità: VQC vs. LLM.	42
2.2	Confronto tra i principali paradigmi per la generazione di dati fair [1, 6, 7, 8].	46
3.1	Allocazione delle risorse di qubit, spazio di Hilbert e attributi sensibili per dataset.	55
3.2	Griglia sperimentale delle 6 configurazioni VQC per $N_q = 10$ qubit (Heart Disease e Student Performance).	59
4.1	Sintesi delle statistiche descrittive per la variabile <code>age</code> nel dataset <i>German Credit</i> reale e nelle relative varianti sintetiche quantistiche (misure espresse come medie aritmetiche calcolate sui seed 7, 17, 27).	81
4.2	Frequenze assolute (medie sui seed 7, 17, 27) e relative dell'attributo sensibile intersezionale A_{overall} nei dataset originari e in tutte le varianti sintetiche.	84
4.3	Medie e deviazioni standard di Accuracy e F1-score (riferito alla classe positiva $Y = 1$) per i dataset reali di baseline e tutte le configurazioni sintetiche quantistiche associate. Le celle colorate in grigio indicano i baseline reali. I valori sono mediati sui tre seed stocastici e sui tre modelli downstream.	87

4.4	Profilo prestazionale dei migliori modelli classificatori classici downstream addestrati in regime TSTR (I valori rappresentano il picco prestazionale registrato sul seed stocastico ottimale).	92
4.5	Medie e deviazioni standard delle metriche di fairness (SPD, EOD, AOD) per tutte le varianti sintetiche quantistiche, disaggregate per attributo sensibile (A_{age} , A_{sex} , A_{overall}) su tutti e tre i domini sperimentali. I valori rappresentano le medie calcolate su 9 run indipendenti. . . .	94

CAPITOLO 1

Introduzione

1.1 Contesto Applicativo

Il Machine Learning (ML) ha assunto negli ultimi anni un ruolo di primo piano in un numero crescente di domini applicativi ad alto impatto sociale, tra cui la medicina diagnostica, i sistemi di concessione del credito, la selezione del personale e i sistemi giudiziari predittivi [9, 10]. I modelli ML si sono dimostrati capaci di apprendere pattern complessi e di automatizzare processi decisionali che solitamente richiedevano l'intervento umano, con risvolti positivi in termini di efficienza, scalabilità e consistenza delle decisioni [10]. Tuttavia, con la diffusione di questi sistemi, sono emerse una serie di problematiche di natura etica e tecnica.

Tra queste, la **fairness** (intesa come il principio secondo cui un modello di ML dovrebbe produrre decisioni imparziali, senza discriminare sistematicamente individui o gruppi sulla base di attributi sensibili quali il sesso, l'età o l'etnia) è emersa come uno dei requisiti non funzionali più critici [11, 12]. La radice del problema è spesso da ricercarsi nei dati stessi: i dataset reali rispecchiano inevitabilmente le disuguaglianze e i pregiudizi storici presenti nella società [11]. Quando un modello è addestrato su dati distorti, esso apprende e riproduce tali distorsioni, talvolta amplificandole [11].

In risposta, la comunità di ricerca nell’ambito del Software Engineering for Artificial Intelligence (SE4AI) ha sviluppato tecniche di bias mitigation classificate in 3 categorie: *pre-processing*, *in-processing* e *post-processing* [13]. Tuttavia, come osservato da Corbett-Davies et al. [14], queste tecniche presentano limiti strutturali: operano in modo reattivo e spesso non eliminano il bias alla radice.

1.2 Motivazioni e Obiettivi

1.2.1 La Generazione di Dati Sintetici come Strategia Proattiva

Un approccio alternativo è rappresentato dalla **generazione di dati sintetici**, ovvero dalla creazione di dataset artificiali che mimano le proprietà statistiche dei dati reali, ma che possono essere costruiti in modo da controllare esplicitamente la distribuzione degli attributi sensibili [15, 16]. Questo approccio contribuisce alla *fairness-by-design* e incorpora l’equità sin dalla fase di generazione del dato [1].

La letteratura (gli studi esistenti) ha esplorato diverse tecniche per la generazione di dati sintetici tabulari. I metodi tradizionali come le reti bayesiane [17] e le copule [18] soffrono di difficoltà con distribuzioni ad alta dimensionalità e feature eterogenee. Le GAN [19] e le VAE [20] hanno offerto soluzioni più flessibili e potenti, nonostante presentino proprie criticità legate alla stabilità dell’addestramento e al mode collapse [15].

1.2.2 Gli LLM per la Generazione di Dati Fair: Contributi e Limiti

Lo studio *‘Fair and square? Evaluating Fairness of LLM-Generated Synthetic Datasets’* a cura del *Software Engineering (SeSa) Lab* [1] (assunto come riferimento metodologico e principale del lavoro) ha condotto uno studio empirico sistematico in cui GPT-4o è stato utilizzato per generare dataset sintetici da descrizioni testuali delle feature, senza accesso ai dati originali. I risultati mostrano che i modelli addestrati su dati 1-shot migliorano consistentemente l’Average Odds Difference (AOD) e la Statistical Parity Difference (SPD). Tuttavia, lo studio evidenzia 4 limiti strutturali:

1. **Bias di addestramento degli LLM:** gli LLM incorporano pregiudizi culturali e stereotipi presenti nei corpora testuali di pre-training [4, 21, 22].
2. **Controllabilità limitata:** nessun meccanismo formale consente di vincolare a priori la distribuzione degli attributi sensibili.
3. **Allucinazioni:** valori implausibili documentati (es. età massima di 460 anni) [1].
4. **Opacità:** il processo generativo è una black-box non ispezionabile [23].

1.2.3 I Variational Quantum Circuits: un approccio alternativo

I limiti appena descritti motivano la ricerca di modelli generativi alternativi, portando il presente lavoro a esplorare l'impiego dei **Variational Quantum Circuits (VQC)** [6, 24] come generatori di dati sintetici fair per dataset tabulari.

Tuttavia, è fondamentale precisare che l'adozione di un paradigma quantistico non implica intrinsecamente la generazione di dati più *fair*. La meccanica quantistica, di per sé, non elimina il bias: se il training set originario è distorto, il VQC apprenderà fedelmente tale distribuzione asimmetrica. Ciò che rende realmente interessante e innovativo l'uso dei VQC rispetto agli LLM risiede nella loro **natura matematico-circuitale**. A differenza delle architetture semantiche black-box, i VQC si configurano come circuiti espliciti e strutturalmente ispezionabili tramite strumenti di XQML [25, 26]. Questa trasparenza strutturale consente sia di analizzare il contributo causale dei singoli parametri del circuito, sia di incorporare vincoli matematici direttamente nella funzione di ottimizzazione. Di conseguenza, è possibile porre la **fairness come vincolo strutturale del processo di ottimizzazione**, potenzialmente riducendo il bias alla radice.

In aggiunta all'ispezionabilità strutturale, i VQC offrono significativi vantaggi in termini di espressività e compattezza parametrica. Come dimostrato nei lavori di Bhardwaj et al. [6] e Kumari et al. [24], queste architetture variazionali applicate ai dati tabulari riescono a raggiungere prestazioni competitive con i modelli classici di riferimento pur impiegando un numero di parametri addestrabili significativamente inferiore. L'unione di queste proprietà consente di investigare sistematicamente la complessa interazione e il **trade-off tridimensionale** che lega tre dimensioni in forte

tensione reciproca: (i) l'**espressività dell'ansatz** (la capacità rappresentativa di modellare fedelmente la distribuzione dei dati per garantire l'utilità), (ii) la **mitigazione del bias** (il soddisfacimento di rigidi criteri geometrici di fairness), e (iii) l'**interpretabilità algoritmica** del circuito. Circuiti più profondi e con maggiore densità di entanglement CNOT (come le varianti all-to-all) possono modellare con maggiore utilità la complessa dispersione dei dati reali, ma rischiano al tempo stesso di comportarsi come scatole nere instabili, inclini a incamerare e propagare il bias demografico storico lungo il registro quantistico. Viceversa, architetture lineari nearest-neighbor più semplici offrono una trasparente ispezionabilità tramite Quantum Shapley Values (SVQX), ma potrebbero incontrare precisi colli di bottiglia espressivi, sacrificando l'utilità classica downstream se prive di adeguati meccanismi di regolarizzazione classica (come il data re-uploading).

1.2.4 Obiettivi e contributi

© **Our Goal.** L'obiettivo del presente lavoro è progettare e valutare un sistema generativo basato su VQC per la produzione di dati sintetici tabulari fair, analizzandone e ottimizzandone il trade-off tridimensionale tra espressività dell'ansatz (**utility**), mitigazione del bias (**fairness**) e interpretabilità del circuito (**explainability**). La valutazione empirica confronta sistematicamente tali dimensioni rispetto ai baseline classici e LLM, assumendo come riferimento metodologico lo studio '*Fair and square? Evaluating Fairness of LLM-Generated Synthetic Datasets*' a cura del *Software Engineering (SeSa) Lab* [1].

A tale scopo, il presente lavoro di tesi introduce tre contributi originali rispetto allo stato dell'arte:

1. Sviluppo di un framework originale per la generazione di dati sintetici tabulari fair tramite VQC, che combina valutazioni di utility, fairness downstream e interpretabilità su dataset sensibili standardizzati. Per quanto a nostra conoscenza, non sono disponibili studi precedenti che analizzino congiuntamente queste tre dimensioni in questo contesto *quantum tabular data* [6, 24, 7].

2. Estensione concettuale dell'applicazione dei Quantum Shapley Values [25]: mentre lo stato dell'arte ha storicamente impiegato tale framework sull'analisi di classificatori quantistici, per la valutazione del rumore hardware o l'analisi strutturale dei gate, noi proponiamo di utilizzarlo per interpretare la semantica delle feature. Nello specifico, lo impieghiamo per dissezionare le logiche di encoding, con il fine di analizzare propagazione del bias lungo le porte logiche dell'ansatz;
3. La conduzione di uno studio empirico su tre popolazioni sensibili (*German Credit, Heart Disease, Student Performance*), caratterizzato dal calcolo integrato di metriche sia classiche che quantistiche native: utilità downstream in regime TSTR (Accuracy, F1-score), fairness demografica (SPD, EOD, AOD), parità statistica quantistica locale (QSP_{diff}), distanza di traccia (D_{tr}), purezza e conformità dello stato preparato (a_1 stimato tramite la libreria `qsalto` [27]) e indici strutturali di complessità ed explainability (SVQX, concentrazione Gini, Meyer-Wallach). Per promuovere la piena riproducibilità, l'intero Online Appendix normalizzato¹, comprensivo di 54 run computazionali replicabili (162 righe per RQ1, 486 righe per RQ2 e 576 per RQ3) e della suite statistico-grafica (test di Friedman, Nemenyi post-hoc e heatmap), è stato rilasciato pubblicamente in conformità con gli standard di open-science e riproducibilità software.

¹La repository pubblica contenente i sorgenti software, i dataset generati, l'appendice normalizzata e la suite statistica è disponibile all'indirizzo: https://github.com/KLS-01/VQC_Generator-Fair-Interpretable-Data [5].

1.3 Risultati Ottenuti

L’audit comparativo sistematico condotto su tre domini reali ad alta sensibilità etica (*German Credit*, *Heart Disease* e *Student Performance*) lungo 54 run computazionali indipendenti convalida l’efficacia del paradigma quantistico variazionale proposto, delineando i seguenti risultati salienti strutturati in conformità con i principali risultati chiave (*Key Findings*) delle tre domande di ricerca:

- Preservazione dell’Utilità Predittiva (RQ1):** Sebbene i modelli addestrati su dati quantistici variazionali registrino, a livello medio aggregato, un calo di utilità predittiva (evidenziando un severo trade-off di utilità per le configurazioni profonde non regolarizzate), l’indagine sulla capacità di generalizzazione nel mondo reale (*Train on Synthetic, Test on Real* - TSTR) documenta performance di picco altamente soddisfacenti. In scenari ottimali di sintonizzazione stocastica (*Seed 27*) ed addestramento vincolato, i modelli downstream preservano l’utilità informativa originaria del dominio, allineandosi o superando i rispettivi baseline reali (toccando un F1-score di picco pari a 0.675 in *Heart Disease* e a 0.929 in *Student Performance*, quest’ultimo competitivo con il baseline reale di 0.912). Il test inferenziale omnibus di Friedman accetta l’ipotesi nulla di equivalenza dei ranghi prestazionali globali tra tutte le varianti sintetiche quantistiche ($p \geq 0.1934$ per l’F1-score), provando che l’introduzione di vincoli etici (varianti $\mathbb{L}_2$) non degrada in modo significativo la predittività rispetto alle controparti quantistiche non vincolate ($\mathbb{L}_1$). Le evidenze confermano che la codifica angolare accoppiata al *data re-uploading* opera come un naturale regolarizzatore geometrico nello spazio di Hilbert, preservando l’espressività informativa del dato sintetico pur sotto l’azione di rigidi vincoli etici demografici.
- Mitigazione del Bias Demografico e Intersezionale (RQ2):** La sperimentazione rivela che i VQC riducono nominalmente il bias downstream, ma evidenzia una forte instabilità stocastica (ampie deviazioni standard) che rende la fairness macroscopica un equilibrio sensibile alle condizioni di ottimizzazione. Tuttavia, questo comportamento si stabilizza efficacemente mitigando l’esplosione dei *barren plateaus* tramite topologie lineari o meccanismi di *data re-uploading*,

consentendo alla variante `L2_all_to_all_re_upload` di contrarre la SPD intersezionale al record minimo di 0.0112 ± 0.0610 nel dominio *Student Performance* (dove la SPD intersezionale viene abbattuta complessivamente fino al valore ottimale di -0.0401 nella variante `L2_re_upload`). L’audit quantistico nativo conferma con significatività statistica ($p \leq 0.0329$ in tutti i domini) che la topologia lineare dei qubit agisce da regolarizzatore geometrico nello spazio di Hilbert, limitando le asimmetrie sul qubit target ed influenzando l’equità del dato campionato downstream. Questa regolarizzazione preserva l’equità locale a livello di singoli stati quantistici, garantendo l’assenza di coppie di bias (*bias pairs*) nel 96.3% delle valutazioni complessive.

- **Spiegabilità Strutturale e Co-Design Etico-Hardware (RQ3):** L’indagine strutturale mappa con rigore inferenziale il comportamento geometrico interno dei VQC. Lo scrutinio dei Quantum Shapley Values (SVQX) individua nei gate ad entanglement globale (porte CNOT) il primario vettore fisico quantistico di iniezione e propagazione del bias demografico (con valori medi di SVQX fino a -0.3225). Inoltre, l’analisi dell’indice di concentrazione Gini dimostra che l’integrazione del *data re-uploading* distribuisce il carico causale lungo tutto l’ansatz, contraendo la polarizzazione delle spiegazioni (riducendo l’indice di oltre il 40%, fino a 0.363 ± 0.027 rispetto a 0.622 ± 0.329 delle configurazioni non regolarizzate in *German Credit*). L’audit delle correlazioni architetturali rivela una diretta e significativa associazione positiva tra la densità delle CNOT e la degradazione dell’equità downstream ($\rho = 0.5230$, $p = 0.0259$ per l’EOD in *Student Performance*). Infine, le misure native di purezza basate su Bell sampling e l’indice di Meyer-Wallach provano con significatività statistica ($p < 0.005$) che l’incremento di profondità variazionale quantistica espande coerentemente l’entanglement globale dello stato preparato. Questo trend delinea la linea guida fondamentale per il co-design etico-hardware quantistico: per sintetizzare dataset equi, è indispensabile limitare la connettività globale dei qubit riducendo le CNOT ed adottando topologie lineari regolarizzate da meccanismi strutturati di data re-uploading.

1.4 Struttura della Tesi

Il resto della tesi è organizzato come segue. Il **Capitolo 2** introduce i concetti di background necessari alla comprensione del lavoro, presentando una discussione critica dello stato dell'arte su fairness, generazione di dati sintetici, modelli generativi quantistici e interpretabilità in QML. Il **Capitolo 3** descrive il metodo di ricerca adottato, l'architettura del VQC generativo, il protocollo sperimentale e le modalità di calcolo delle metriche di spiegabilità strutturale e di conformità quantistica locale. Il **Capitolo 4** presenta i risultati ottenuti in merito alle tre domande di ricerca e ne discute criticamente le implicazioni metodologiche e fisiche. Il **Capitolo 5** espone le minacce alla validità interna, esterna, di costrutto e di conclusione, delineando le strategie di mitigazione sistematiche implementate. Infine, il **Capitolo 6** conclude la tesi riassumendo i messaggi chiave (*Take-Away Messages*), i contributi originali, le limitazioni riscontrate e le promettenti linee di sviluppo per la ricerca futura.

CAPITOLO 2

Background e Stato dell'Arte

Prima di procedere con la trattazione, è opportuno precisare che le formalizzazioni matematiche presentate nel corso di questo capitolo assumono una funzione prettamente esemplificativa ai fini della comprensione dello stato dell'arte e non costituiscono un contributo originale del presente studi. Sono uno strumento analitico necessario per comprendere in modo rigoroso i fondamenti teorici, le metriche e i framework sviluppati dagli autori analizzati nel presente capitolo, lavoro necessario per comprendere il posizionamento del nostro lavoro.

2.1 Fairness nel Machine Learning

2.1.1 Definizioni e fondamenti concettuali

Il concetto di fairness nei sistemi di machine learning non ammette una definizione universale e univoca. Come osservato da Mehrabi et al. [11], la letteratura documenta oltre venti definizioni formalmente distinte, derivate da tradizioni disciplinari diverse e spesso tra loro incompatibili. Ciononostante, la ricerca ha progressivamente converso su alcune definizioni operative classificabili in due macro-categorie: **fairness di gruppo** (*group fairness*) e **fairness individuale** (*individual fairness*) [11, 12].

La fairness individuale, nella formulazione seminale di Dwork et al. [28], richiede che individui simili ricevano trattamenti simili. Formalmente, un modello M è individualmente fair rispetto a una metrica di similarità (o distanza) $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ nello spazio degli input se, per ogni coppia $x, x' \in \mathcal{X}$:

$$D(M(x), M(x')) \leq d(x, x')$$

dove D è una distanza nello spazio degli output.

Questa formula impone un vincolo preciso: la differenza D tra le decisioni prese dal modello M per due individui x, x' non deve essere maggiore della reale differenza d tra le caratteristiche degli individui stessi.

Sebbene elegante, questa definizione presenta difficoltà operative significative: la specifica di d è spesso arbitraria e potenzialmente essa stessa fonte di bias [11, 12].

2.1.2 Metriche formali di fairness di gruppo

Sia $\hat{Y} \in \{0, 1\}$ la variabile di predizione del modello, $Y \in \{0, 1\}$ l'etichetta vera associata ad un individuo, $A \in \{0, 1\}$ l'attributo sensibile (gruppo privilegiato $A = 1$, non privilegiato $A = 0$), e $P(\dots | \dots)$ la probabilità condizionata, le metriche di fairness di gruppo più comunemente adottate sono:

Statistical Parity Difference (SPD) Misura la deviazione dalla parità statistica [29]:

$$\text{SPD} = P(\hat{Y} = 1 | A = 1) - P(\hat{Y} = 1 | A = 0)$$

ossia la differenza tra la probabilità che il modello dia un esito positivo a un individuo del gruppo privilegiato e la probabilità che lo dia a uno del gruppo non privilegiato.

Equal Opportunity Difference (EOD) Proposta da Hardt et al. [30], misura la disparità nei tassi di veri positivi:

$$\text{EOD} = P(\hat{Y} = 1 | Y = 1, A = 1) - P(\hat{Y} = 1 | Y = 1, A = 0)$$

ossia la differenza tra la probabilità che il modello riconosca correttamente (poiché $Y = 1$) l'esito positivo per il gruppo privilegiato rispetto a quello non privilegiato.

Average Odds Difference (AOD) Definita da Bellamy et al. [31], combina la differenza nei tassi di falsi e veri positivi:

$$\text{AOD} = \frac{1}{2} \left[(P(\hat{Y} = 1 \mid Y = 0, A = 1) - P(\hat{Y} = 1 \mid Y = 0, A = 0)) \right. \\ \left. + (P(\hat{Y} = 1 \mid Y = 1, A = 1) - P(\hat{Y} = 1 \mid Y = 1, A = 0)) \right]$$

ossia la media tra la differenza nei tassi di falsi positivi e la differenza nei tassi di veri positivi tra i due gruppi (EOD).

Per tutte e tre le metriche, il valore zero indica fairness ideale; deviazioni positive favoriscono il gruppo privilegiato, deviazioni negative il gruppo non privilegiato [1]. Queste sono le metriche adottate da Voria et al. [1] e dal presente lavoro.

2.1.3 Il trade-off tra metriche di fairness

Un risultato fondamentale nella teoria della fairness è che le principali definizioni di gruppo sono, in generale, **mutualmente incompatibili**.

Il teorema di Chouldechova [32] (noto anche come teorema di impossibilità dell'equità algoritmica) dimostra che, se le prevalenze delle classi differiscono tra i gruppi (in terminologia statistica, se i due gruppi hanno tassi di base diversi per un determinato esito), formalmente ($P(Y = 1 \mid A = 1) \neq P(Y = 1 \mid A = 0)$), è matematicamente impossibile che un algoritmo soddisfi contemporaneamente i tre criteri di equità legati a calibrazione, tassi uguali di errore e parità predittiva; di conseguenza, qualsiasi classificatore calibrato viola necessariamente almeno una condizione di fairness di errore.

Kleinberg et al. [33] estendono questo risultato mostrando l'incompatibilità simultanea di calibrazione, bilanciamento delle false positive rates e delle false negative rates. Questi risultati di impossibilità motivano la scelta di adottare un insieme complementare di metriche (SPD, EOD, AOD) piuttosto che una singola misura [1].

2.1.4 Origine del bias: dalla distribuzione dei dati al modello

Il bias nei sistemi ML è quasi sempre riconducibile a distorsioni presenti nei dati prima ancora che nelle scelte algoritmiche [11]. Le principali fonti includono:

- **Bias di selezione:** sottorappresentazione di certi gruppi demografici nella raccolta dei dati [11].
- **Bias di etichettatura:** le etichette riflettono decisioni umane passate già distorte [12].
- **Bias di proxy:** feature non sensibili correlano fortemente con attributi sensibili, reintroducendo il bias anche dopo rimozione esplicita [11, 30].

Come sottolineano Pessach e Shmueli [12], qualunque sia l'algoritmo impiegato, l'entità del bias è sempre determinata in misura preponderante dalla distribuzione del dataset di addestramento. È in questo contesto che si colloca la generazione di dati sintetici come strategia proattiva: tramite questo approccio, è possibile garantire matematicamente una distribuzione equa fin dall'inizio.

2.2 Generazione di Dati Sintetici per la Fairness

2.2.1 Fondamenti della generazione di dati sintetici tabulari

La generazione di dati sintetici produce istanze artificiali che mimano le proprietà statistiche di un dataset reale senza contenere record originali [15, 16]. La valutazione della qualità si articola lungo due dimensioni: **fidelity** (fedeltà statistica, misurata tramite SDMetrics, MMD, test KS) e **utility**, che valuta le prestazioni *downstream* dei dati generati utilizzando il framework TSTR/TRTS (acronimo di *Train Synthetic, Test Real*) [15].

Nel panorama della sintesi dei dati, i framework di riferimento tradizionali sono riconducibili a due paradigmi principali: le reti generative avversarie (GAN) e gli autoencoder variazionali (VAE). Nel panorama della sintesi dei dati, i framework di riferimento tradizionali sono riconducibili a due paradigmi principali: le reti generative avversarie (GAN) e gli autoencoder variazionali (VAE).

Una **GAN** (Generative Adversarial Network) [19] è composta da due modelli addestrati simultaneamente:

- un **generatore** $G : \mathcal{Z} \rightarrow \mathcal{X}$, che ha l'obiettivo di apprendere la distribuzione reale dei dati p_{data} .

- **Input:** un vettore di rumore latente z campionato da una distribuzione a priori p_z sullo spazio latente $\mathcal{Z}$.
- **Output:** un'istanza sintetica $G(z)$ mappata nello spazio delle feature $\mathcal{X}$.

Esso viene addestrato per massimizzare la probabilità che il discriminatore commetta un errore;

- un **discriminatore** $D : \mathcal{X} \rightarrow [0,1]$, che funge da classificatore avversario, penalizzando i tentativi di contraffazione del generatore G .
 - **Input:** un dato campione x , che può provenire dalla distribuzione dei dati di addestramento p_{data} ($x \sim p_{\text{data}}$) oppure essere un'istanza sintetica generata da G ($x = G(z)$).
 - **Output:** un valore scalare continuo, che stima la probabilità che il campione in input sia reale (valore tendente a 1) piuttosto che proveniente dal generatore G (valore tendente a 0).

Questo framework corrisponde a un gioco *minimax* a due giocatori, in cui i due modelli vengono addestrati in modo antagonistico tramite la seguente funzione obiettivo:

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

In particolare:

- Il discriminatore opera sotto il comando $\max_D$: il suo obiettivo è massimizzare il valore totale dell'equazione cercando di avvicinare $D(x)$ a 1 (dati veri riconosciuti come veri) e allontanando $D(G(z))$ da 1 (dati falsi riconosciuti come falsi).
- Il generatore opera sotto il comando $\min_G$: non avendo controllo sui dati reali, il suo unico scopo è minimizzare il secondo blocco dell'equazione cercando di generare dati sintetici talmente realistici da spingere $D(G(z))$ verso il valore 1 (dati falsi riconosciuti come veri), "massimizzando la probabilità che D commetta un errore".
- $\mathbb{E}_{x \sim p_{\text{data}}}$ calcola il valore atteso (*Expected value*) pescando campioni x dalla distribuzione dei dati reali.

- $\mathbb{E}_{z \sim p_z}$ calcola il valore atteso (*Expected value*) pescando il rumore z dalla distribuzione a priori p_z sullo spazio latente $\mathcal{Z}$.
- $1 - D(G(z))$ rappresenta la probabilità che il discriminatore riconosca correttamente il falso.

Un **VAE** (Variational AutoEncoder) [20], come spiegato da Kingma e Welling, affronta il problema dell'apprendimento in presenza di variabili latenti continue. In tali scenari, i dati osservabili sono generati da fattori nascosti per i quali risulta analiticamente e computazionalmente impossibile applicare il Teorema di Bayes per calcolarne l'esatta probabilità inversa, rendendo di fatto le distribuzioni a posteriori intrattabili.

È composto da due reti neurali addestrate congiuntamente:

- un **encoder** (o *recognition model*) $q_\phi(z | x)$, parametrizzato dai pesi ϕ , che funge da modello di inferenza approssimata.
 - **Input:** un dato campione reale x proveniente dallo spazio delle feature originali $\mathcal{X}$.
 - **Output:** i parametri (es. media e varianza) di una distribuzione di probabilità $q_\phi(z | x)$ da cui viene campionato un vettore latente stocastico z nello spazio compresso $\mathcal{Z}$.

Esso ha l'obiettivo di mappare i dati reali x nel dominio compresso (spazio latente $\mathcal{Z}$);

- un **decoder** (o *generative model*) $p_\theta(x | z)$, parametrizzato dai pesi θ , che esegue l'operazione inversa.
 - **Input:** il vettore stocastico latente z campionato dalla distribuzione prodotta dall'encoder ($q_\phi(z | x)$).
 - **Output:** una distribuzione di probabilità $p_\theta(x | z)$ utilizzata per ricostruire il dato originario x nello spazio delle feature iniziali $\mathcal{X}$.

Esso ha il compito di massimizzare la fedeltà della ricostruzione del campione di partenza.

Poiché risulta matematicamente impossibile calcolare in modo analitico l'esatta probabilità dei dati complessi nel mondo reale, il framework massimizza invece un'approssimazione sicura chiamata *Evidence Lower BOund* (ELBO) [1]:

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - D_{\text{KL}}(q_\phi(z | x) \| p(z))$$

In particolare, la massimizzazione di questa espressione bilancia due forze contrapposte:

- $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)]$ rappresenta il **termine di ricostruzione**: valuta la log-verosimiglianza stimata dal decoder di ricreare il dato x dato il vettore latente z . Il valore atteso (Expected value) preme affinché la rete neurale venga premiata per la ricostruzione più fedele possibile;
- $D_{\text{KL}}(q_\phi(z | x) \| p(z))$ rappresenta la **penalità di regolarizzazione**: misura la divergenza di Kullback-Leibler (rappresentata da $D_{\text{KL}}(\dots \| \dots)$) per quantificare quanto la distribuzione generata dall'encoder $q_\phi(z | x)$ differisca da una distribuzione a priori nota e strutturata $p(z)$ (solitamente una Gaussiana standard). Forzando l'algoritmo a minimizzare questa distanza, ci si assicura che lo spazio latente $\mathcal{Z}$ si mantenga ordinato, requisito fondamentale per poter successivamente campionare vettori randomici validi e generare nuove istanze sintetiche realistiche.

2.2.2 Generazione di dati sintetici fair: lo stato dell'arte classico

Fair-SMOTE [34] rimuove istanze con etichette distorte e genera campioni sintetici per ciascuna combinazione di classe e attributo sensibile, garantendo rappresentazione bilanciata. Tuttavia opera solo per interpolazione nello spazio delle istanze reali e non può generare dati in regioni non rappresentate nel training set.

I modelli WGAN con vincoli di fairness (tra cui PF-WGAN [8]) incorporano penalità aggiuntive durante l'addestramento. Come definito originariamente dagli autori, la funzione obiettivo per il generatore è una somma lineare dei singoli obiettivi:

$$\mathcal{L}_{\text{final}} = \mathcal{L}_{\text{WGAN-GP}} + l_{\text{fairness}} + l_{\text{privacy}}$$

Esplicitando gli specifici iperparametri di peso (λ_f e λ_p) che modulano le singole loss di fairness e privacy, possiamo riscrivere la loss del generatore $\mathcal{L}_G$ nella sua forma esplicita equivalente:

$$\mathcal{L}_G = \mathcal{L}_{\text{adv}} + \lambda_f \cdot \mathcal{L}_{\text{fair}} + \lambda_p \cdot \mathcal{L}_{\text{privacy}}$$

Questo approccio introduce tensioni nell’ottimizzazione congiunta, in quanto le prestazioni del modello dipendono fortemente dalla difficile calibrazione dell’iperparametro λ_f tra dataset diversi [8]. Il denominatore comune di tutti questi approcci è che operano in uno spazio di distribuzione interamente determinato dal dataset reale: la fairness è imposta come vincolo esterno su un processo generativo che ha già internalizzato le asimmetrie del dato.

2.2.3 Generazione di dati sintetici fair tramite LLM: il contributo di Voria et al. [1]

Voria et al. [1] propongono un approccio radicalmente diverso: sfruttare la conoscenza semantica implicita di GPT-4o per generare dataset sintetici a partire esclusivamente dalla descrizione testuale delle feature. Lo studio impiega tre dataset sensibili (German Credit [35], Heart Disease [36], Student Performance [37]) con prompt a tre livelli (0-shot, 1-shot, 2-shot) ripetuti tre volte ciascuno. I modelli sono valutati in cross-validazione e in modalità TSTR, con metriche di fairness (SPD, EOD, AOD) calcolate tramite AI Fairness 360 [31] nella configurazione multiple-sensitive attribute.

I risultati principali mostrano che i dataset 1-shot producono miglioramenti statisticamente significativi sull’AOD in tutti e tre i dataset, con la SPD che migliora in modo consistente [1]. L’aumento della complessità da 1-shot a 2-shot non porta a ulteriori benefici: per il German Credit, la SPD degrada da 0.083 (reale) a -0.441 (2-shot) [1].

2.2.4 Limiti della generazione tramite LLM e distinzione con i VQC

I limiti strutturali dell'approccio LLM si articolano lungo quattro assi critici:

1. **Bias linguistico:** gli LLM incorporano pregiudizi culturali e stereotipi presenti nel testo di pre-training [4, 21, 22].
2. **Assenza di controllabilità formale:** nessun meccanismo consente di vincolare quantitativamente la distribuzione degli attributi sensibili a priori.
3. **Allucinazioni:** propensione a generare output stocastici e talvolta implausibili [38] con casi documentati di valori fuori dominio (es. età massima di 460 anni nel German Credit) [1].
4. **Opacità:** il processo generativo è black-box, rendendo impossibile la verifica formale della fairness generativa [23].

La distinzione fondamentale è:

- l'approccio di Voria et al. [1] è **testuale**, quindi il modello *comprende* le feature e *scrive* valori plausibili nel linguaggio naturale; l'approccio di questo lavoro è **matematico-circuitale**.
- il VQC *campiona* da una distribuzione di probabilità definita nello spazio di Hilbert, i cui parametri sono ottimizzati per soddisfare esplicitamente vincoli di fairness.

2.3 Quantum Generative Models per Dati Tabulari

2.3.1 Fondamenti di calcolo quantistico per il Machine Learning

L'unità elementare dell'informazione quantistica è il **qubit**. A differenza del bit classico, che assume un valore scalare definito e deterministico (0 o 1), un qubit è descritto matematicamente come un vettore in uno spazio vettoriale complesso bidimensionale. Esso può trovarsi in una **sovrapposizione coerente** degli stati di base computazionali $|0\rangle$ e $|1\rangle$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad \alpha, \beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1$$

Per tradurre i concetti fisici in entità manipolabili a livello computazionale, il Quantum Machine Learning si avvale di un solido formalismo matematico che combina la **notazione di Dirac** per i vettori di stato con le operazioni fondamentali dell'algebra lineare per la loro manipolazione e combinazione [39, 3].

Gli elementi specifici della **notazione di Dirac** sono:

- **Ket ($|\cdot\rangle$):** Rappresenta un vettore colonna. Ad esempio, $|0\rangle$ e $|1\rangle$ indicano i due vettori ortonormali della base computazionale, definiti rispettivamente come $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ e $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ (scrivibili in linea anche come $[1, 0]^\top$ e $[0, 1]^\top$).
- **Bra ($\langle\cdot|$):** Rappresenta un vettore riga, ottenuto calcolando il trasposto complesso coniugato del rispettivo ket.

A questi si aggiungono le nozioni algebriche necessarie per la **valutazione e la composizione degli stati**:

- **Ampiezze di probabilità (α, β):** Sono pesi complessi. La condizione di normalizzazione ($|\alpha|^2 + |\beta|^2 = 1$) assicura che il loro modulo quadro corrisponda all'esatta probabilità di misurare i rispettivi stati classici.
- **Prodotto tensoriale ($\otimes$):** L'operatore che combina gli spazi bidimensionali di n qubit isolati per formare un singolo stato quantistico globale $|\Psi\rangle$ all'interno dello spazio vettoriale multidimensionale chiamato **spazio di Hilbert** $\mathcal{H}^{\otimes n} = \mathbb{C}^{2^n}$. Questo spazio ha dunque una dimensione *esponenziale* nel numero di qubit [40, 41].

In termini algoritmici, mentre un registro classico di n bit memorizza una singola stringa deterministica (formalizzabile come un vettore $x \in \{0, 1\}^n$, es. l'array 01...1), un registro di n qubit appartenente allo spazio $\mathbb{C}^{2^n}$ codifica una combinazione lineare (espressa come $\sum_{j=0}^{2^n-1} \alpha_j |j\rangle$) di tutti i 2^n possibili stati classici simultaneamente [40, 41]. Come sottolineato da Preskill [41], tale complessità dimensionale implica che per descrivere analiticamente le correlazioni di poche centinaia di qubit servirebbero più bit di quanti siano gli atomi nell'universo visibile.

Evoluzione Unitaria e Porte Quantistiche. Nel calcolo quantistico, le istruzioni computazionali (equivalenti alle porte logiche classiche come AND o OR) sono

realizzate tramite **gate quantistici**. Matematicamente, un gate applicato a n qubit corrisponde alla moltiplicazione del vettore di stato per una matrice quadrata complessa e *unitaria* U di dimensione $2^n \times 2^n$ (dove $U^\dagger U = I$). Questa operazione trasforma direttamente le ampiezze di probabilità del sistema, ricalcolando i pesi della combinazione lineare e facendo di fatto evolvere lo stato quantistico verso una nuova sovrapposizione. L'imposizione che la matrice U sia unitaria costituisce un vincolo matematico e fisico imprescindibile: essa garantisce che la trasformazione preservi la norma del vettore (la sua lunghezza complessiva). In questo modo, l'integrità probabilistica del sistema non viene alterata dall'istruzione computazionale, assicurando che la somma delle probabilità di ottenere i possibili risultati al momento della misura resti sempre rigorosamente pari a 1 (rispettando la condizione di normalizzazione $|\alpha|^2 + |\beta|^2 = 1$ per un singolo qubit) [39, 3].

Geometricamente, per il caso di un singolo qubit, l'azione di un gate unitario è visualizzabile come una rotazione del vettore di stato sulla superficie della **Sfera di Bloch** (si veda la Figura 2.1). Durante l'operazione, la direzione del raggio vettore cambia (modificando quindi le probabilità di misura per i rispettivi stati di base) ma la conservazione della norma impone che la punta del vettore rimanga sempre vincolata alla superficie della sfera di raggio unitario [3]. La sequenza programmata di queste moltiplicazioni matriciali definisce un algoritmo quantistico (o *Ansatz* nel caso di circuiti parametrizzati).




Figura 2.1: Rappresentazione sulla Sfera di Bloch dell'evoluzione unitaria di un singolo qubit.

L'applicazione di un gate quantistico (nell'esempio, l'operatore X) corrisponde a una rotazione del raggio vettore di un angolo $\theta = \pi$ che mappa lo stato iniziale $|0\rangle$ nello stato finale $|1\rangle$, modificando l'ampiezza di probabilità degli stati base preservando la norma unitaria del sistema [3].

Entanglement. Un sistema composto si definisce in uno stato **entangled** se non è fattorizzabile come prodotto tensoriale degli stati individuali: $|\Psi\rangle \neq |\psi_1\rangle \otimes \cdots \otimes |\psi_n\rangle$ (dove il termine $|\psi_n\rangle$ indica lo stato locale e isolato del singolo n -esimo qubit), rendendo di fatto le variabili non separabili [39]. Per fornire un'interpretazione tangibile del fenomeno, Preskill [41] paragona l'entanglement a un libro di 100 pagine: se il libro è classico, leggendo una pagina alla volta si acquisisce progressivamente tutta l'informazione; se il libro è quantistico (ed *entangled*), le singole pagine lette individualmente appariranno come puro rumore casuale, perché l'informazione non è scritta sulle singole pagine, ma risiede quasi interamente in *come* le pagine sono correlate globalmente tra loro. In ambito ML, l'applicazione di speciali gate unitari (come i blocchi U_{ent} composti da gate CNOT o Controlled-Z [40]) funge da risorsa architetturale per catturare e codificare direttamente nel circuito le dipendenze multivariate tra le *feature* di un dataset.

Misura e Valore di Aspettazione. Finché non viene misurato, il qubit mantiene l'informazione relativa ad entrambi gli stati simultaneamente. Per estrarre informazione utile da questo spazio vettoriale (come ad esempio la predizione finale di un modello di Machine Learning), si effettua una misurazione. L'estrazione dell'informazione dall'algoritmo quantistico determina il collasso della funzione d'onda. Per scopi predittivi o di training, si ricorre al **valore di aspettazione** (o valore atteso) di un'osservabile $\hat{O}$ (rappresentabile come una matrice hermitiana che garantisce autovalori reali):

$$\langle \hat{O} \rangle = \langle \Psi | \hat{O} | \Psi \rangle$$

Attraverso il prodotto interno tra il *bra*, la matrice dell'osservabile e il *ket*, si ottiene un valore scalare reale che corrisponde alla media statistica dei risultati ottenuti eseguendo e misurando il circuito per molteplici iterazioni (*shot*) [39]. Nel Machine Learning quantistico, questo scalare costituisce l'output iterativo utilizzato dall'ottimizzatore classico per valutare la *loss function* e aggiornare i parametri dell'algoritmo (ossia gli angoli di rotazione θ dei gate quantistici all'interno del circuito) del modello [40, 41].

2.3.2 Architettura dei Variational Quantum Circuits

I VQC (*Variational Quantum Circuits*) sono modelli di machine learning basati su circuiti parametrizzati che operano secondo un paradigma ibrido *quantum-classico*: delegano il calcolo dello stato a un processore quantistico e l'aggiornamento dei parametri a un ottimizzatore classico. Questa architettura è compatibile con il regime NISQ [41] (*Noisy Intermediate-Scale Quantum*), che indica l'attuale era di hardware quantistico, ancora affetto da rumore. I VQC sono ideali in questo contesto poiché utilizzano circuiti a bassa profondità per minimizzare la propagazione degli errori.

Un VQC opera secondo un paradigma strutturato in tre fasi quantistiche principali, affiancate da un modulo di ottimizzazione classico:

1. **Encoding** Realizza la mappatura matematica $\mathcal{E} : \mathbb{R}^d \rightarrow \mathcal{H}^{\otimes n}$ che traduce i dati classici in input, rappresentati da vettori reali di d feature in $\mathbb{R}^d$, all'interno dello spazio vettoriale quantistico di Hilbert $\mathcal{H}^{\otimes n}$ associato a un registro di n qubit. Nella strategia di *angle encoding*:

$$|\phi(x_j)\rangle = \cos(x_j/2)|0\rangle + \sin(x_j/2)|1\rangle \quad (2.3.1)$$

Sotto il profilo fisico-geometrico, la presenza del fattore di dimezzamento $\frac{x_j}{2}$ all'interno degli argomenti trigonometrici di seno e coseno risponde a una precisa proprietà geometrica dello spazio degli stati. Come discusso da Sisini [3], lo stato quantistico di un singolo qubit viene rappresentato geometricamente come un raggio vettore sulla superficie della *Sfera di Bloch*. Mentre nello spazio fisico tridimensionale della sfera l'angolo di rotazione del raggio rispetto all'asse di quantizzazione z è pari a θ , nello spazio vettoriale complesso bidimensionale di Hilbert $\mathbb{C}^2$ le ampiezze di probabilità che definiscono il vettore di stato quantistico sono pesate sull'angolo dimezzato $\theta/2$. Di conseguenza, per imprimere una rotazione di un angolo fisico θ , l'operatore unitario di evoluzione deve agire sulle ampiezze d'onda modulandole rispetto alla metà di tale ampiezza. Questa proprietà geometrica assicura che gli estremi del dominio classico ($x_j = 0$ e $x_j = \pi$) corrispondano a stati quantistici puri reciprocamente ortonormali ($|0\rangle$ e $|1\rangle$), garantendone la massima distinguibilità in fase di misura ed escludendo fenomeni di over-rotation.

2. **Ansatz** L'ansatz è il circuito parametrizzato vero e proprio, rappresentato dall'operatore unitario parametrizzato $U(\theta)$ che fa evolvere lo stato quantistico. Esso è composto da L layer, che ne definiscono la profondità, formati da gate di rotazione e gate CNOT. I gate di rotazione modificano lo stato dei singoli qubit tramite i parametri addestrabili θ , mentre i gate CNOT operano a due qubit per creare l'*entanglement*, ovvero lo stato fondamentale per catturare le correlazioni multivariate nei dati. Il circuito parametrizzato produce lo stato:

$$|\Psi(\theta)\rangle = U(\theta)|\phi(x)\rangle = U_L(\theta_L) \cdots U_1(\theta_1)|\phi(x)\rangle$$

dove $|\Psi(\theta)\rangle$ è il vettore di stato quantistico globale che emerge dall'applicazione dell'ansatz ai dati inizialmente codificati. Per l'input $|\phi(x)\rangle$ viene usato l'*angle encoding*, una specifica tecnica di codifica che inserisce il valore del dato classico x_j nell'ampiezza di probabilità, trasformandolo in un angolo di rotazione. Questo posiziona il qubit in una sovrapposizione coerente dei due vettori ortonormali della base computazionale ($|0\rangle$ e $|1\rangle$).

- ◇ **Data Re-uploading** Nei dispositivi NISQ, il numero limitato di qubit impedisce di incrementare la capacità espressiva del circuito aumentando semplicemente la larghezza del registro. Per superare tale vincolo architetturale, Pérez-Salinas et al. [42] hanno introdotto la tecnica del *Data Re-uploading*. Essa consiste nella re-iniezione periodica del vettore delle feature classiche x all'inizio di ciascun layer variazionale:

$$|\Psi(x; \theta)\rangle = \left[\prod_{l=1}^L U_{\text{ent}}^{(l)} \left(\bigotimes_{j=1}^n R_y(\theta_{l,j}) R_z(\theta'_{l,j}) \right) \left(\bigotimes_{j=1}^n R_y(x_j) \right) \right] |\phi(x)\rangle \quad (2.3.2)$$

Attraverso la ripetizione dell'operatore di encoding, il circuito quantistico cessa di comportarsi come una semplice trasformazione lineare su spazio di Hilbert e acquisisce le proprietà di un approssimatore universale di funzioni non lineari, aumentando l'espressività senza richiedere qubit addizionali [42, 3].

3. **Measurement** Rappresenta il processo conclusivo in cui si estrae l'informazione classica dal sistema quantistico. Essendo il dominio quantistico probabilistico,

si misura l'osservabile $\hat{O}_j$ ripetendo il circuito su molteplici esecuzioni (*shots*). Poiché ogni singola misurazione provoca il collasso dello stato quantistico (funzione d'onda), la media statistica dei risultati ottenuti produce il *valore di aspettazione* $\langle \hat{O}_j \rangle$, tramite il quale sono generate le istanze sintetiche. L'output classico finale prodotto $\tilde{x}_j$ corrisponde proprio al valore di aspettazione $\langle \hat{O}_j \rangle$:

$$\tilde{x}_j = \langle \Psi(\theta) | \hat{O}_j | \Psi(\theta) \rangle, \quad j = 1, \dots, d$$

4. **Parameter Shift Rule** Poiché la *backpropagation* classica non è applicabile sull'hardware quantistico, l'ottimizzazione dei parametri utilizza una regola matematica nota come *parameter shift rule* [43] che permette di calcolare il gradiente esatto della funzione di costo valutando il circuito due volte rispetto al k -esimo parametro (isolato dal vettore base $\hat{e}_k$), spostandolo in avanti e all'indietro di $\pi/2$:

$$\frac{\partial}{\partial \theta_k} \langle \hat{O} \rangle(\theta) = \frac{1}{2} \left[\langle \hat{O} \rangle \left(\theta + \frac{\pi}{2} \hat{e}_k \right) - \langle \hat{O} \rangle \left(\theta - \frac{\pi}{2} \hat{e}_k \right) \right]$$

2.3.3 QGAN e modelli generativi quantistici per dati tabulari

TabularQGAN [6] propone un ansatz specifico per feature miste categoriche e numeriche, con layer di entanglement localizzati in blocchi di qubit (sub-registers) associati a specifici sottoinsiemi di feature. I risultati mostrano che TabularQGAN supera i modelli classici CTGAN e CopulaGAN sull'indice aggregato di similarità SDMetrics, utilizzando un numero di parametri significativamente inferiore.

Parallelamente, QTabGAN [24] introduce un'architettura ibrida fortemente ottimizzata per la compatibilità con il regime NISQ. In questo framework, il circuito quantistico è affiancato a una rete neurale classica (*Classical Mapper*) che funge da decoder, mappando le distribuzioni di probabilità estratte dalle misurazioni quantistiche direttamente nello spazio delle feature tabulari.

Un elemento comune e critico allo stato dell'arte attuale è che, in recenti lavori come TabularQGAN e QTabGAN, la valutazione dei dataset generati si concentra principalmente su metriche di fedeltà statistica e utilità predittiva, senza includere un'analisi esplicita delle metriche di fairness di gruppo (quali SPD, EOD e AOD). In questa tesi, infatti, estendiamo tali linee di ricerca introducendo una valutazione

sistematica della fairness per dati tabulari sintetici in regime quantistico, ponendoci in diretta continuità teorica con i filoni di mitigazione del bias già consolidati nei modelli generativi classici [44, 45].

2.3.4 RepFair-QGAN e la Fairness nei modelli generativi quantistici

Sabbagh et al. [7] introducono il concetto di **fairness rappresentazionale** per i QGAN. Nel loro lavoro, definiscono formalmente un generatore come ϵ -fair se la distanza (quantificata anche tramite la divergenza di Kullback-Leibler) tra la distribuzione dei tratti sensibili generata e una distribuzione uniforme $U(S)$ è $\leq \epsilon$.

Per promuovere tale equità, gli autori descrivono esclusivamente in modo testuale l'applicazione di un *group-wise gradient norm clipping* nel discriminatore, definendola come “una tecnica di clipping della norma del gradiente basata sul gruppo che vincola la magnitudine degli aggiornamenti del discriminatore per ogni gruppo demografico”. Una possibile formalizzazione matematica di quanto descritto nel paper può essere espressa come segue.

Per il gruppo demografico k :

$$\tilde{\nabla}_{\phi} \mathcal{L}_k = \nabla_{\phi} \mathcal{L}_k \cdot \min\left(1, \frac{\tau}{\|\nabla_{\phi} \mathcal{L}_k\|_2}\right)$$

dove:

- $\nabla_{\phi} \mathcal{L}_k$ è il gradiente originale (non modificato) della funzione di loss del discriminatore valutato esclusivamente sui campioni del gruppo demografico k . Questo termine isola matematicamente quelli che gli autori definiscono gli “aggiornamenti del discriminatore per ogni gruppo demografico” [7] rispetto al vettore dei parametri ϕ .
- $\|\nabla_{\phi} \mathcal{L}_k\|_2$ rappresenta la norma L_2 (euclidea) di tale gradiente. Corrisponde esattamente alla “magnitudine” (*magnitude*) [7] degli aggiornamenti di cui gli autori discutono la necessità di misurazione e controllo.
- τ è l'iperparametro che definisce la soglia massima consentita per la norma del gradiente. Esso rappresenta il meccanismo pratico attraverso cui l'algoritmo “vincola” (*constrains*) [7] la magnitudine massima accettabile per singolo gruppo, come spiegano Sabbagh et al..

- $\tilde{\nabla}_{\phi} \mathcal{L}_k$ è il nuovo gradiente *clippato*: se la magnitudine originale supera la soglia τ , il gradiente viene ridimensionato proporzionalmente, altrimenti rimane inalterato (effetto ottenuto moltiplicando il gradiente originale per il termine $\min\left(1, \frac{\tau}{\|\nabla_{\phi} \mathcal{L}_k\|_2}\right)$, il quale varrà 1 se la norma è entro la soglia, oppure agirà da fattore di scala riduttivo se la supera). Questo assicura, come dichiarato nel lavoro originale, che gli aggiornamenti del gradiente di ciascun gruppo demografico “siano controllati uniformemente” (*uniformly controlled*) [7].

L’aggiornamento totale dei parametri del discriminatore è calcolato come la media dei gradienti clippati su tutti i K gruppi demografici presenti:

$$\nabla_{\phi} \mathcal{L}_{\text{total}} = \frac{1}{K} \sum_{k=1}^K \tilde{\nabla}_{\phi} \mathcal{L}_k$$

Questo meccanismo matematico assicura che gli aggiornamenti del discriminatore per ciascun gruppo demografico siano “controllati uniformemente” (*uniformly controlled*) [7], garantendo che nessun gruppo, anche se sovrarappresentato, possa dominare l’aggiornamento dei pesi durante l’addestramento. Come evidenziato dagli autori, tale operazione non solo “promuove una generazione di dati equa” (*promoting fair data generation*), ma affronta intrinsecamente anche il noto problema del *mode collapse* tipico sia delle GAN classiche che di quelle quantistiche (come riportano Sabbagh et al., “*Our method inherently tackles mode collapse, a well-known challenge in both classical and quantum GANs*” [7]).

Tuttavia, come precisato nello stesso studio a causa delle limitazioni fisiche dei qubit disponibili, RepFair-QGAN si concentra esclusivamente su dataset di immagini (MNIST); **non affronta quindi dati tabulari strutturati, non esplora la verifica formale di fairness né la dimensione dell’interpretabilità** [7].

2.4 Fairness nel Quantum Machine Learning

2.4.1 Quantum Fair Machine Learning: il contributo di Perrier

Perrier [46], dichiarando di voler inaugurare questo nuovo ambito di ricerca (“*we inaugurate the field of quantum fair machine learning*”), adatta le definizioni classiche allo spazio vettoriale di Hilbert. Per farlo, l’autore si avvale del formalismo degli operatori di densità [39], descrivendo lo stato di un sistema quantistico misto come:

$$\hat{\rho} = \sum_k p_k |\psi_k\rangle\langle\psi_k|, \quad \hat{\rho} \geq 0, \quad \text{Tr}(\hat{\rho}) = 1$$

In particolare:

- $\hat{\rho}$ (operatore di densità o matrice di densità) rappresenta lo stato globale e probabilistico del sistema quantistico;
- p_k è la probabilità classica che il sistema si trovi nello specifico stato puro quantistico k ;
- $|\psi_k\rangle\langle\psi_k|$ è il proiettore associato allo stato puro $|\psi_k\rangle$, ottenuto dal prodotto tensoriale tra il vettore colonna (*ket*) e il suo trasposto coniugato (*bra*);
- $\hat{\rho} \geq 0$ indica che la matrice di densità deve essere definita positiva (i suoi autovalori, ovvero le probabilità, non possono essere negativi);
- $\text{Tr}(\hat{\rho}) = 1$ indica che la traccia (la somma degli elementi sulla diagonale principale) deve essere pari a 1, garantendo che la somma totale delle probabilità di tutti i possibili stati sia il 100%.

Nel definire i concetti di equità, l’autore introduce testualmente la “*quantum ε -statistical parity*”, richiedendo che la probabilità di un dato esito sia indipendente dall’appartenenza a un gruppo sensibile. A partire da questa definizione testuale, è possibile fornire una **nostra formalizzazione matematica**, definendo la **Quantum Statistical Parity** (QSP) tramite la differenza dei valori attesi:

$$\text{QSP-diff} = |\text{Tr}(\hat{O}\hat{\rho}_1) - \text{Tr}(\hat{O}\hat{\rho}_0)| \leq \varepsilon$$

dove i termini di questa nostra interpretazione operativa indicano:

- QSP-diff quantifica la differenza di parità statistica quantistica tra due gruppi;
- $\hat{O}$ è l'osservabile misurato, che codifica l'operazione di misurazione necessaria per estrarre l'output classico;
- $\hat{\rho}_1$ e $\hat{\rho}_0$ sono gli operatori di densità che rappresentano rispettivamente gli stati quantistici codificati per il gruppo demografico privilegiato (1) e non privilegiato (0);
- $\text{Tr}(\hat{O}\hat{\rho}_i)$ calcola il **valore di aspettazione** (valore atteso) della misurazione per il gruppo i . Come esplicitato dallo stesso Perrier [46], l'uso dell'operatore di Traccia applicato alla matrice di densità rappresenta la naturale generalizzazione per gli stati misti (tipici delle popolazioni statistiche) della formula $\langle \Psi | \hat{O} | \Psi \rangle$ introdotta in precedenza per i singoli stati puri;
- ε è la soglia di tolleranza massima (iperparametro) entro la quale la differenza assoluta dei valori attesi è considerata accettabile per definire il modello "fair".

Per quantificare quanto due distribuzioni differiscano, Perrier fa esplicito riferimento alla **distanza di traccia**, che nel suo lavoro definisce anche "*L₁-Kolmogorov distance*" [46]. La formula esatta utilizzata dall'autore (che si rifà a Nielsen e Chuang) per gli stati quantistici (rappresentati da operatori di densità) è [46, 39]:

$$D_{\text{tr}}(\hat{\rho}_1, \hat{\rho}_0) = \frac{1}{2} \text{Tr} |\hat{\rho}_1 - \hat{\rho}_0|$$

In particolare:

- D_{tr} indica la metrica della distanza di traccia tra due stati quantistici;
- $\hat{\rho}_1 - \hat{\rho}_0$ calcola la differenza matriciale tra gli operatori di densità dei due gruppi;
- L'operatore $\text{Tr}|\dots|$ calcola la traccia del valore assoluto (o modulo) della matrice risultante. Equivalentemente, $\|\dots\|_1$ denota la norma della traccia (o norma L_1), calcolata come la somma dei valori singolari della matrice risultante [46];

- Il fattore $\frac{1}{2}$ normalizza il risultato in modo che la distanza sia sempre un valore compreso tra 0 (stati identici) e 1 (stati perfettamente distinguibili/ortogonali).

Infine, Perrier introduce il principio di **fairness individuale quantistica** (o “*Quantum Lipschitz Fairness*”), definendolo formalmente come un vincolo in cui la distanza tra gli output quantistici deve essere limitata dalla distanza tra gli input moltiplicata per una costante [46]. Siccome lo stesso autore suggerisce di valutare tale distanza confrontando le distribuzioni di probabilità sulle misurazioni finali, si propone **una nostra formalizzazione operativa di questo vincolo**. A differenza della fairness di gruppo (che confronta aggregati demografici), la fairness individuale deve valere per *qualsiasi* coppia di individui. Per ogni coppia di stati di densità iniziali $\hat{\rho}$ e $\hat{\sigma}$ (rappresentanti due individui qualsiasi, a prescindere dal loro gruppo di appartenenza), si ha che:

$$|\text{Tr}(\hat{O}\mathcal{E}(\hat{\rho})) - \text{Tr}(\hat{O}\mathcal{E}(\hat{\sigma}))| \leq L \cdot D_{\text{tr}}(\hat{\rho}, \hat{\sigma})$$

In particolare:

- $\mathcal{E}$ (mappa quantistica o *quantum channel*) rappresenta l’evoluzione del sistema, ovvero l’applicazione del modello allo stato iniziale;
- $\mathcal{E}(\hat{\rho})$ e $\mathcal{E}(\hat{\sigma})$ sono gli stati quantistici finali di output prodotti dal modello a partire dai due individui arbitrari in input;
- $\text{Tr}(\hat{O}\mathcal{E}(\cdot))$ è, come visto in precedenza, il valore atteso della predizione finale del modello dopo la misurazione;
- Il termine a sinistra della disuguaglianza rappresenta quindi la differenza assoluta tra le predizioni fornite dal modello per i due individui;
- $D_{\text{tr}}(\hat{\rho}, \hat{\sigma})$ è la distanza di traccia calcolata sui due stati originari di input, indicandone la reale diversità intrinseca;
- L funge da costante di Lipschitz del modello, limitando e vincolando la variazione massima dell’output alla reale distanza originaria degli input, garantendo così che individui simili nel dominio quantistico ricevano trattamenti simili dal circuito.

2.4.2 Verifica formale della fairness in QML: dalla Counterfactual Fairness al Bias Pair di Guan et al.

Nel **Machine Learning classico**, un punto di riferimento per la definizione e la misura dell'equità a livello locale e individuale è costituito dalla *Counterfactual Fairness* (formalizzata originariamente da Kusner et al. [47] nel contesto dei modelli causali strutturati). Secondo tale formulazione, una decisione algoritmica si definisce equa rispetto a un dato individuo se la predizione del modello rimarrebbe identica in un mondo alternativo (controfattuale) in cui l'attributo sensibile del soggetto fosse stato differente, assumendo come invariati tutti i fattori non causalmente dipendenti da esso. Questa condizione di parità controfattuale locale si esprime attraverso la seguente equazione:

$$P(\hat{Y}_{A \leftarrow a}(x) = y \mid X = x, A = a) = P(\hat{Y}_{A \leftarrow a'}(x) = y \mid X = x, A = a) \quad (2.4.1)$$

dove i singoli termini e gli operatori matematici indicano:

- $P(\cdots \mid \cdots)$ definisce la misura di probabilità condizionata classica;
- $\hat{Y}$ indica la variabile casuale associata alla predizione finale restituita dal modello decisionale;
- $\hat{Y}_{A \leftarrow a}(x) = y$ rappresenta l'esito controfattuale, ossia la predizione y che il modello formulerebbe qualora l'attributo sensibile A venisse forzato (tramite un intervento di sostituzione attiva) ad assumere il valore specifico a per un soggetto caratterizzato dalle feature classiche x ;
- $\hat{Y}_{A \leftarrow a'}(x) = y$ esprime in modo analogo la predizione controfattuale qualora lo stesso attributo sensibile venisse forzato ad assumere il valore alternativo e opposto a' ;
- $X = x$ e $A = a$ costituiscono i dati osservati (fattuali) relativi rispettivamente alle caratteristiche non protette e all'attributo sensibile reale dell'individuo, fungendo da contesto di condizionamento per la stima probabilistica.

La parità controfattuale impone quindi che individui identici per profilo di merito (ovvero con dati fattuali e controfattuali sovrapponibili nello spazio delle variabili non protette) ricevano dal classificatore il medesimo trattamento predittivo.

Nel **dominio quantistico**, Guan, Fang e Ying [48] estendono questo principio di parità di trattamento locale sfruttando le proprietà geometriche dello spazio di Hilbert, sviluppando un framework formale per la verifica e l'analisi della fairness nei modelli decisionali di Quantum Machine Learning. Adottando il principio di fairness individuale secondo cui individui simili devono ricevere trattamenti simili, gli autori introducono il concetto di *bias pair*. Testualmente, definiscono un *bias pair* per una data tolleranza (ε, δ) quando la distanza tra due stati quantistici in input è $\leq \varepsilon$, ma la distanza tra le rispettive distribuzioni di output è $> \delta$ [48].

Poiché gli autori indicano l'uso della distanza di traccia per misurare gli input e della distanza di variazione totale per misurare gli output, proponiamo qui una nostra formalizzazione matematica e operativa di tale definizione, avvalendoci della norma L_1 . Una coppia $(\hat{\rho}, \hat{\sigma})$ è definibile operativamente come un **bias pair di parametri** (ε, δ) se:

$$D_{\text{tr}}(\hat{\rho}, \hat{\sigma}) \leq \varepsilon \quad \text{e} \quad \|\mathbf{p}(\cdot \mid \hat{\rho}) - \mathbf{p}(\cdot \mid \hat{\sigma})\|_1 > \delta$$

In particolare:

- $\hat{\rho}$ e $\hat{\sigma}$ sono gli operatori di densità che codificano gli stati quantistici di due individui (dati) distinti forniti in input al modello;
- $D_{\text{tr}}(\hat{\rho}, \hat{\sigma})$ è la distanza di traccia tra i due stati, che quantifica la reale diversità (o similarità) intrinseca tra i due individui;
- ε è la soglia (iperparametro) che fissa la massima distanza entro cui due individui sono legalmente/eticamente considerati simili;
- $\mathbf{p}(\cdot \mid \hat{\rho})$ e $\mathbf{p}(\cdot \mid \hat{\sigma})$ sono i vettori che descrivono le distribuzioni di probabilità dell'output classico, ottenute misurando il circuito condizionato rispettivamente agli input $\hat{\rho}$ e $\hat{\sigma}$;
- $\|\dots\|_1$ denota la norma L_1 , utilizzata per quantificare matematicamente la discrepanza totale tra le predizioni ricevute dai due individui;
- δ è la soglia oltre la quale la differenza di predizione (trattamento) è considerata inaccettabile e discriminatoria.

Per quantificare globalmente l'equità del modello, gli autori si affidano alla **costante di Lipschitz quantistica** (denotata con K^*), definendola come il più piccolo coefficiente per cui la variazione dell'output risulta limitata da K^* volte la variazione dell'input [48]. Formalizzando matematicamente questo concetto, possiamo calcolare in modo esatto K^* come l'estremo superiore del rapporto tra la distanza degli output e la distanza quantistica degli input:

$$K^* = \sup_{\hat{\rho} \neq \hat{\sigma}} \frac{\|\mathbf{p}(\cdot | \hat{\rho}) - \mathbf{p}(\cdot | \hat{\sigma})\|_1}{D_{\text{tr}}(\hat{\rho}, \hat{\sigma})}$$

In particolare:

- L'operatore $\sup_{\hat{\rho} \neq \hat{\sigma}}$ ricerca il caso peggiore (in questo caso il valore massimo possibile) valutato su tutte le infinite combinazioni di coppie di stati quantistici distinti presenti nello spazio di Hilbert;
- Il numeratore misura il divario nel trattamento (output), mentre il denominatore indica la diversità originaria (input).

Di conseguenza, K^* funge da **indicatore globale di fairness**: un modello con un K^* più basso è intrinsecamente più equo e stabile.

Come descritto nel lavoro appena citato, l'algoritmo di verifica è progettato attorno a una struttura dati altamente efficiente basata su *Tensor Networks* ed è stato implementato su *Google TensorFlow Quantum* [48]. Tale architettura ha permesso di mitigare l'esplosione dimensionale dello spazio degli stati, riuscendo a verificare formalmente la fairness di modelli quantistici con fino a 27 qubit.

Infine, un risultato controintuitivo ma fondamentale di questo studio (dimostrato matematicamente nel Teorema 2 della fonte) è che l'introduzione di perturbazioni può mitigare il bias: *“mostriamo che il rumore quantistico può migliorare la fairness”* (*we show that quantum noise can improve fairness*) [48]. Adottando una nostra notazione esplicita, se denotiamo con $\mathcal{A}_N$ un modello affetto da rumore ambientale e con $\mathcal{A}$ lo stesso modello ideale (noiseless), la relazione si esprime come:

$$K^*(\mathcal{A}_N) \leq K^*(\mathcal{A})$$

confermando che l'ambiente rumoroso dei dispositivi NISQ abbate la costante di Lipschitz, stringendo il bound sulle discriminazioni algoritmiche [48].

2.4.3 Quantificazione dell’Entanglement nei Circuiti Variazionali: Meyer-Wallach e libreria `qsalt`

L’entanglement multipartito costituisce la risorsa fondamentale attraverso cui un circuito quantistico correla i qubit associati alle diverse feature del dataset. Per quantificare rigorosamente il grado di entanglement globale generato da uno stato puro a n qubit $|\Psi\rangle$, la letteratura fa riferimento alla misura di **Meyer-Wallach** (Q) [49], operazionalizzata attraverso la purezza media dei singoli sottosistemi a un qubit:

$$E_{\text{MW}}(|\Psi\rangle) = 1 - \frac{1}{n} \sum_{j=1}^n \text{Tr}(\hat{\rho}_j^2) \quad (2.4.2)$$

dove $\hat{\rho}_j = \text{Tr}_{\setminus j}(|\Psi\rangle\langle\Psi|)$ rappresenta la matrice di densità ridotta del j -esimo qubit, ottenuta tramite traccia parziale su tutti i restanti $n - 1$ sottosistemi [39]. Quando lo stato è fattorizzabile (assenza di entanglement), tutti i singoli qubit rimangono in stati puri ($\text{Tr}(\hat{\rho}_j^2) = 1$), annullando E_{MW} ; al contrario, in presenza di correlazioni quantistiche massimali, i sottosistemi collassano in stati massimamente misti, massimizzando l’entanglement score.

Nell’ambito delle architetture NISQ reali, il calcolo analitico di $\text{Tr}(\hat{\rho}_j^2)$ tramite tomografia dello stato risulta computazionalmente proibitivo. A tale scopo, nel presente lavoro viene adottato il protocollo di Bell sampling a due copie (*Two-Copy Bell State Measurement*), implementato tramite la libreria open-source `qsalt` di Miller et al.[27]. Eseguendo due repliche parallele del circuito preparatorio e misurando congiuntamente ciascuna coppia di qubit $(j, j + n)$ su base di Bell, il sistema stima il primo coefficiente dei *Weight Enumerators* di Shor-Laflamme (a_1), il quale quantifica la purezza media dei sottosistemi a singolo qubit senza richiedere l’accesso esplicito alla matrice di densità globale, fornendo una stima empirica robusta contro il rumore statistico di misura[27].

2.5 Interpretabilità di VQC e XQML

2.5.1 Il problema dell'interpretabilità nel contesto quantistico

La transizione dai modelli classici ai Variational Quantum Circuits solleva nuove problematiche per il campo dell'Explainable Quantum Machine Learning (XQML) [25]. Come analizzato nello studio di rassegna di Gil-Fuster et al. [50], esistono tre proprietà intrinseche della meccanica quantistica che alterano profondamente il modo in cui i modelli possono essere interpretati rispetto al contesto classico:

- **Misura distruttiva e assenza di memoria intermedia:** Come riportano letteralmente gli autori Gil-Fuster et al., *“l’archiviazione di informazioni intermedie (anche se non si tratta dell’intero stato) distrugge inevitabilmente la computazione”* (Storing intermediate information [...] necessarily destroys the computation) [50].

Forniamo qui una formalizzazione matematica di questo limite: per estrarre informazione sulle *feature* latenti di uno stato intermedio $|\psi_{\text{int}}\rangle$ è necessario effettuare una misurazione rispetto a un osservabile $\hat{O}$. Questa operazione porta al collasso probabilistico della funzione d’onda restituendo il valore di aspettazione $\langle \hat{O} \rangle = \langle \psi_{\text{int}} | \hat{O} | \psi_{\text{int}} \rangle$. Di conseguenza, è fisicamente impossibile ispezionare il flusso dei dati intermedi senza arrestare e alterare irrimediabilmente l’algoritmo stesso.

- **Teorema di No-Cloning:** Come accennato dagli autori Gil-Fuster et al., citando il lavoro fondazionale di Wootters e Zurek [51], *“gli stati quantistici ignoti non possono essere copiati in modo che entrambe le copie siano statisticamente indistinguibili dall’input”* [50].

Forniamo qui una formalizzazione matematica di questo divieto esprimendo l’impossibilità universale di costruire un operatore unitario U_{clone} in grado di eseguire la seguente trasformazione esatta:

$$U_{\text{clone}}(|\psi\rangle \otimes |0\rangle) = |\psi\rangle \otimes |\psi\rangle$$

In particolare, i termini di questa equazione esplicativa sono:

- U_{clone} : l’operatore matriciale unitario ipotetico, di cui il teorema fisico vieta l’esistenza in forma universale;

- $|\psi\rangle$: lo stato quantistico arbitrario e ignoto che si desidera copiare;
- $|0\rangle$: un qubit ausiliario (noto in letteratura come *ancilla qubit* [39, 3]) nello stato base, predisposto per ricevere l'informazione clonata;
- $\otimes$: l'operatore di prodotto tensoriale che unisce i due qubit in un unico sistema quantistico globale;
- $|\psi\rangle \otimes |\psi\rangle$: lo stato finale fisicamente interdetto, in cui coesistono due copie identiche e indipendenti dello stato originario.

Gil-Fuster et al. evidenziano che questa limitazione comporta che “ogni volta che il modello viene valutato, il circuito quantistico deve essere eseguito da zero” [50]. Da ciò si deduce che le consuete strategie algoritmiche di perturbazione locale dei dati, essenziali per spiegare i modelli classici, divengano computazionalmente e temporalmente molto costose in ambito quantistico.

- **Linearità dell'evoluzione unitaria:** L'interpretabilità nelle reti neurali classiche poggia in gran parte sulla loro “composizione annidata di funzioni di attivazione non lineari” [50]. Nei circuiti quantistici, invece, la manipolazione dell'informazione avviene tramite operatori strettamente lineari.

Forniamo qui una formalizzazione matematica della linearità quantistica con la seguente identità:

$$U(\alpha|\psi\rangle + \beta|\phi\rangle) = \alpha U|\psi\rangle + \beta U|\phi\rangle$$

In particolare, i termini di questa equazione esplicativa sono:

- α e β sono le ampiezze di probabilità (numeri complessi) associate alla sovrapposizione quantistica originaria;
- $|\psi\rangle$ e $|\phi\rangle$ sono due generici vettori di stato in input;
- U è l'operatore unitario (gate) che descrive l'evoluzione del sistema e agisce in modo direttamente proporzionale sui singoli stati base, senza introdurre deviazioni non lineari.

Gli autori precisano che, di per sé, tale linearità “può tradursi in un’interpretabilità diretta” in alcuni contesti analitici [50]. Possiamo concludere dicendo che la linearità dell’evoluzione unitaria (e quindi l’assenza di un classico grafo computazionale con attivazioni non lineari localizzate) rende gran parte della complessità interpretativa estraibile solamente nel momento conclusivo della misurazione.

2.5.2 Dalla Teoria Assiomatica dei Giochi all’Explainable AI: il Framework SHAP

L’impiego dei valori di Shapley nell’ambito dell’apprendimento automatico classico è stato formalizzato da Lundberg e Lee [52] attraverso il framework **SHAP** (*SHapley Additive exPlanations*), che ha unificato diverse tecniche di spiegazione locale sotto una solida base assiomatica derivata dalla teoria dei giochi cooperativi [53]. Nel paradigma predittivo classico, un modello di machine learning di natura black-box $f(x)$ viene interpretato a livello locale attribuendo a ciascuna caratteristica (*feature*) i un valore di importanza locale $\phi_i(f, x)$. Tale valore quantifica l’effetto della feature sulla deviazione della predizione locale rispetto all’output medio del modello, ed è calcolato attraverso la seguente formulazione matematica:

$$\phi_i(f, x) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f_x(S \cup \{i\}) - f_x(S)] \quad (2.5.1)$$

dove i singoli termini, operatori e indici matematici indicano:

- $\mathcal{F}$ rappresenta l’insieme totale di tutte le feature di input classiche (che costituisce la “grande coalizione” dei giocatori nel contesto della teoria dei giochi);
- i indica la specifica feature di cui si desidera quantificare il contributo causale locale;
- $S \subseteq \mathcal{F} \setminus \{i\}$ definisce una generica coalizione (sottoinsieme) di feature che non include al suo interno la variabile i sotto analisi;
- $|S|$ e $|\mathcal{F}|$ indicano rispettivamente la cardinalità (ovvero il numero di elementi attivi) del sottoinsieme S e dell’insieme completo delle feature $\mathcal{F}$;

- l'operatore fattoriale $!$ è applicato alle rispettive cardinalità per calcolare i coefficienti combinatori;
- $\frac{|S|!(|\mathcal{F}|-|S|-1)!}{|\mathcal{F}|!}$ costituisce il peso probabilistico associato alla coalizione S , il quale assicura che i contributi marginali vengano mediati in modo perfettamente uniforme su tutte le possibili sequenze (permutazioni) con cui le feature possono essere introdotte nel modello;
- $f_x(S)$ rappresenta la funzione di valore (o payoff) del sottoinsieme S per l'istanza x , operativamente definita come l'aspettazione condizionata del modello ristretta alle sole variabili attive: $f_x(S) = \mathbb{E}[f(x) \mid x_S]$;
- $[f_x(S \cup \{i\}) - f_x(S)]$ definisce il contributo marginale apportato dalla feature i , misurando la variazione diretta dell'output del modello quando la variabile viene aggiunta alla coalizione di feature S .

La rilevanza metodologica di questo approccio risiede nel fatto che SHAP è l'unico metodo di attribuzione locale in grado di soddisfare contemporaneamente tre proprietà assiomatiche fondamentali [52]: l'*efficienza* (la somma delle attribuzioni dei singoli giocatori eguaglia la differenza tra la predizione locale e il valore atteso globale, $\sum_i \phi_i = f(x) - \mathbb{E}[f]$), la *simmetria* (feature che apportano contributi marginali identici a qualsiasi coalizione ricevono valori di Shapley identici) e la *monotonicità* (se il contributo marginale di una feature aumenta a seguito di un cambio del modello, il suo valore di Shapley non può diminuire).

Nel contesto del nostro lavoro, tale formalismo costituisce il precursore teorico diretto per l'interpretabilità dei modelli quantistici: mentre SHAP opera trattando le **feature dell'input classico** come giocatori della cooperazione [52], l'estensione quantistica SVQX (discussa nella sezione successiva) trasla tale logica sui componenti fisici del circuito, elevando i **gate quantistici** al ruolo di giocatori della coalizione [25].

2.5.3 Quantum Shapley Values: il framework di Heese et al.

La teoria dei giochi cooperativi, fondata storicamente sul lavoro di Shapley [53], introduce un metodo matematico, gli **Shapley values**, per valutare il contributo di singoli individui all'interno di un gioco di coalizione (*coalition game*). Heese et al. [25]

compiono un passo fondamentale per l'Explainable Quantum Machine Learning (XQML), adattando questo concetto ai circuiti quantistici parametrizzati (tramite un framework che gli autori denominano “*Shapley values for quantum circuit explanations*”, o SVQXs).

Come dichiarano testualmente gli autori, l'intuizione alla base del loro approccio è quella di “*considerare i gate (o gruppi di gate) come giocatori*” (*consider the gates as players*) e di utilizzare una “*funzione di valore che è determinata dai risultati delle misurazioni*” [25]. Formalizzando matematicamente questo concetto tramite una notazione in linea con la struttura dei circuiti, definiamo l'insieme dei gate attivi come $\mathcal{G} = \{g_1, \dots, g_p\}$ e una funzione di valore $v : 2^{\mathcal{G}} \rightarrow \mathbb{R}$. Lo Shapley value per il singolo gate g_i è calcolato come:

$$\phi_i = \sum_{S \subseteq \mathcal{G} \setminus \{g_i\}} \frac{|S|! (|\mathcal{G}| - |S| - 1)!}{|\mathcal{G}|!} [v(S \cup \{g_i\}) - v(S)]$$

In particolare, i termini di questa equazione esplicativa sono:

- ϕ_i è lo Shapley value, ovvero il contributo medio (o "importanza") assegnato al gate g_i ;
- $\mathcal{G}$ rappresenta la "grande coalizione", ossia l'insieme di tutti i gate del circuito quantistico, con $|\mathcal{G}|$ che ne indica il numero totale;
- S è una specifica coalizione (un sottoinsieme) di gate che *non* include al suo interno il gate g_i ;
- $v(S)$ è la funzione di valore (o *payoff*) ottenuta eseguendo e misurando il modello che utilizza esclusivamente i gate presenti in quella specifica coalizione S ;
- L'espressione $[v(S \cup \{g_i\}) - v(S)]$ quantifica il *contributo marginale* del gate g_i , misurando l'incremento (o decremento) della funzione di valore derivante dall'aggiunta di g_i alla coalizione S ;
- Il termine frazionario con i fattoriali funge da peso probabilistico, garantendo che il contributo marginale sia mediato equamente su tutte le possibili sequenze (permutazioni) con cui i gate possono essere progressivamente aggiunti al circuito.

Heese et al. limitano l'applicazione del loro framework alla valutazione di funzioni di valore puramente performative, tra cui l'accuratezza per i classificatori o la *Hellinger fidelity* per i modelli generativi [25]. A partire dalla proposta originale dello studio menzionato, si propone quindi una nostra interpretazione del metodo: applicando tale costrutto a un VQC generativo e definendo la funzione di valore $v(S)$ come la riduzione (o il rispetto) delle metriche di fairness algoritmica (SPD, AOD), lo scalare ϕ_i ci permette di identificare analiticamente quali gate (e di conseguenza quali feature in essi codificate) siano maggiormente responsabili delle proprietà di equità dell'output.

2.5.4 Q-LIME: spiegazioni locali per QNN

Nel contesto dell'interpretabilità locale, Pira e Ferrie [26] compiono un passo fondamentale proponendo una generalizzazione per i modelli quantistici. Come dichiarano testualmente gli autori, essi generalizzano “una tecnica classica chiamata LIME, introducendo Q-LIME, che produce spiegazioni per le reti neurali quantistiche” [26].

Sulla base dei limiti fisici discussi in precedenza, notiamo che **Q-LIME supera intrinsecamente il vincolo del Teorema di No-Cloning**: anziché tentare di perturbare direttamente lo stato quantistico in sovrapposizione (operazione fisicamente impossibile), il framework effettua le perturbazioni direttamente nello spazio classico dei parametri di encoding, aggirando l'ostacolo alla base.

A partire dalla definizione algoritmica generale fornita dagli autori, formalizziamo matematicamente l'ottimizzazione del modello surrogato (ossia il modello semplice e interpretabile impiegato per approssimare le decisioni della rete quantistica, che costituisce l'effettiva *spiegazione* restituita in output da Q-LIME). La spiegazione per una specifica istanza x_0 è ottenuta addestrando un modello interpretabile locale g^* su un set di perturbazioni $x_0 + \delta_k$:

$$g^* = \arg \min_g \sum_k w_k (f(x_0 + \delta_k) - g(x_0 + \delta_k))^2 + \Omega(g)$$

In particolare, i termini di questa equazione esplicativa sono:

- g^* è il modello surrogato ottimale (la spiegazione locale, tipicamente un modello lineare) che approssima al meglio il comportamento della QNN per la specifica

istanza considerata;

- x_0 è il dato di input classico originale che si desidera spiegare;
- δ_k rappresenta la perturbazione (rumore) aggiunta al dato iniziale nello spazio classico per esplorarne l'intorno locale prima della codifica quantistica;
- $f(\cdot)$ e $g(\cdot)$ sono rispettivamente l'output della black-box quantistica (il valore di aspettazione misurato) e l'output del modello surrogato classico per il dato perturbato;
- Il termine $(f(x_0 + \delta_k) - g(x_0 + \delta_k))^2$ quantifica l'errore (*loss*), misurando la distanza tra le predizioni della QNN e quelle del modello interpretabile;
- $w_k = \exp(-\|\delta_k\|^2/\sigma^2)$ è il peso assegnato a ciascuna perturbazione. Esso decade esponenzialmente all'aumentare della distanza $\|\delta_k\|^2$, garantendo che il modello g^* sia fedele alla QNN strettamente nell'intorno locale misurato dalla larghezza di banda σ ;
- $\Omega(g)$ è il termine di regolarizzazione che penalizza la complessità intrinseca del modello surrogato g , imponendo che la spiegazione rimanga semplice e umanamente interpretabile.

Oltre all'adattamento della funzione di loss, il framework si distingue per la gestione dell'incertezza: come sottolineano gli autori, il QML *“ci costringe in modo unico ad affrontare l'incertezza nell'interpretazione delle sue decisioni”* [26]. Per questo motivo, Q-LIME identifica esplicitamente quelle che gli autori definiscono le **regioni di indecisione** (*“region of indecision”*). In queste specifiche aree dello spazio dei dati, come evidenziano Pira e Ferrie, ai campioni viene assegnata un'“*etichetta casuale*” a causa di misurazioni quantistiche intrinsecamente stocastiche [26]. Possiamo concludere dicendo che in tali regioni è la pura casualità del collasso della funzione d'onda, e non la struttura semantica delle feature, a determinare l'output: **questo è un aspetto fondazionale della meccanica quantistica che non possiede alcun equivalente diretto negli strumenti XAI puramente classici.**

2.5.5 Interpretabilità strutturale dei VQC rispetto agli LLM

I VQC offrono una **interpretabilità strutturale intrinseca** grazie alla struttura esplicita del circuito quantistico. Come dimostrato da Daskin [54], le reti neurali quantistiche basate su VQC possono essere comprese come una “*combinazione lineare di ridge functions*” (funzioni di crinale), un costrutto matematico storicamente “*utilizzato per comprendere l’interpretabilità e la spiegabilità delle reti neurali classiche*”. Partendo dalla definizione dell’autore, basata sulla forma di Fourier esponenziale:

$$\Psi_{w_k} := e^{ix \cdot w_k}$$

e considerando che, come suggerito dallo stesso studio, il piano complesso può essere riscritto utilizzando esclusivamente funzioni a valori reali [54], presentiamo di seguito una nostra formalizzazione matematica. In particolare, esprimiamo la decomposizione dell’output effettivo di un VQC (basato su gate di rotazione) nel dominio dei numeri reali in questo modo:

$$f_{\text{VQC}}(x; \theta) = \sum_k c_k \cos(\omega_k^\top \theta + \phi_k)$$

I termini che compongono questa nostra equazione esplicativa indicano:

- $f_{\text{VQC}}(x; \theta)$ è l’output continuo (il valore di aspettazione misurato) del circuito quantistico, valutato per un dato input x e parametrizzato da θ ;
- x rappresenta il vettore delle feature classiche fornite in input al modello;
- θ è il vettore globale dei parametri addestrabili (tipicamente gli angoli dei gate di rotazione) che definiscono l’evoluzione dell’ansatz quantistico;
- c_k è il coefficiente reale (peso o ampiezza scalare) associato alla k -esima componente della combinazione lineare;
- $\cos(\dots)$ funge da *ridge function* a valori reali, catturando la natura intrinsecamente periodica e limitata delle trasformazioni unitarie quantistiche;
- ω_k è il vettore delle frequenze, il quale determina analiticamente la direzione e il peso con cui i parametri θ si combinano proiettivamente all’interno del k -esimo termine;

- ϕ_k è l'offset di fase (o bias angolare) specifico per la k -esima componente.

Portando avanti una riflessione architetture comparativa, si osserva che questa decomposizione analitica, che divide il modello in chiare componenti periodiche, è **strutturalmente impossibile da ottenere per un Large Language Model (LLM)** di natura *black-box*. A tal proposito, la Tabella 2.1 propone un quadro di confronto tra i due paradigmi.

Tabella 2.1: Confronto tra paradigmi di interpretabilità: VQC vs. LLM.

Dimensione	LLM	VQC
Struttura interna	Implicita, miliardi di pesi	Esplicita, gate con significato operativo definito
Accesso stati intermedi	Impossibile (black-box)	Vincolato dalla misura, ma strutturalmente ispezionabile
Attribuzione del contributo	Post-hoc senza garanzie di fedeltà	Quantum Shapley Values con calcolo algoritmico [25]
Correlazioni spurie	Non distinguibili	Identificabili tramite Shapley values sui gate di encoding*

***Nota:** sebbene il framework introdotto da Heese et al. [25] utilizzi i Quantum Shapley Values (SVQX) per attribuire un valore di importanza ai singoli gate quantistici in generale, evidenziamo che, oltre a questo, è possibile utilizzare le importanze attribuite dai SVQX agli specifici gate di encoding per l'identificazione diretta di correlazioni spurie.

2.6 Sintesi Critica e Posizionamento della Tesi

2.6.1 Tre pilastri, tre filoni di ricerca separati

Il percorso proposto attraverso la letteratura evidenzia che i tre topic principali del presente lavoro, ossia **generazione di dati sintetici**, **fairness** e **interpretabilità**, sono stati affrontati in filoni di ricerca separati.

Sul versante della **generazione di dati tabulari**, gli studi si sono concentrati quasi esclusivamente sulla massimizzazione delle performance predittive (*utility*) e della fedeltà statistica (*fidelity*). Come emerge dalla rassegna di Borisov et al. [15], la valutazione qualitativa dei generatori si basa principalmente su metriche di utilità (come la “*machine learning efficacy*”). Allo stesso modo, le recenti architetture quantistiche per dati eterogenei, quali TabularQGAN di Bhardwaj et al. [6] e QTabGAN di Kumari et al. [24], valutano l’output unicamente tramite indici di similarità distribuzionale (es. *SDMetrics*, *Jensen-Shannon Divergence*) e accuratezza downstream. Di conseguenza, in questi lavori la fairness e l’interpretabilità del processo generativo risultano dimensioni ancora non sufficientemente approfondite: la valutazione esplicita di metriche di equità e l’uso di strumenti XQML per analizzare il processo generativo tabulare rimangono, per quanto di nostra conoscenza, limitati [6, 24, 25].

Sul versante della **fairness quantistica**, i framework teorici introdotti in letteratura sono stati concepiti per valutare esclusivamente i modelli discriminativi. Lo studio fondazionale di Perrier [46] contestualizza le metriche di parità esplicitamente in un “*contesto di classificazione*”. Analogamente, il framework di verifica formale sviluppato da Guan et al. [48] è progettato in modo specifico per l’analisi di un “*quantum decision model*” (modello decisionale quantistico), impiegato per task di classificazione (come il credit scoring) o regressione. Di conseguenza, l’estensione e l’applicazione di tali framework teorici e di verifica formale ad architetture generative per la sintesi di nuovi dati tabulari resta, per quanto ci risulta, un problema da approfondire per quanto emerge dalle rassegne di Perrier e Guan et al. [46, 48]. Pertanto, in questa tesi esploriamo come alcuni di questi concetti formali (ad es. parità statistica quantistica e costanti di Lipschitz) possano essere adattati e impiegati nella progettazione e valutazione di architetture generative basate su VQC per dati tabulari.

Sul versante dell'**interpretabilità (XQML)**, i framework attuali presentano le medesime limitazioni applicative. Come accennato, gli approcci in letteratura si dividono principalmente in due rami: la spiegabilità orientata alle feature di input (*feature attribution*) e quella orientata alla struttura interna del circuito (*circuit explanation*). Nel primo ramo, strumenti come Q-LIME, introdotti da Pira e Ferrie [26], sono stati finora applicati quasi esclusivamente all'interpretazione di task predittivi (e.g. "*interpreting the classification output of a QNN*"). Nel secondo ramo, che sposta l'analisi direttamente sui componenti fisici del circuito trattando i singoli gate (o gruppi di gate) come giocatori di una coalizione, si collocano invece i *Quantum Shapley Values* (SVQX) proposti da Heese et al. [25]. Sebbene gli autori ne mostrino l'utilità sia per classificatori sia per circuiti generativi (QGAN), la loro analisi si focalizza in via prioritaria sulla diagnosi di anomalie ed effetti fisici ("*deficienze dell'hardware*" quantistico indotte dal rumore NISQ) e sulla comprensione del ruolo strutturale dei gate. Nei lavori sopracitati si osserva tuttavia che, sebbene tali framework vengano impiegati con successo per analizzare la struttura interna dei circuiti quantistici rispetto a specifici task, il loro uso sistematico per interpretare la semantica delle feature e validare le logiche di equità algoritmica (fairness) in processi complessi di generazione sintetica tabulare rappresenta, per quanto ci risulta, un ambito ancora poco sviluppato, come emerge anche dalla recente rassegna sistematica di Gil-Fuster et al. [50]. In questo lavoro, pertanto, estendiamo l'applicazione di tali strumenti analitici (con particolare riferimento a SVQX) al caso di VQC generativi tabulari, con l'obiettivo di dissezionare le logiche di encoding e la struttura degli ansatz in relazione alla mitigazione del bias.

2.6.2 Mappa dello stato dell'arte




Figura 2.2: Confronto tra il paradigma *semantico-linguistico* degli LLM e il paradigma *matematico-circuitale* dei VQC per la generazione di dati sintetici fair. Nel flusso LLM (in alto), la fairness dei dati generati emerge come proprietà indotta dal pre-training del modello e non è controllata tramite vincoli quantitativi espliciti sulla distribuzione degli attributi sensibili [1, 4]. Nel flusso VQC (in basso) la fairness diventa un vincolo strutturale del processo di ottimizzazione. Nello specifico, il paradigma VQC prevede che il vettore dei parametri addestrabili θ dell'operatore unitario parametrizzato (ovvero l'ansatz generativo $U(\theta)$) venga ottimizzato affinché il campionamento probabilistico finale dallo spazio di Hilbert globale a n qubit (indicato con $\mathcal{H}^{\otimes n}$) rispetti esplicitamente i criteri di equità definiti sugli attributi sensibili (SPD, EOD, AOD).

Tabella 2.2: Confronto tra i principali paradigmi per la generazione di dati fair [1, 6, 7, 8].

Dimensione	Gen. Classica (GAN/VAE)	Fairness-Aware Classica	LLM	VQC
Paradigma	Statistico- neurale	Statistico con vincoli	Semantico- linguistico	Matematico- circuitale
Utility (TSTR)	Alta	Media/Alta	Competitiva	Competitiva
Fairness by-design	Assente (nessun vincolo esplicito nella loss)	Parziale (vincolo nella loss del ge- neratore)	Emergente (non controllabile a priori)	Strutturale (vin- colo esplicito di ottimizzazione)
Fairness down-stream	Non valutata	Valutata (dipen- de da dataset rea- le)	Sistematicamente valutata [1]	Obiettivo esplici- to (RQ2)
Interpretabilità	Limitata	Limitata	Assente	Intrinseca + XQML [25]
Verifica formale	Assente	Assente	Assente	Possibile [48]
Rischio allucinazioni	Basso	Basso	Alto [1]	Strutturalmente limitato (spazio di encoding vincolato)
Dipendenza da dati reali	Alta (training di- retto)	Alta (training di- retto)	Indiretta (pre- training testuale)	Alta (training su dati reali)

2.6.3 Identificazione del gap e contributo della tesi

Il lavoro di Voria et al. [1] ha dimostrato che la generazione semantica può produrre dati sintetici tabulari con proprietà di fairness competitive. Tuttavia, l’opacità strutturale intrinseca degli LLM, i rischi di bias linguistico ereditati dal pre-training e le allucinazioni documentate (con la generazione di istanze fuori dominio) alimentano l’esplorazione di approcci alternativi formalmente verificabili.

La presente tesi si propone come la **prosecuzione quantistica** di quel lavoro: sostituisce l’inferenza testuale di natura *black-box* con l’ottimizzazione di circuiti

parametrizzati nello spazio di Hilbert. In tal modo, proponiamo di trasformare la fairness da effetto emergente e non controllabile a vincolo matematico formalizzabile e ottimizzabile. Nello specifico, estendiamo al dominio generativo i fondamenti teorici sviluppati in letteratura per i modelli discriminativi [46, 48], integrandoli con i recenti meccanismi di mitigazione del bias introdotti per le architetture QGAN [7].

2.6.4 Ingegneria del Software per il QML e Crisi di Riproducibilità

La ricerca empirica in ambito Machine Learning e Quantum Machine Learning affronta una documentata crisi di riproducibilità [55, 56], imputabile a fattori architeturali critici quali la stocasticità non controllata degli ottimizzatori, la dipendenza da seed globali non replicati e la gestione non trasparente delle anomalie di calcolo. Nei circuiti variazionali NISQ, tali criticità sono ulteriormente esacerbate dalla natura ibrida classica-quantistica del ciclo di ottimizzazione, in cui interruzioni o fallimenti silenziosi durante l'esecuzione di grid-search prolungate possono compromettere l'integrità dei log sperimentali. In questo scenario, la letteratura recente evidenzia come l'adozione di rigorosi pattern formali derivati dall'Ingegneria del Software per contesti scientifici (*Software Engineering for Science*) [9] sia un prerequisito indispensabile per garantire il determinismo, l'idempotenza e l'affidabilità statistica dei benchmarking downstream.

2.6.5 Verso il Capitolo 3

Sulla base del framework teorico costruito in questo capitolo, il Capitolo 3 descrive nel dettaglio il metodo di ricerca adottato per rispondere alle Research Questions. Verranno specificate l'architettura del VQC generativo, le modalità di integrazione dei vincoli di fairness nella funzione di loss, il protocollo sperimentale e il framework di analisi interpretativa basato sui Quantum Shapley Values, tenendo esplicitamente conto dei risultati e dei limiti documentati da Voria et al. [1].

CAPITOLO 3

Metodo di Ricerca

3.1 Disegno della Ricerca e Research Questions

L'obiettivo del presente studio empirico è valutare in che misura la generazione di dataset tabulari sensibili attraverso circuiti quantistici variazionali (VQC) possa contribuire a soddisfare i requisiti di fairness algoritmica, mantenendo al contempo inalterata l'utilità dei dati per l'addestramento di modelli di Machine Learning (ML). La prospettiva di analisi è duplice: da un lato, si intende verificare empiricamente se i VQC possano fornire fonti di dati non distorte e performanti in scenari applicativi reali; dall'altro, si mira a valutare il livello di trasparenza e interpretabilità del processo generativo, superando l'opacità dei tradizionali modelli black-box.

A tale scopo, assumendo come riferimento metodologico il protocollo di valutazione definito da Voria et al. [1], lo studio empirico è stato strutturato attorno a tre principali domande di ricerca (*"Research Questions"*).

In primo luogo, abbiamo mirato a valutare l'utilità e il valore pratico dei dataset sintetici generati dall'architettura quantistica. Questo ha comportato un'analisi empirica per determinare se i dati quantistici possano fungere da validi sostituti dei dati reali. L'elemento chiave di questa valutazione è stato il confronto delle performance

predittive downstream, al fine di stabilire quanto i dati sintetici riescano a eguagliare l'accuratezza e l'affidabilità dei dati del mondo reale. Pertanto, ci siamo chiesti:

Q RQ₁. *In che misura la performance predittiva di modelli ML addestrati su dataset sintetici generati tramite VQC è comparabile a quella di modelli addestrati su dataset reali?*

In secondo luogo, l'indagine si è concentrata sulla dimensione etica e sull'effettiva mitigazione del bias. Abbiamo misurato l'impatto dei dati sintetici generati dal VQC sulle disparità demografiche rispetto ai dataset originali, confrontando i modelli addestrati attraverso metriche standardizzate di equità di gruppo. Di conseguenza, abbiamo formulato il seguente interrogativo:

Q RQ₂. *In che misura i modelli ML addestrati su dataset sintetici generati tramite VQC migliorano le metriche di fairness (SPD, EOD, AOD) rispetto a modelli addestrati su dataset reali?*

Infine, per valorizzare ciò che rende peculiare l'approccio quantistico, abbiamo superato la semplice valutazione indiretta delle performance per indagare il grado di trasparenza strutturale del processo generativo offerto dal paradigma quantistico. Anziché limitarci a verificare *se* i dati generati siano migliori o più equi, la nostra terza domanda di ricerca mira a comprendere *perché* lo siano. Avvalendoci del framework basato sui Quantum Shapley Values [25], intendiamo analizzare in che modo le proprietà architetturali e i trade-off del circuito influenzino il risultato finale:

Q RQ₃. *Quali proprietà strutturali del circuito VQC (profondità, livello di entanglement, strategia di encoding) favoriscono la generazione di dati sintetici fair, e come si caratterizza il trade-off tra l'espressività del circuito, la mitigazione del bias e l'interpretabilità algoritmica estraibile tramite Quantum Shapley Values?*

Per rispondere in modo rigoroso a questi interrogativi, il presente studio prevede la definizione di un insieme di configurazioni del VQC che differiscono sistematicamente per profondità dei layer, schemi di entanglement e ansatz. I paragrafi successivi di questo capitolo descriveranno nel dettaglio le fasi operative dell'esperimento: la selezione e il pre-processing dei dataset (*German Credit*, *Heart Disease*, *Student Performance*), la definizione delle architetture VQC da confrontare, la formulazione della funzione di costo vincolata alla fairness, e infine la pipeline per la valutazione congiunta di utility, fairness downstream e metriche di interpretabilità e complessità.

3.2 Panoramica del Processo Sperimentale

Per rispondere in modo controllato e riproducibile alle tre Research Questions, l'intero processo generativo, di ottimizzazione variazionale e di audit empirico è formalizzato come una pipeline computazionale sequenziale, denotata con $\mathcal{P}$, composta da cinque stadi operativi $\mathcal{S}_1, \dots, \mathcal{S}_5$ e rappresentata dalla seguente equazione di composizione:

$$\mathcal{P} = \mathcal{S}_5 \circ \mathcal{S}_4 \circ \mathcal{S}_3 \circ \mathcal{S}_2 \circ \mathcal{S}_1 \quad (3.2.1)$$

In particolare, la pipeline riceve in input il dataset reale grezzo $\mathcal{D}_{\text{real}}$:

$$\mathcal{P}(\mathcal{D}_{\text{real}}) = (\mathcal{S}_5 \circ \mathcal{S}_4 \circ \mathcal{S}_3 \circ \mathcal{S}_2 \circ \mathcal{S}_1)(\mathcal{D}_{\text{real}}) \quad (3.2.2)$$

Le cinque fasi operative si articolano come segue:

1. **Data Ingestion, Filtering e Pre-processing Sensibile** ($\mathcal{S}_1$): acquisizione deterministica dei dataset reali, selezione delle feature informative ($k \leq 8$), binarizzazione degli attributi protetti e scaling angolare continuo $[0, \pi]$;
2. **Quantum State Preparation ed Encoding** ($\mathcal{S}_2$): mappatura del vettore classico di feature nello spazio di Hilbert $\mathcal{H}^{\otimes n}$ tramite rotazioni parametriche;
3. **Addestramento Variazionale Vincolato** ($\mathcal{S}_3$): ottimizzazione dei parametri dell'ansatz tramite Parameter-Shift Rule rispetto a una funzione di costo multi-obiettivo vincolata alla fairness;
4. **Misura e Ricostruzione del Dataset Sintetico** ($\mathcal{S}_4$): estrazione dei valori di aspettazione dell'osservabile $\hat{Z}$ e inversione di scala nel dominio classico originale;
5. **Audit Empirico, Inferenziale e Strutturale** ($\mathcal{S}_5$): valutazione dell'utilità downstream (TSTR su tre classificatori per RQ1), quantificazione della fairness multi-attributo (RQ2) e dissezione causale tramite Quantum Shapley Values ed entanglement (RQ3).




Figura 3.1: Architettura della Pipeline sperimentale $\mathcal{P}$ per la generazione di dati sintetici fair tramite VQC, valutazione downstream e audit strutturale XQML. L'implementazione della pipeline è consultabile nella nostra repository pubblica: https://github.com/KLS-01/VQC_Generator-Fair-Interpretable-Data [5]

3.3 Dataset Benchmark e Pre-processing Sensibile ($\mathcal{S}_1$)

In coerenza con l'architettura formale della pipeline $\mathcal{P}$ introdotta nella Sezione 3.2, l'avvio operativo del processo di generazione sintetica ha inizio con la **Fase I: Ingestion & Pre-Processing ($\mathcal{S}_1$)**. L'operatore $\mathcal{S}_1$ agisce direttamente sullo spazio dei dati reali $\mathcal{D}_{\text{real}}$ allo scopo di effettuare l'ingestione deterministica, l'estrazione delle feature più informative, la binarizzazione degli attributi protetti e il condizionamento geometrico dello spazio di input per le rotazioni quantistiche.

In linea con il protocollo sperimentale del benchmark di riferimento di Voria et al. [1], la sperimentazione adotta tre dataset sensibili ampiamente consolidati nella letteratura sull'equità algoritmica [57, 11]:

1. **German Credit** (UCI ID: 144) [35]: 1000 istanze di richiedenti credito bancario, classificate rispetto al merito creditizio favorevole o sfavorevole ($Y \in \{0, 1\}$);
2. **Heart Disease** (Cleveland Database, UCI ID: 45) [36]: 303 record clinici per la diagnosi di patologie coronariche binarizzate ($Y \in \{0, 1\}$);
3. **Student Performance** (UCI ID: 320) [37]: 649 studenti valutati sul rendimento in lingua portoghese, con target decisionale binarizzato sul voto finale ($G3 \geq 10 \implies Y = 1$, ovvero superamento del corso, altrimenti $Y = 0$, in accordo con la scala di valutazione scolastica portoghese e in linea con la classificazione binaria a 2 classi di Cortez e Silva [58]).

3.3.1 Feature Selection e Allocazione del Registro Quantistico

Nei simulatori quantistici esatti su vettori di stato, la dimensione dello spazio di Hilbert cresce esponenzialmente come $\dim(\mathcal{H}) = 2^n$, imponendo un limite pratico di trattabilità per l'addestramento variazionale nel regime NISQ [41]. A tale scopo, l'operatore $\mathcal{S}_1$ applica una procedura di *Feature Selection* basata sul criterio dell'Informazione Mutua (*Mutual Information*) [39], selezionando le $d \leq 8$ feature predittive continue e discrete X a più alto potere informativo rispetto al target Y .

Il registro quantistico alloca $n = d + 2$ qubit come segue:

$$N_{\text{qubits}} = d_{\text{features}} + 1_{\text{target}} + 1_{\text{sensitive}} \quad (3.3.1)$$

- d qubit ($q_0, \dots, q_{d-1}$) dedicati alla codifica delle feature predittive X ;
- 1 qubit target (q_d) dedicato alla predizione della variabile di classe Y ;
- 1 qubit sensibile (q_{d+1}) dedicato alla codifica dell'attributo protetto intersezionale A_{overall} (approfondito nella Sezione 3.3.2).

L'allocazione delle risorse di qubit, le dimensioni dello spazio di Hilbert, gli attributi sensibili e i singoli gate groups per ciascun dataset sono sintetizzati all'interno della Tabella 3.1 nella sezione seguente.

3.3.2 Codifica Sensibile Intersezionale

Prima di definire la congiunzione intersezionale delle variabili sensibili, è essenziale formalizzare le scelte di binarizzazione applicate ai singoli attributi protetti originali, ovvero l'età (A_{age}) e il genere (A_{sex}). Tali scelte rispondono a criteri consolidati nella letteratura etica classica e quantistica [31, 57, 59]:

- **German Credit:** l'attributo sensibile A_{age} si ottiene binarizzando la variabile continua age alla soglia protettiva a $\text{Age} \geq 25$, in perfetta conformità con le specifiche del *GermanDataset* della libreria standard AI Fairness 360 (AIF360) [31]; l'attributo sensibile A_{sex} si ottiene mappando la feature qualitativa originaria dello stato personale, definendo come privilegiata la classe $\text{personal_status} \in \{A91, A93, A94\}$ (ovvero uomini celibi, divorziati/separati o coniugati/vedovi).
- **Heart Disease:** l'attributo sensibile A_{age} si ottiene binarizzando la variabile continua age alla soglia $\text{Age} \geq 55$ per isolare la coorte anagrafica clinicamente più esposta a rischio cardiovascolare [59]; il genere A_{sex} è binarizzato sulla codifica d'origine ($\text{sex} == 1$ per la popolazione maschile).
- **Student Performance:** l'attributo sensibile A_{age} si ottiene binarizzando la variabile continua age alla soglia legale della maggiore età $\text{Age} \geq 18$, in conformità con la letteratura consolidata sui sistemi predittivi educativi [57]; il genere A_{sex} è binarizzato sulla codifica d'origine ($\text{sex} == 'M'$ per la popolazione maschile).

La Tabella 3.1 riassume anche la codifica adottata per le variabili sensibili.

Tabella 3.1: Allocazione delle risorse di qubit, spazio di Hilbert e attributi sensibili per dataset.

Dataset	Feature (d)	Qubit Totali (n)	Dim. Hilbert	Soglia Età (A_{age})	Codifica Genere (A_{sex})	Gate Groups (RQ3)
German Credit	7	9	$2^9 = 512$	Age ≥ 25	'personal_status' $\in \{A91, A93, A94\}$	10 (9 rot. + 1 CNOT)
Heart Disease	8	10	$2^{10} = 1024$	Age ≥ 55	'sex' == 1	11 (10 rot. + 1 CNOT)
Student Performance	8	10	$2^{10} = 1024$	Age ≥ 18	'sex' == 'M'	11 (10 rot. + 1 CNOT)

Per evitare il fenomeno del *fairness gerrymandering* [60], in cui un modello appare equo rispetto ai singoli attributi isolati ma discrimina sistematicamente i loro sottogruppi congiunti, l'attributo di protezione primario ottimizzato ed esportato dal generatore è l'attributo intersezionale:

$$A_{\text{overall}} = A_{\text{sex}} \wedge A_{\text{age}} \quad (3.3.2)$$

Tale approccio contribuisce a colmare un importante gap nella letteratura emergente sul QML, dove la valutazione multi-attributo disaggregata risulta ancora scarsamente esplorata, principalmente a causa dei severi limiti fisici in termini di qubit e profondità circuitale imposti dall'hardware NISQ. In questa prima fase di pre-processing ($\mathcal{S}_1$), l'inclusione esplicita e la binarizzazione di A_{overall} all'interno del dataset di addestramento si rivelano scelte fondamentali: contrariamente alle pratiche classiche che si limitano a escludere le variabili protette dal set di addestramento (addestramento tramite *unawareness*), il nostro framework mantiene deliberatamente l'informazione demografica affinché possa essere successivamente sfruttata come vincolo geometrico attivo dall'ansatz quantistico.

3.3.3 Scaling Angolare e Split Stratificato

Per condizionare geometricamente lo spazio dei dati di input per le successive rotazioni quantistiche, l'operatore $\mathcal{S}_1$ mappa linearmente ciascuna feature classica continua X_j nell'intervallo angolare chiuso $[0, \pi]$ [40, 42]. Tale intervallo è rigorosamente limitato dalle proprietà dell'algebra lineare dello spazio di Hilbert e dall'impiego dei gate di rotazione monoqubit R_y previsti dalla successiva fase di preparazione dello stato ($\mathcal{S}_2$).

Operativamente, la normalizzazione e l'estensione trigonometrica seguono la seguente equazione:

$$S(x_j) = \pi \cdot \frac{x_j - x_{j,\min}}{x_{j,\max} - x_{j,\min} + \epsilon}, \quad \forall j \in \{1, \dots, d\} \quad (3.3.3)$$

dove i singoli termini, operatori e costanti matematiche indicano:

- $S(x_j)$ rappresenta l'output del processo di scaling per la j -esima caratteristica, espresso sotto forma di angolo radiante nell'intervallo $[0, \pi]$;
- x_j indica il valore scalare originario e continuo della j -esima feature del campione sotto analisi;
- $x_{j,\min}$ definisce il limite inferiore (valore minimo) assunto dalla j -esima feature continua all'interno dell'intero dataset reale di riferimento;
- $x_{j,\max}$ definisce il limite superiore (valore massimo) assunto dalla j -esima feature continua all'interno dell'intero dataset reale di riferimento;
- π rappresenta la costante irrazionale del semicerchio, necessaria per riscalarare l'intervallo normalizzato [11] nell'intervallo angolare di rotazione quantistica;
- ϵ costituisce un fattore di regolarizzazione numerica infinitesimo, valorizzato a 10^{-12} nel nostro framework, avente lo scopo di prevenire l'instabilità computazionale derivante da divisioni per zero nel caso limite in cui una feature presenti varianza nulla sull'intero corpus ($x_{j,\max} = x_{j,\min}$).

Corrispondenza Software. La normalizzazione dell'equazione 3.3.3 è implementata dalla funzione vettorizzata `scale_to_angle(X)` del modulo `data_pipeline.py`, la quale esegue l'algebra matriciale tramite NumPy ed esporta le tuple dei parametri minimi e massimi per consentire la successiva inversione classica.

Per garantire che la ripartizione dei dati rispetti l'omogeneità delle distribuzioni demografiche, il dataset normalizzato viene suddiviso tramite campionamento stratificato sull'attributo sensibile intersezionale A_{overall} in:

- un training set (70%, corrispondente a $N = 700$ istanze per German Credit, $N = 212$ per Heart Disease, $N = 454$ per Student Performance) impiegato per addestrare il generatore VQC;

- un test set reale (30%) preservato per tutte le valutazioni downstream TSTR.

Tale partizione è delegata alla funzione `train_test_split` con parametro `test_size=0.30` e seeding Monte Carlo ispezionabile, integrata nel modulo dell'orchestratore `pipeline_orchestrator.py`.

3.4 Architettura del Generatore Quantistico Variazionale ($\mathcal{S}_2$ - $\mathcal{S}_3$ - $\mathcal{S}_4$)

Il modulo generativo quantistico, operativamente implementato dalla classe `VQCGenerator`, unisce in un unico blocco logico le tre fasi centrali della simulazione quantistica: la preparazione dello stato ed encoding ($\mathcal{S}_2$), l'ottimizzazione variazionale vincolata ($\mathcal{S}_3$) e la misura con ricostruzione classica dei dati sintetici ($\mathcal{S}_4$), in perfetto parallelismo con il paradigma strutturale a tre fasi dei circuiti quantistici variazionali già esaminato in dettaglio nella Sezione 2.3.2.

3.4.1 Preparazione dello Stato ed Encoding ($\mathcal{S}_2$)

Il vettore classico esteso $x_{\text{full}} \in [0, \pi]^n$ (composto dalle d feature scalate, dal target scalato $\pi \cdot y$ e dall'attributo protetto $\pi \cdot a$) viene iniettato nel registro a n qubit del simulatore quantistico tramite la tecnica dell'*Angle Encoding*. Questa fase **realizza la mappatura matematica** $\mathcal{E} : \mathbb{R}^n \rightarrow \mathcal{H}^{\otimes n}$ (che **traduce le variabili classiche continue in ampiezze di probabilità quantistiche**, ponendo i qubit del registro in uno stato di sovrapposizione coerente), operazionalizzando i concetti già discussi nella Sezione 2.3.2.

La preparazione dello stato quantistico è descritta dalla seguente equazione:

$$|\phi(x)\rangle = \mathcal{E}(x) = \bigotimes_{j=1}^n R_y(x_{\text{full},j}) |0\rangle^{\otimes n} = \bigotimes_{j=1}^n \left(\cos\left(\frac{x_{\text{full},j}}{2}\right) |0\rangle + \sin\left(\frac{x_{\text{full},j}}{2}\right) |1\rangle \right) \quad (3.4.1)$$

Corrispondenza Software. All'interno della classe `VQCGenerator` definita nel modulo `quantum_vqc.py`, il metodo di codifica degli input riceve in ingresso la matrice dei dati classici precedentemente normalizzati nell'intervallo $[0, \pi]$ dal modulo `data_pipeline.py`. Successivamente, la pipeline quantistica applica l'operatore

di rotazione unitaria R_Y su ciascun qubit del registro. Siccome la simulazione esatta dello statevector (eseguita tramite algebra matriciale in NumPy) non fa altro che moltiplicare la matrice di rotazione quantistica per il vettore dello stato fondamentale, il sistema a runtime produce ampiezze di probabilità che coincidono alla perfezione, e in modo deterministico, con i valori teorici definiti dall'equazione 3.4.1.

3.4.2 Griglia delle Configurazioni VQC

Per approssimare la distribuzione dei dati reali nel registro quantistico simulato, si è adottato un circuito variazionale parametrizzato. In perfetta continuità con le tassonomie strutturali introdotte e discusse nella Sezione 2.3.2, l'ansatz variazionale $U(\theta)$ segue la topologia di un *layered hardware-efficient ansatz*, soluzione consolidata nel regime NISQ per ottimizzare l'espressività riducendo al contempo il rumore sistematico e la profondità fisica del circuito [41].

Nello specifico, l'operatore $U(\theta)$ è strutturato come una sequenza di L layer variazionali alternati, in cui ciascun blocco prevede:

1. una barriera di rotazioni monoqubit parametriche $R_y(\theta)R_z(\phi)$ applicate in parallelo su ciascun qubit del registro per esplorare lo spazio degli stati lungo gli assi polare e azimutale della sfera di Bloch;
2. un blocco di entanglement U_{ent} a porte CNOT a due qubit per generare correlazioni quantistiche non classiche (entanglement multilivello) tra le feature e i qubit di protezione, distribuito secondo topologie controllate dal modulo `quantum_vqc.py`.

Al fine di indagare sistematicamente l'impatto della complessità hardware e dell'espressività dell'ansatz sulla qualità e sulla fairness dei dati generati, si è strutturata una griglia sperimentale di confronto comparativo. Di seguito, la Tabella 3.2 descrive le configurazioni variazionali adottate, evidenziando le variazioni sistematiche di profondità (L), topologia di connessione e strategia di encoding.

Tabella 3.2: Griglia sperimentale delle 6 configurazioni VQC per $N_q = 10$ qubit (Heart Disease e Student Performance).

Configurazione	Layer (L)	Topologia Entanglement	Strategia Encoding	Parametri (θ)	Porte CNOT
L1_linear	1	Lineare (nearest-neighbor)	Single Encoding	20	9
L1_all_to_all	1	Completa (all-to-all)	Single Encoding	20	45
L2_linear	2	Lineare (nearest-neighbor)	Single Encoding	40	18
L2_all_to_all	2	Completa (all-to-all)	Single Encoding	40	90
L2_re_upload	2	Lineare (nearest-neighbor)	Data Re-uploading	40	18
L2_all_to_all_re_upload	2	Completa (all-to-all)	Data Re-uploading	40	90

Giustificazione del Disegno a 6 Configurazioni Dal punto di vista teorico, l'incrocio ortogonale dei tre iperparametri strutturali a due livelli, ossia Profondità ($L \in \{1, 2\}$), Topologia di Entanglement ($\{\text{Linear, All-to-All}\}$) e Strategia di Encoding ($\{\text{Single, Re-upload}\}$), darebbe origine a un fattoriale completo composto da $2 \times 2 \times 2 = 8$ combinazioni distinte.

Tuttavia, l'implementazione software della nostra pipeline impone un vincolo algebrico che riduce la griglia a 6 configurazioni effettive: la strategia di *Data Re-uploading* (formalizzata nella Sezione 2.3.2) prevede infatti la re-iniezione del dato classico riscaldato a ogni layer successivo al primo ($l > 0$), descritta all'interno del modulo `quantum_vqc.py` dalla seguente condizione logica:

$$\text{if encoding_strategy} == \text{"re_upload"} \text{ and } l > 0 : \quad \bigotimes_{j=1}^n R_y(x_j) \quad (3.4.2)$$

Nel caso limite di circuiti a singolo strato ($L = 1$), l'indice di livello può assumere unicamente il valore iniziale $l = 0$. Di conseguenza, la condizione di attivazione del re-uploading ($l > 0$) non si verifica mai a runtime. Sotto il profilo algebrico e operativo, le configurazioni teoriche `L1_linear_re_upload` e `L1_all_to_all_re_upload` collassano e risultano matematicamente identiche alle varianti `L1_linear` e `L1_all_to_all` a singolo encoding. Al fine di escludere trattamenti degeneri e ridondanti dal benchmark, tali combinazioni sono state formalmente rimosse dall'orchestratore `pipeline_orchestrator.py`, portando alla definizione finale di una griglia ortogonale e non degenera di 6 configurazioni sperimentali distinte (Tabella 3.2).

3.4.3 Funzione di Costo Vincolata e Parameter-Shift Rule ($\mathcal{S}_3$)

Una volta preparato lo stato quantistico coerente nella fase precedente, l'obiettivo della fase $\mathcal{S}_3$ della nostra pipeline consiste nel **trovare il vettore ottimale dei parametri di rotazione $\theta^* \in \mathbb{R}^P$** . A differenza dei tradizionali approcci di mitigazione del bias post-hoc, l'addestramento del nostro circuito variazionale adotta una filosofia di *fairness-by-design*, integrando l'**equità come vincolo matematico e analitico direttamente all'interno del processo di ottimizzazione**.

L'apprendimento è governato dalla minimizzazione di una funzione di costo multi-obiettivo espressa dalla seguente equazione di loss composita:

$$\mathcal{L}_{\text{tot}}(\theta) = \mathcal{L}_{\text{fidelity}}(\theta) + \lambda_f \cdot \mathcal{L}_{\text{fairness}}(\theta) \quad (3.4.3)$$

Con questa formulazione, il paradigma di regolarizzazione tramite penalità soft, tipico dei modelli generativi classici per la sintesi di dati equi (come le GAN fairness-aware discusse nella Sezione 2.2.2), viene adattato al contesto quantistico. In particolare:

- La componente $\mathcal{L}_{\text{fidelity}}(\theta)$ misura l'errore quadratico medio (Mean Squared Error) di ricostruzione dei dati confrontando i valori di aspettazione misurati sui qubit con i corrispettivi target classici scalati:

$$\mathcal{L}_{\text{fidelity}}(\theta) = \frac{1}{d} \sum_{j=1}^d (\langle \hat{Z}_j \rangle(\theta) - \cos(S(x_j)))^2 \quad (3.4.4)$$

La formulazione della *loss di fidelity* (Equazione 3.4.4) concretizza la teoria generale della misurazione esposta nella Sezione 2.3.2. Come osservabile per la misurazione abbiamo selezionato l'operatore di Pauli $\hat{Z}_j$ poiché il suo valore di aspettazione $\langle \hat{Z}_j \rangle$ appartiene nativamente all'intervallo continuo $[-1, 1]$, rendendolo geometricamente coerente con lo spazio delle feature classiche scalate e proiettabili sulla sfera di Bloch. Il termine $\cos(S(x_j))$ rappresenta il target teorico atteso rispetto a cui calcolare lo scostamento quadratico ed è calcolato proiettando la feature scalata classica sul rispettivo asse di misura.

- La componente $\mathcal{L}_{\text{fairness}}(\theta)$ penalizza quadraticamente la deviazione dalla parità statistica proxy calcolata sul qubit target (q_d):

$$\mathcal{L}_{\text{fairness}}(\theta) = (\mathbb{E}_{\mathcal{D}}[P(\hat{Y} = 1 \mid A = 1)] - \mathbb{E}_{\mathcal{D}}[P(\hat{Y} = 1 \mid A = 0)])^2 \quad (3.4.5)$$

La formulazione della *loss di fairness* (Equazione 3.4.5) costituisce l'adattamento quantistico della metrica classica di *Statistical Parity Difference* (SPD) introdotta e formalizzata nella Sezione 2.1.2, calcolata tramite l'operatore di aspettazione empirica $\mathbb{E}_{\mathcal{D}}[\cdot]$ sul dataset di addestramento $\mathcal{D}$. Per calcolare la probabilità di assegnazione del target favorevole $P(\hat{Y} = 1)$ dal valore di aspettazione del qubit target misurato lungo la base computazionale ($\langle \hat{Z}_{\text{target}} \rangle \in [-1, 1]$), si applica la formula di riscaldamento introdotta nella Sezione 2.3.2:

$$\begin{aligned} \langle \hat{Z}_{\text{target}} \rangle &= P(|0\rangle) - (1 - P(|0\rangle)) = 2P(\hat{Y} = 1) - 1 \\ \implies P(\hat{Y} = 1) &= \frac{\langle \hat{Z}_{\text{target}} \rangle + 1}{2} \end{aligned} \quad (3.4.6)$$

L'integrazione esplicita di penalità di parità statistica nella funzione di costo ($\mathcal{L}_{\text{fairness}}$) supera l'approccio ingenuo della *Fairness Through Unawareness* (la semplice rimozione degli attributi protetti); in tal modo, l'ansatz variazionale non ignora le variabili sensibili durante l'addestramento, ma ottimizza attivamente i parametri θ per neutralizzare e compensare i bias di proxy latenti veicolati dallo spazio delle feature non protette X .

Calcolo Analitico dei Gradienti La discesa del gradiente stocastico sui parametri del circuito variazionale richiede il calcolo dei gradienti parziali $\nabla_{\theta} \mathcal{L}_{\text{tot}}$. Poiché la natura distruttiva della misura quantistica impedisce fisicamente l'applicazione dell'algoritmo di retropropagazione dell'errore (backpropagation), come approfondito nell'analisi delle limitazioni dei dispositivi NISQ nella Sezione 2.5.1, la nostra pipeline calcola i gradienti esatti sfruttando il teorema della *Parameter-Shift Rule* esposto nella Sezione 2.3.2:

$$\frac{\partial \mathcal{L}_{\text{tot}}}{\partial \theta_k} = \frac{1}{2} \left[\mathcal{L}_{\text{tot}} \left(\theta + \frac{\pi}{2} \hat{e}_k \right) - \mathcal{L}_{\text{tot}} \left(\theta - \frac{\pi}{2} \hat{e}_k \right) \right] \quad (3.4.7)$$

La derivata analitica rispetto al k -esimo parametro θ_k viene così calcolata valutando la funzione di perdita complessiva del circuito in due punti simmetricamente traslati di

un offset pari a $\pm\pi/2$, garantendo la convergenza matematica senza approssimazioni alle differenze finite.

Corrispondenza Software ed Iperparametri Il calcolo della loss multi-obiettivo (Equazione 3.4.3) e dei gradienti tramite Parameter-Shift (Equazione 3.4.7) sono implementati all'interno della classe `VQCGenerator` nel sorgente `quantum_vqc.py`, sfruttando l'efficienza del motore di calcolo vettorizzato NumPy. Il moltiplicatore di penalità di fairness, impostato analiticamente a $\lambda_f = 5.0$, corrisponde esattamente alla variabile globale `LAMBDA_FAIR = 5.0` gestita dal modulo dell'orchestratore `pipeline_orchestrator.py`. L'aggiornamento dei parametri avviene tramite ottimizzazione stocastica su mini-batch, governata in modo deterministico dalle specifiche di griglia definite in `pipeline_orchestrator.py`: frazione di batch pari al 25% (`batch_frac = 0.25`), addestramento limitato a $E = 15$ epoche (`EPOCHS = 15`), tasso di apprendimento pari a $\eta = 0.4$ (`learning_rate = 0.4`) e seeding Monte Carlo ispezionabile per garantire l'assoluta riproducibilità di ciascuna run.

3.4.4 Ottimizzazione con Algebra Vettorizzata in NumPy

Il calcolo sequenziale dei gradienti analitici tramite l'interfaccia ad alto livello di Qiskit introduce un sensibile overhead computazionale, dovuto principalmente alla compilazione e all'esecuzione iterativa dei singoli circuiti per ciascun campione del batch. Per risolvere questo collo di bottiglia senza alterare le proprietà matematiche e la precisione del modello, il calcolo dei valori di aspettazione è progettato sfruttando l'algebra matriciale vettorizzata in NumPy. Invece di simulare i singoli circuiti in modo sequenziale, il sistema calcola la distribuzione di probabilità globale sul vettore di stato (*statevector*) di dimensione 2^n per l'intero batch di dati. I valori di aspettazione dell'osservabile $\hat{Z}$ su tutti i qubit del registro vengono successivamente estratti in parallelo attraverso un'unica operazione di moltiplicazione matriciale densa:

$$\langle \hat{Z} \rangle_{\text{batch}} = 1.0 - 2.0 \cdot \left(|\psi_{\text{batch}}|^2 \times M_Z \right) \quad (3.4.8)$$

dove $|\psi_{\text{batch}}|^2$ rappresenta la matrice contenente le distribuzioni di probabilità degli stati quantistici per l'intero batch, mentre M_Z costituisce una matrice binaria di

transizione pre-calcolata di dimensioni $2^n \times n$ che mappa gli indici degli stati della base computazionale sui singoli qubit.

Corrispondenza Software ed Iperparametri Questo approccio si traduce nel sorgente del progetto nel metodo `batch_forward` del modulo `quantum_vqc.py`. Uno specifico test di validazione numerica (`benchmark_numpy_refactor`) è stato eseguito e ha certificato che questa ottimizzazione vettorizzata produce parametri ottimali θ^* , gradienti e valori di loss perfettamente identici rispetto alle primitive native di Qiskit, con scostamenti numerici ampiamente inferiori alla precisione macchina ($|\Delta| < 10^{-15}$), garantendo al contempo un’accelerazione computazionale superiore.

3.4.5 Ablation Study e Diagnostica di Convergenza della Loss

Gli iperparametri di addestramento sono stati calibrati conducendo uno studio preliminare di *ablation* (`batch_ablation`) e diagnostica di convergenza al variare della frazione di campionamento `batch_frac` $\in \{0.10, 0.20, 0.25, 0.30, 0.50, 0.75, 1.0\}$ e del numero di epoche $E \in \{15, 20, 25\}$. Come illustrato in Figura 3.2, le curve di apprendimento relative alla perdita totale ($\mathcal{L}_{\text{tot}}$), alla componente di fedeltà ($\mathcal{L}_{\text{fidelity}}$) e al vincolo di fairness ($\mathcal{L}_{\text{fairness}}$) registrate sui tre dataset benchmark evidenziano un comportamento coerente. In tutti e tre i domini, la discesa della loss di fedeltà statistica si concentra principalmente nelle prime dieci epoche di addestramento, rallentando progressivamente fino a raggiungere un plateau asintotico via via più stabile attorno a $E = 15$ epoche. Contestualmente, la penalità di fairness $\mathcal{L}_{\text{fairness}}$ si stabilizza su valori prossimi allo zero fin dai primi cicli, dimostrando la rapidità con cui l’ansatz quantistico adegua i propri parametri per soddisfare il vincolo di parità statistica sul qubit target. Estendere l’addestramento a 20+ epoche produce variazioni della loss del tutto trascurabili ($\Delta\mathcal{L} < 0.008$), introducendo un sensibile overhead computazionale e aumentando esponenzialmente il rischio di intrappolamento in barren plateaus locali o di overfitting. Di conseguenza, l’accoppiamento di iperparametri composto da `batch_frac` = 0.25, $\eta = 0.4$ ed $E = 15$ epoche è stato scelto come bilanciamento ottimale tra stabilità analitica del gradiente ed efficienza temporale della pipeline.




Figura 3.2: Diagnostica di convergenza delle curve di loss per i dataset German Credit (sinistra), Heart Disease (centro) e Student Performance (destra) su 15 epoche con $\text{batch_frac} = 0.25$ e $\lambda_f = 5.0$. La linea blu indica la perdita totale ($\mathcal{L}_{tot}$), la linea verde tratteggiata rappresenta la componente di fedeltà statistica delle feature ($\mathcal{L}_{fid}$), e la linea rossa punteggiata evidenzia la penalità di fairness ($\mathcal{L}_{fair}$) sul qubit target. Si osserva il raggiungimento di un plateau asintotico stabile per tutti e tre i domini entro la 15-esima epoca.

3.4.6 Valore λ_f nella funzione di costo

A differenza degli iperparametri batch_frac ed EPOCHS , per cui la Sezione 3.4.5 documenta uno studio di ablation empirico su una griglia di valori, il moltiplicatore λ_f non è stato oggetto di una ricerca a griglia sistematica. La sua calibrazione si fonda su una considerazione relativa alla scala dei due termini della loss multi-obiettivo (Equazione 3.4.3). Il termine di fedeltà $\mathcal{L}_{\text{fidelity}}$, essendo una media di differenze quadratiche tra valori di aspettazione in $[-1, 1]$, assume un range teorico, mentre il termine di fairness $\mathcal{L}_{\text{fairness}} = \text{spd_proxy}^2$, essendo il quadrato di una differenza tra probabilità in $[-1, 1]$, assume un range più ristretto. Questa asimmetria di scala replica, nel dominio quantistico, la stessa tensione di calibrazione già documentata per l'iperparametro λ_f nei modelli WGAN fairness-aware discussi in Sezione 2.2.2 [8]: senza un fattore di amplificazione adeguato, il contributo della fairness al gradiente totale rischierebbe di essere sistematicamente subordinato a quello della fedeltà, specialmente nelle prime epoche di addestramento, quando l'errore di ricostruzione è ancora ampio. Il valore $\lambda_f = 5.0$ è stato fissato a priori, identicamente per tutte le 54 run della griglia sperimentale, con l'obiettivo di **garantire che il vincolo di equità esercitasse un'influenza non trascurabile sull'ottimizzazione senza tuttavia dominarla** al punto da compromettere la fedeltà distribuzionale del generatore.

3.4.7 Misurazione e Ricostruzione Classica ($\mathcal{S}_4$)

Al termine del processo variazionale, con il vettore dei parametri ottimizzati e congelati θ^* , si avvia la fase $\mathcal{S}_4$: questa si occupa di **estrarre l'informazione classica** dal registro quantistico e di **ricostruire la matrice sintetica** $\mathcal{D}_{\text{synth}}$ riportandola nel dominio continuo e nelle scale originarie dei dataset reali classici.

Operativamente, questo stadio concretizza la teoria generale della misurazione esposta nella Sezione 2.3.2. La decodifica dei qubit predittivi avviene proiettando linearmente i relativi valori di aspettazione $\langle \hat{Z}_j \rangle(\theta^*) \in [-1, 1]$ nell'intervallo probabilistico $[0, 1]$ e applicando la funzione di scaling inverso S^{-1} per ripristinare i range fisici reali del dataset originario:

$$\tilde{x}_j = S^{-1} \left(\frac{\langle \hat{Z}_j \rangle(\theta^*) + 1}{2} \right) = \frac{\langle \hat{Z}_j \rangle(\theta^*) + 1}{2} \cdot (x_{j,\max} - x_{j,\min}) + x_{j,\min} \quad (3.4.9)$$

dove l'indice j si estende su tutte le d feature continue del dataset. Le variabili dicotomiche associate alla classe Y e all'attributo sensibile A vengono ricostruite binarizzando il rispettivo valore atteso tramite una funzione a gradino $\mathbb{I}(\cdot)$ incentrata sullo zero:

$$\tilde{y} = \mathbb{I}(\langle \hat{Z}_{\text{target}} \rangle \geq 0), \quad \tilde{a} = \mathbb{I}(\langle \hat{Z}_{\text{sens}} \rangle \geq 0) \quad (3.4.10)$$

Questa binarizzazione basata sul segno del valore atteso del qubit equivale matematicamente a verificare se la probabilità proiettata $P(\hat{Y}_i = 1)$ definita dall'equazione 3.4.6 sia maggiore o uguale alla classica soglia decisionale di 0.5 (arrotondando a 1 se la condizione è soddisfatta e a 0 in caso contrario). Questa equivalenza formale garantisce una perfetta coerenza decisionale tra le distribuzioni nello spazio quantistico e i dati ricostruiti nel dominio classico.

Corrispondenza Software Questa fase traduce la simulazione quantistica in dati classici ispezionabili e direttamente fruibili. L'estrazione dei valori attesi del batch è implementata dalla funzione `reconstruct_dataset()` all'interno della classe `VQCGenerator` nel modulo `quantum_vqc.py`. L'inversione dello scaling lineare (Equazione 3.4.9) applica i parametri minimi e massimi ($x_{j,\min}, x_{j,\max}$) salvati originariamente a monte durante la fase di pre-processing ($\mathcal{S}_1$) dalla funzione `scale_to_angle` del modulo `data_pipeline.py`. Una volta completata la ricostruzione della matrice, la funzione `save_synthetic_dataset` integrata nel

modulo `dataset_export.py` esporta la matrice $\mathcal{D}_{\text{synth}}$ in formato CSV. Per promuovere la riproducibilità scientifica e l'ispezionabilità diretta delle istanze sintetizzate, il file viene salvato con intestazioni di colonna leggibili e nelle unità fisiche originali del dominio classico, adottando la convenzione di naming formalizzata nel benchmark empirico di Voria et al. [1]:

```
<dataset>_generated_<configuration>_seed<seed>.csv
(ad esempio, german_credit_generated_L1_linear_seed7.csv)
```

Questo assicura che il dataset generato costituisca un artefatto empirico indipendente e pronto per il protocollo di audit downstream ($\mathcal{S}_5$).

3.5 Valutazione Empirica e Audit XQML ($\mathcal{S}_5$)

La fase conclusiva $\mathcal{S}_5$ completa la pipeline $\mathcal{P}$. Avendo ricostruito e salvato su disco i dataset sintetici $\mathcal{D}_{\text{synth}}$ nelle unità fisiche e nelle scale originarie del dominio classico, lo step $\mathcal{S}_5$ esegue uno scrutinio sistematico e multidimensionale per quantificare la qualità complessiva delle istanze generate. Tale impianto di valutazione si articola in una fase propedeutica di caratterizzazione strutturale, seguita da tre procedure d'indagine associate alle nostre domande di ricerca:

- Profiling delle Frequenze Marginali e Intersezionali (Prerequisito)
- Utilità Predittiva Downstream (RQ1)
- Fairness Downstream e Diagnostica Quantistica (RQ2)
- Quantum Explainability, Entanglement e Complessità (RQ3)

3.5.1 Profiling delle Frequenze Marginali e Intersezionali

Come prerequisito per l'analisi comparativa, l'operatore $\mathcal{S}_5$ esegue un protocollo di profiling descrittivo incentrato esclusivamente sulle distribuzioni di frequenza dei dati sintetici e reali. Questo passaggio è indispensabile per verificare la consistenza strutturale delle popolazioni sintetizzate, con particolare riferimento al bilanciamento dei gruppi demografici e alla ripartizione della variabile target.

Nello specifico, l'audit descrittivo si concentra sulla quantificazione delle frequenze assolute e relative per le variabili binarie e qualitative del sistema:

- **L'attributo sensibile intersezionale** (A_{overall}): necessario per mappare l'equità di gruppo ed escludere squilibri macroscopici o asimmetrie sistematiche nella rappresentazione dei sottogruppi storicamente svantaggiati;
- **La variabile target di classificazione** (Y): indispensabile per assicurare che il generatore quantistico non soffra di fenomeni di *mode collapse* e preservi il corretto bilanciamento tra le classi favorevoli e sfavorevoli.

Il censimento delle frequenze viene condotto capillarmente su tutti i 19 file per dominio (il dataset reale di riferimento e i 18 sintetici generati dalle 6 configurazioni variazionali su 3 seed indipendenti), applicando quality gates automatici per verificare che la cardinalità complessiva e la struttura dimensionale delle matrici sintetiche coincidano rigorosamente con quelle dei training set reali di partenza.

Corrispondenza Software Questo protocollo di profiling descrittivo è interamente automatizzato ed eseguito dal modulo `dataset_analysis.py`. Nello specifico, la funzione `compute_freq_stats()` calcola ed esporta le tabelle di frequenza marginale per la variabile target e per l'attributo sensibile intersezionale. I report strutturati risultanti `overall_statistics.csv` e `target_statistics.csv` vengono salvati nella directory dedicata `Datasets_Analysis/<dataset>/`. In parallelo, la verifica formale dei quality gates sulla cardinalità e sull'integrità dimensionale dei file è delegata al modulo `validation_suite.py`, il quale blocca l'esecuzione ed emette un'eccezione in caso di discrepanze strutturali.

3.5.2 RQ1: Utilità Predittiva Downstream (Protocollo TSTR)

Coerentemente con il protocollo *Train on Synthetic, Test on Real* (TSTR) [15, 1], abbiamo scelto 3 modelli rappresentativi di classificazione classica di diversa complessità architetturale ($\mathcal{M}_{\text{down}} \in \{\text{RandomForest}, \text{XGBoost_stub}, \text{MLP}\}$) da addestrare esclusivamente sul dataset sintetico $\mathcal{D}_{\text{synth}}$ e testare sul test set reale congelato $\mathcal{D}_{\text{test}}$. Le metriche estratte sono l'**F1-score** (macro/weighted) e l'**Accuracy**.

Matematicamente, indicando con TP , TN , FP e FN rispettivamente i veri positivi, veri negativi, falsi positivi e falsi negativi estratti dalla matrice di confusione di ciascun classificatore downstream, le due metriche prestazionali sono formalizzate come segue:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.5.1)$$

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (3.5.2)$$

dove la precisione ($\text{Precision} = \frac{TP}{TP+FP}$) misura la capacità dell'algoritmo di non classificare erroneamente istanze negative come positive, mentre la sensibilità ($\text{Recall} = \frac{TP}{TP+FN}$) indica la frazione di istanze positive reali correttamente individuate dal modello.

Nel nostro disegno di ricerca, focalizzato sull'equità distributiva e sulla parità di trattamento, il calcolo dell'F1-score si concentra rigorosamente sulla classe positiva e favorevole $Y = 1$ (credito concesso, assenza di rischio patologico, superamento del corso), garantendo una valutazione diretta dell'utilità del dato sintetico rispetto all'esito decisionale d'interesse.

Corrispondenza Software Il calcolo numerico delle equazioni 3.5.1 e 3.5.2 è integrato all'interno del modulo `evaluation.py`. Nello specifico, utilizziamo la funzione `rq1_rq2_evaluation_multi_attribute()` per gestire l'addestramento sequenziale dei tre classificatori downstream ($\mathcal{M}_{\text{down}}$) sul dataset sintetico ed esegue la successiva fase di testing sul test set reale congelato $\mathcal{D}_{\text{test}}$, estraendo le metriche di Accuracy e F1-score tramite le primitive della libreria `scikit-learn` [61]. I risultati così computati vengono strutturati e salvati automaticamente nel file:

`rq1_models_results.csv,`

rendendoli immediatamente disponibili per le successive fasi di analisi comparativa e statistica.

3.5.3 RQ2: Fairness Downstream e Diagnostica Quantistica

Sulle predizioni $\hat{Y} = \mathcal{M}_{\text{down}}(\mathcal{D}_{\text{test}})$ prodotte dai tre modelli classificatori classici downstream sul test set reale congelato vengono calcolate le tre metriche canoniche di parità di gruppo su ciascun asse sensibile (age, sex e la congiunzione intersezionale overall) per quantificare l'equità algoritmica:

$$\text{SPD} = P(\hat{Y} = 1 \mid A = 1) - P(\hat{Y} = 1 \mid A = 0) \quad (3.5.3)$$

$$\text{EOD} = P(\hat{Y} = 1 \mid Y = 1, A = 1) - P(\hat{Y} = 1 \mid Y = 1, A = 0) \quad (3.5.4)$$

$$\text{AOD} = \frac{1}{2} \left[(P(\hat{Y} = 1 \mid Y = 0, A = 1) - P(\hat{Y} = 1 \mid Y = 0, A = 0)) + \text{EOD} \right] \quad (3.5.5)$$

In linea con le formalizzazioni espresse nella Sezione 2.1.2, l'equazione 3.5.3 misura la parità statistica pura, l'equazione 3.5.4 quantifica l'uguaglianza delle opportunità limitatamente al sottoinsieme dei soli profili meritevoli ($Y = 1$), mentre l'equazione 3.5.5 esprime la media simmetrica tra il divario dei falsi positivi e la componente di EOD.

Corrispondenza Software Il calcolo delle metriche SPD, EOD e AOD è affidata alla routine `fairness_metrics_by_attribute()` invocata da `evaluation.py` che esegue vettorialmente le equazioni 3.5.3, 3.5.4 e 3.5.5 binarizzando ed estraendo i valori per ciascun attributo sensibile e salva i risultati nel file:

```
rq2_all_fairness_results_multiattribute.csv.
```

Inoltre, al fine di correlare il comportamento decisionale classico dei classificatori downstream con le proprietà geometriche quantistiche intrinseche dello spazio di Hilbert, si effettua una diagnostica quantistica nativa. Sfruttando la classe e le funzioni specializzate del modulo `bell_sampling.py`, il sistema estrae tre parametri fisici fondamentali del circuito variazionale:

- la **Trace Distance d'input** ($D_{\text{tr}}(\hat{\rho}_1, \hat{\rho}_0)$): calcolata dalla funzione

`trace_distance()`, quantifica la distinguibilità geometrica tra gli operatori

di densità ridotta dello stato quantistico misto d'ingresso per il gruppo privilegiato ($\hat{\rho}_1$) e non privilegiato ($\hat{\rho}_0$), definita a livello teorico nella Sezione 2.4.1 sulla base del formalismo di Perrier [46] e Nielsen e Chuang [39];

- la **Quantum Statistical Parity di output** (`qsp_diff_output`): estratta dalla funzione `quantum_statistical_parity_diff()`, esprime la parità quantistica pura misurata direttamente alle uscite del circuito prima dell'unscaling classico, valutando la deviazione dei valori attesi dell'osservabile di Pauli $\hat{Z}$ e traducendo operativamente la metrica di QSP introdotta nella Sezione 2.4.1 sulla base dei lavori di Perrier [46];
- l'**identificazione di coppie di bias** (*bias pairs*): gestita attraverso la funzione `bias_pair_diagnostic()`, mappa operativamente le istanze che presentano una minima distanza di traccia nello spazio di Hilbert quantistico d'ingresso ($\leq \epsilon$) ma che producono una divergenza predittiva d'uscita superiore alla tolleranza classica ($> \delta$), in linea con la formulazione di Guan et al. [48] discussa nella Sezione 2.4.2.

3.5.4 RQ3: Quantum Explainability (SVQX), Entanglement e Complessità

L'interpretabilità causale del circuito è analizzata attraverso il framework dei **Quantum Shapley Values** (SVQX), estendendo all'equità algoritmica la formulazione assiomatica di Heese et al. [25] ampiamente descritta nella Sezione 2.5.3. In questo contesto di gioco cooperativo, i giocatori della coalizione corrispondono ai raggruppamenti funzionali dei gate quantistici $\mathcal{G}$ (composti dalle porte di rotazione per ciascun qubit e dall'intero blocco di entangling CNOT).

La funzione di valore cooperativa $v(S)$ misura la capacità di una sotto-coalizione di gate attivi $S \subseteq \mathcal{G}$ di preservare l'equità algoritmica sul qubit target, proiettando le misure nello spazio classico:

$$v(S) = 1 - \left| \text{SPD} \left(\mathcal{M}_{\text{down}}^{(S)} \right) \right| \quad (3.5.6)$$

dove $\text{SPD} \left(\mathcal{M}_{\text{down}}^{(S)} \right)$ rappresenta la disparità statistica downstream prodotta valutando il generatore con la maschera dei gate parziali associata alla sotto-coalizione S .

In perfetta coerenza con la Sezione 2.5.3, lo Shapley value ϕ_i di ciascun gate group viene calcolato per enumerazione combinatoria esatta su tutte le $2^{|\mathcal{G}|}$ sotto-coalizioni:

$$\phi_i = \sum_{S \subseteq \mathcal{G} \setminus \{g_i\}} \frac{|S|! (|\mathcal{G}| - |S| - 1)!}{|\mathcal{G}|!} [v(S \cup \{g_i\}) - v(S)] \quad (3.5.7)$$

Data la cardinalità contenuta del registro quantistico del simulatore ($|\mathcal{G}| \in \{10, 11\}$ a seconda del dominio applicativo), l'esplorazione esaustiva dello spazio delle coalizioni (1024 o 2048 combinazioni) è computazionalmente trattabile.

Sulle spiegazioni causali estratte e sulla struttura fisica dell'ansatz vengono calcolate tre metriche quantistiche e statistiche:

1. **Indice di Concentrazione Gini SVQX:** quantifica la dispersione dell'attribuzione causale tra le porte del circuito, valutando la deviazione della disuguaglianza interna delle spiegazioni;
2. **Stabilità Inter-Seed SVQX ($\bar{\rho}$):** misura la concordanza media di rango pairwise di Spearman tra i vettori di attribuzione ϕ ottenuti eseguendo il fit su tre seed di inizializzazione stocastica indipendenti ($7 \leftrightarrow 17, 7 \leftrightarrow 27, 17 \leftrightarrow 27$);
3. **Entanglement Meyer-Wallach e Stima Purezza (con `qsalto`):** stima dello score di entanglement multipartito medio $E_{MW} = 1 - \frac{1}{n} \sum \text{Tr}(\hat{\rho}_j^2)$ e del relativo coefficiente Shor-Laflamme a_1 , teorizzati nella Sezione 2.4.3. Il calcolo viene eseguito simulando un protocollo Bell State Measurement a due copie su un registro di $2n$ qubit, registrando la statistica dei singoletti su 2048 shot in conformità con il framework di Miller et al. [27].

Infine, vengono valutate 12 correlazioni architetturali per ciascun dataset, incrociando i tre predittori di complessità hardware quantistica

$$X \in \{\text{cnot_count}, \text{n_params}, \text{n_layers}\}$$

con i quattro outcome fisici e funzionali emersi dalle simulazioni

$$Y \in \{\text{aod_mean}, \text{spd_mean}, \text{eod_mean}, \text{entanglement_score}\}$$

Corrispondenza Software L'intero protocollo di audit XQML e complessità strutturale è automatizzato mediante la cooperazione di moduli Python specializzati:

- Il calcolo dei Quantum Shapley Values (Equazione 3.5.7) è implementato all'interno del modulo `svqx.py`. In particolare, la funzione `build_gate_groups()` ripartisce i gate fisici dell'ansatz quantistico in rotazioni per qubit e blocchi CNOT, mentre la routine `svqx_exact()` esegue l'esplorazione combinatoria ed estrae deterministicamente i relativi contributi di Shapley. L'indice di concentrazione dell'attribuzione causale è calcolato dalla funzione `svqx_concentration()` come rapporto tra il valore di picco assoluto e la sommatoria delle attribuzioni associate a ciascun gruppo di gate.
- La quantificazione fisica dell'entanglement globale e la simulazione a due copie sono affidate al modulo `entanglement_analysis.py`: attraverso la funzione `build_two_copy_bell_circuit()` si costruisce il circuito esteso a $2n$ qubit necessario per eseguire il protocollo di misura dello stato di Bell, mentre con la routine `analyze_entanglement()` si esegue la simulazione esatta dello statevector usando le primitive della libreria `qsalto` [27] per calcolare il coefficiente Shor-Laflamme a_1 .

Tutti i vettori di attribuzione causale SVQX, gli indici di stabilità e concentrazione, nonché i parametri di entanglement globale e complessità computati a runtime vengono strutturati e salvati automaticamente nel file di record:

`rq3_all_results.csv,`

garantendo la perfetta omogeneità metodologica dell'analisi strutturale e assicurando che le metriche fisiche estratte per la RQ3 siano rigorosamente confrontabili tra tutte le configurazioni variazionali simulate.

3.6 Framework Statistico Inferenziale (Demšar [2])

L'analisi statistica inferenziale adotta un protocollo inferenziale non parametrico strutturato in quattro fasi conforme alle linee guida di Demšar [2]:

1. **Test preliminare di Normalità di Shapiro-Wilk (Fase Diagnostica):** rappresenta il punto di partenza logico dell'intero framework inferenziale. Prima di procedere a qualsiasi confronto comparativo, è indispensabile verificare se le distribuzioni empiriche delle metriche campionate (F1-score, Accuracy, SPD, EOD, AOD, Trace Distance, stabilità SVQX ed entanglement) seguano un andamento simmetrico di tipo gaussiano. Il test di Shapiro-Wilk viene applicato per verificare l'ipotesi nulla H_0 di normalità ($\alpha = 0.05$). L'esito di questa diagnosi determina la direzione metodologica dello studio: l'evidenza di una sistematica violazione della normalità (frequente nelle metriche di fairness a causa dei loro vincoli di dominio e delle asimmetrie dei dati) rende l'uso di test parametrici classici (come ANOVA o t -test) fallace, rendendo di conseguenza obbligatoria l'adozione di un impianto statistico di tipo non parametrico;
2. **Test Omnibus di Friedman (Rilevazione delle Differenze Globali):** una volta accertata la non-normalità dei dati nel passo precedente, si applica il test di Friedman, un metodo non parametrico a blocchi randomizzati progettato per valutare se vi siano discrepanze significative tra i ranghi delle $k = 6$ configurazioni sperimentali su molteplici blocchi di controllo indipendenti N . I blocchi vengono strutturati a grana differente a seconda dell'obiettivo di ricerca:
 - per **RQ1** (utility) e **RQ2** (fairness), si utilizzano $N = 9$ blocchi derivanti dall'incrocio tra le ripetizioni stocastiche e i classificatori downstream (`seed × model`);
 - per **RQ3** (struttura e spiegabilità), l'analisi si disaggrega operativamente su due livelli: a livello di singola porta (*gate-level*) si opera su $N = 30$ o $N = 33$ blocchi risultanti dall'incrocio tra i seed e i raggruppamenti funzionali di porte quantistiche (`seed × gate_group`), mentre a livello di intero circuito (*run-level*) l'analisi opera su $N = 3$ blocchi di controllo

basati esclusivamente sui seed stocastici per confrontare metriche globali quali la concentrazione Gini, l'entanglement e la purezza quantistica.

Se questo test omnibus produce un valore di significatività $p < 0.05$, esso rigetta l'ipotesi nulla di equivalenza prestazionale globale, attestando che almeno una configurazione differisce dalle altre e fungendo da trigger logico per l'attivazione del successivo test post-hoc;

3. **Test Post-Hoc di Nemenyi e Correzioni per Test Multipli (Localizzazione e Controllo dei Falsi Positivi):** l'ottenimento di un risultato significativo nel test di Friedman (passo 2) certifica l'esistenza di differenze complessive, ma non consente di individuare quali specifiche configurazioni siano dissimili. Per risolvere tale limitazione, si procede ai confronti pairwise (a coppie) tra i trattamenti. Avendo definito $k = 6$ configurazioni quantistiche, il numero di confronti simultanei da effettuare è pari a 15, valore derivante dal coefficiente binomiale che calcola le combinazioni semplici di classe 2:

$$\binom{k}{2} = \frac{k(k-1)}{2} = \frac{6 \times (6-1)}{2} = 15 \quad (3.6.1)$$

Tuttavia, l'esecuzione di ben 15 test indipendenti sullo stesso dataset introduce una grave minaccia metodologica nota come inflazione dell'errore di Tipo I (accumulo di falsi positivi). Per mitigare questa minaccia e garantire l'assoluta affidabilità delle rilevazioni, i p -value grezzi calcolati tramite il test di Nemenyi vengono sottoposti a procedure di correzione. Nello specifico, il nostro motore statistico applica in parallelo la procedura conservativa step-down di **Holm-Bonferroni** (volta a controllare il Family-Wise Error Rate, FWER, escludendo anche un singolo falso positivo) e la procedura step-up di **Benjamini-Hochberg** (volta a controllare il False Discovery Rate, FDR, stabilito al valore nominale di 0.05, bilanciando la potenza statistica con il rigore dei filtri);

4. **Analisi delle Correlazioni di Rango e Stabilità (Comprensione Causale e Strutturale):** mentre i test di Friedman e Nemenyi (passi 2 e 3) si limitano a stabilire e localizzare l'esistenza di differenze prestazionali, questo passo finale mira a comprenderne le cause architetturali e a verificarne la stabilità metodologica. Sulla base delle distribuzioni verificate nel passo 1, si applica

il calcolo dei coefficienti di correlazione non parametrica di Spearman (o di Pearson, qualora le assunzioni di Shapiro-Wilk siano rispettate). Questa analisi permette di:

- valutare pairwise la stabilità del ranking causale dei Quantum Shapley Values (SVQX) attraverso seed stocastici indipendenti ($7 \leftrightarrow 17$, $7 \leftrightarrow 27$, $17 \leftrightarrow 27$) per dimostrare la robustezza del framework esplicativo, esportando i coefficienti;
- mappare sistematicamente la forza e la direzione del legame tra le metriche di complessità fisica del circuito (`n_layers`, `cnot_count`, `n_params`) e i risultanti outcome funzionali di fairness ed entanglement (`spd_mean`, `eod_mean`, `aod_mean`, `entanglement_score`), traducendo la pura osservazione in una solida spiegazione teorica dei modelli. Per poter mettere in relazione le metriche misurate a livello di singolo classificatore con i parametri fisici dei circuiti (estratti a livello di run), che risiedono su livelli di dettaglio differenti, il motore statistico calcola la media delle metriche classiche per ogni run e le unisce ai dati di complessità. Questo allineamento permette di calcolare le 12 correlazioni architetturali.

Corrispondenza Software Questo intero impianto di analisi statistica inferenziale è centralizzato ed eseguito automaticamente dal modulo `statistical_engine.py`. All'interno del modulo, la funzione `shapiro_table()` esegue i test diagnostici di normalità sulle metriche esportate, mentre la funzione `friedman_table()` gestisce l'applicazione del test di Friedman e calcola le correzioni di Holm e FDR-BH tramite le librerie `SciPy` e `Statsmodels`. L'estrazione delle matrici post-hoc è affidata alla funzione `write_posthoc()`, che mappa le differenze critiche di Nemenyi salvando i risultati in file CSV dedicati. Infine, la funzione `process_rq3()` governa l'intero flusso di indagine strutturale della RQ3: gestisce l'aggregazione media delle performance downstream, esegue il merge relazionale RQ2-RQ3, calcola le correlazioni di complessità architetturale e compila i report `complexity_correlations.csv` e `svqx_stability_spearman.csv`, rendendoli pronti per la successiva generazione di grafici ad alta risoluzione da parte del modulo `visualization_suite.py`.

3.7 Ingegneria del Software per la Ricerca Riproducibile

Per garantire la rigorosa riproducibilità scientifica dell'intero impianto empirico, l'infrastruttura software adotta tre criteri di qualità formale:

1. **Politica di Zero Fallback Silenzioso:** ogni modulo solleva eccezioni esplicite e bloccanti (`DatasetLoadError`, `EntanglementAnalysisError`) qualora si verificano anomalie nei dati o nei circuiti, prevenendo la propagazione silenziosa di valori approssimati o fittizi;
2. **Persistenza Atomica e Self-Healing:** l'orchestratore della pipeline (`pipeline_orchestrator.py`) traccia lo stato della griglia tramite manifest JSON atomico (*write-to-temp-then-replace*). All'avvio, un meccanismo di auto-riconciliazione rileva le tuple già scritte sui file CSV raw tramite un manifest, garantendo l'idempotenza del resume in caso di interruzioni di calcolo ed eliminando il rischio di duplicazioni accidentali nei record;
3. **Gestione Deterministica dell'Entropia (Multi-Seeding):** l'uso della terna di seed (7, 17, 27) fissata sistematicamente garantisce il perfetto determinismo sia nella componente classica (suddivisione dei dataset e addestramento dei modelli downstream) sia in quella quantistica (inizializzazione dell'ansatz e campionamento dei qubit), assicurando la replicabilità esatta (*bit-for-bit*) di ogni run sperimentale;
4. **Validation Suite Formale:** uno script di audit (`validation_suite.py`) certifica prima dell'elaborazione statistica l'integrità dimensionale delle 54 run (162 righe RQ1, 486 righe RQ2, 576 righe RQ3), l'unicità delle chiavi primarie composite, i vincoli di range delle matrici Nemenyi ($p \in [0, 1]$) e la conformità relazionale 1 : 1 tra i dataset di fairness e complessità.

3.8 Delimitazione dello Scope Sperimentale

In conformità con le buone pratiche dell'Ingegneria del Software Empirica, si esplicitano le seguenti scelte metodologiche volte a delimitare e circoscrivere lo scope della presente sperimentazione:

1. **Selezione dell'Ansatz Variazionale:** la sperimentazione mantiene fissa la famiglia di ansatz a rotazioni alternate $R_y(\theta) - R_z(\phi)$ con porte CNOT. Il confronto con topologie strutturalmente diverse non è affrontata in questo lavoro;
2. **Valutazione delle Divergenze Distributive:** l'audit della fedeltà statistica del dato si concentra sull'analisi descrittiva marginale (univariata e bivariata) e sul protocollo downstream Train-on-Synthetic Test-on-Real (TSTR). La quantificazione di metriche di divergenza ad alta dimensionalità sul joint space completo (X, Y, A) non rientra negli obiettivi di questo studio;
3. **Esecuzione in Ambiente di Simulazione:** l'intera griglia sperimentale di 54 run è eseguita su simulatori quantistici esatti (*statevector*) per isolare l'espressività algebrica e geometrica pura dell'ansatz variazionale, escludendo però l'interferenza del rumore stocastico e gli errori di lettura (*readout errors*) tipici dei processori NISQ reali;
4. **Vincoli di Dimensionalità del Registro Quantistico:** a causa dell'esponenziale scalabilità computazionale della simulazione variazionale classica (2^n), la sperimentazione è stata intenzionalmente limitata a un registro quantistico ristretto a 9 o 10 qubit. Questo vincolo impone una compressione preliminare delle feature in input tramite *Feature Selection* (Sezione 3.3.1) e delimita l'applicabilità immediata del framework a dataset a bassa dimensionalità;
5. **Natura Tabulare e Target Binario della Generazione:** il framework sviluppato è circoscritto alla sintesi di dataset esclusivamente tabulari a bassa dimensionalità, caratterizzati da feature predittive, un singolo attributo sensibile binarizzato (A) e una variabile target dicotomica (Y). L'adattamento del generatore quantistico a strutture dati non tabulari (es. serie storiche, immagini) o a variabili target multi-classe esula dagli obiettivi di questa tesi.

CAPITOLO 4

Analisi dei Risultati

In questo capitolo vengono presentati e discussi criticamente i risultati empirici¹. derivanti dallo studio comparativo condotto sulla nostra pipeline quantistica variazionale. L'indagine empirica si sviluppa lungo un percorso sequenziale che mira a mappare le capacità dei circuiti quantistici variazionali (VQC) di operare come generatori affidabili ed equi di dati sintetici tabulari. Il capitolo si apre con una valutazione preliminare sulla fedeltà strutturale e sulla conformità geometrica dei dataset sintetizzati nello spazio di Hilbert, analizzando le distribuzioni dell'attributo protetto intersezionale e del target downstream rispetto ai baseline reali. Successivamente, la discussione dei risultati prosegue sviscerando le 3 Research Question che guidano il presente studio.

¹La repository pubblica contenente i sorgenti software, i dataset generati, l'appendice normalizzata e la suite statistica è disponibile all'indirizzo: https://github.com/KLS-01/VQC_Generator-Fair-Interpretable-Data [5].

4.1 Struttura dei Dataset Sintetici Quantistici

Prima di procedere con l'analisi delle Research Question, esaminiamo i dataset sintetizzati da un punto di vista strutturale e distribuzionale. Questa indagine descrittiva preliminare mira a verificare se il generatore variazionale quantistico (VQC) riesca a preservare i vincoli di dominio, a mappare accuratamente la dispersione delle caratteristiche numeriche e a rimodellare in modo equo le frequenze marginali delle variabili critiche (target e attributi sensibili congiunti).

Conformità Geometrica e Resilienza alle Allucinazioni Una delle minacce più documentate nella generazione di dati sintetici tramite modelli linguistici classici (LLM) risiede nella comparsa di allucinazioni semantiche e valori fuori dominio in grado di distorcere pesantemente la deviazione standard e la media dell'intero campione. Al contrario, la nostra pipeline quantistica variazionale offre **garanzie matematiche assolute di conformità dei confini**. Poiché il VQC apprende la distribuzione dei dati all'interno dello spazio di Hilbert proiettando le misure quantistiche (valori di aspettativa degli operatori di Pauli $\langle \hat{Z}_j \rangle \in [-1, 1]$) e applicando una decodifica classica basata sull'inversione esatta dello scaling angolare, i valori sintetizzati vengono matematicamente confinati all'interno dei limiti fisici minimi e massimi del training set reale. L'analisi condotta sulla totalità dei dataset sintetici generati conferma la **completa assenza di outliers** o valori geometricamente non conformi in tutti e tre i domini d'indagine.

Di seguito, la Tabella 4.1 presenta il confronto descrittivo della variabile sensibile continua *age* (età) tra il dataset originale *German Credit* e le relative 6 varian [46]ti sintetiche quantistiche (con valori mediati sulle tre repliche stocastiche associate ai seed 7, 17 e 27). I report descrittivi completi per gli altri due domini (*Student Performance* e *Heart Disease*) sono messi a disposizione all'interno della repository del progetto [5].

Tabella 4.1: Sintesi delle statistiche descrittive per la variabile *age* nel dataset *German Credit* reale e nelle relative varianti sintetiche quantistiche (misure espresse come medie aritmetiche calcolate sui seed 7, 17, 27).

Variante Sperimentale	Min	First Qu.	Mediana	Mean	Third Qu.	Max	Dev. Std.
German Credit Reale	19.00	27.00	33.00	35.55	42.00	75.00	11.38
Varianti Sintetiche VQC							
Sintetico L1 All-to-All	25.76	36.19	49.89	51.04	65.91	74.02	15.40
Sintetico L1 Lineare	24.55	42.93	46.46	46.56	51.25	67.84	7.91
Sintetico L2 All-to-All	34.14	41.63	50.41	49.04	56.61	64.55	8.33
Sintetico L2 All-to-All Re-Upload	24.68	45.45	51.70	52.98	62.93	71.62	11.05
Sintetico L2 Lineare	41.66	45.97	47.07	47.44	48.89	55.04	2.29
Sintetico L2 Lineare Re-Upload	36.40	45.90	47.20	47.29	48.71	58.18	3.02

Come si evince dai dati riportati, i campioni generati tramite circuito quantistico preservano con notevole precisione l'andamento della distribuzione reale, manifestando al contempo un comportamento geometrico correlato alla complessità dell'ansatz:

- **Sotto-Dispersione e Collasso della Varianza (Underdispersion):** Nei circuiti ad ansatz più profondo ($L = 2$) e privi di regolarizzazione classica, si registra una drastica contrazione della deviazione standard della feature continua *age*, che scende a 2.29 nella configurazione *L2_linear* (con range tra 41.66 e 55.04 anni) rispetto all'11.38 del dataset reale. Questa contrazione costituisce un fenomeno di sotto-dispersione geometrica o di collasso locale della varianza. A causa dell'elevata non linearità dell'ansatz profondo non regolarizzato, l'ampiezza di probabilità nello spazio di Hilbert si concentra attorno al valore medio, escludendo sistematicamente le code della distribuzione originale (le fasce d'età inferiori a 40 anni e superiori a 55 anni). L'introduzione del data re-uploading attenua solo parzialmente tale rigidità strutturale nella topologia lineare, come documentato dalla deviazione standard di 3.02 registrata da *L2_re_upload*;

- **Preservazione della Dispersione tramite Connettività All-to-All:** Al contrario, l'adozione di una topologia ad entanglement completo (*All-to-All*) combinata con la tecnica del data re-upload (variante `L2_all_to_all_re_upload`) consente di catturare con straordinaria fedeltà l'intera dispersione originaria. In questa variante, la deviazione standard si attesta a 11.05 (vicina all'11.38 reale), preservando il range della popolazione originale senza incorrere in compressioni o distorsioni del dominio.

Bilanciamento Demografico e Rimodellamento dell'Attributo Intersezionale L'obiettivo cardine del paradigma quantistico variazionale risiede nell'incorporare requisiti di equità direttamente nella loss del circuito, inducendo una **distorsione controllata mirata alla rimozione del bias latente**. Sotto questo aspetto, l'analisi descrittiva delle frequenze dell'attributo sensibile intersezionale A_{overall} (ottenuto congiungendo genere ed età, $A_{\text{sex}} == 1 \wedge A_{\text{age}} == 1$) documenta un'**azione di riequilibrio rappresentativo** all'interno dei dataset sintetici quantistici.

La Tabella 4.2 riassume la distribuzione dell'attributo sensibile intersezionale A_{overall} confrontando il baseline reale e le medie delle configurazioni sintetiche generate su topologia lineare e all-to-all.

I dati raccolti evidenziano un comportamento interessante per la fairness engineering:

- Nel dominio *German Credit*, caratterizzato da un forte sbilanciamento originario a favore del gruppo privilegiato (62.5% vs 37.5%), tutti i dataset sintetizzati riducono nettamente questa asimmetria distributiva. La configurazione quantistica `L2_all_to_all`, ad esempio, rimodella la distribuzione raggiungendo una quasi perfetta parità geometrica nel campione sintetico (50.4% di classe non privilegiata vs 49.6% di classe privilegiata), seguita a stretto giro dalle configurazioni `L1_linear` (47.6%) e `L2_re_upload` (46.7%);
- Nel dominio *Heart Disease*, dove le donne sotto i 55 anni (classe non privilegiata $A_{\text{overall}} = 0$) rappresentano la maggioranza della popolazione reale (65.7%), i circuiti ad addestramento vincolato attenuano questo bias di campionamento spingendo la distribuzione verso la parità demografica. In particolare, le va-

rianti ad ansatz lineare riescono a stabilizzare la rappresentanza portando i due gruppi in perfetta equivalenza campionaria: la configurazione `L1_linear` registra un bilanciamento pari a 48.8% vs 51.2%, mentre la variante `L2_linear` si attesta a 50.2% vs 49.8%;

- Il caso più emblematico si registra nel dominio *Student Performance*. All'interno del dataset reale, le giovani studentesse (classe storicamente svantaggiata $A_{\text{overall}} = 1$) costituiscono un'esigua minoranza pari ad appena l'11.3% del totale, introducendo una grave minaccia di *bias di sotto-rappresentazione*. L'azione correttiva della loss variazionale incrementa sensibilmente la presenza del sottogruppo protetto in tutte le varianti sintetiche: la configurazione `l_all_to_all` quasi quadruplica la presenza del gruppo minoritario (40.7%), mentre tutte e tre le configurazioni lineari (`L1_linear`, `L2_linear` e `L1_re_upload`) stabilizzano i due gruppi demografici attorno a una ripartizione speculare e bilanciata del 50% (con scostamenti inferiori all' 1.1%). Tuttavia, si segnala una anomalia nel comportamento dell'ansatz ad entanglement completo `L2_all_to_all`, dove il sottogruppo protetto viene sovra-rappresentato fino a toccare il 75.8% del campione generato. Questo fenomeno indica una patologia di **over-mitigazione demografica**: la complessa connettività all-to-all a due layer, in assenza di strategie di data re-uploading, spinge la discesa del gradiente verso una compensazione eccessiva e distorta del vincolo di fairness, invertendo la struttura demografica originaria del dominio.

Questo trend sistematico verso l'incremento controllato della diversità demografica attesta che la pipeline variazionale **non si limita a replicare passivamente le asimmetrie storiche** presenti nei dati di addestramento. Interagendo attivamente con la penalità di fairness $\mathcal{L}_{\text{fairness}}$, l'ansatz variazionale riallinea geometricamente i pesi distributivi all'interno dello spazio di Hilbert, attuando un'efficace prevenzione proattiva del bias direttamente a livello del dato.

Tabella 4.2: Frequenze assolute (medie sui seed 7, 17, 27) e relative dell'attributo sensibile intersezionale A_{overall} nei dataset originari e in tutte le varianti sintetiche.

Dominio / Configurazione	N Totale	Sottogruppo $A_{\text{overall}} = 0$		Sottogruppo $A_{\text{overall}} = 1$	
		Frequenza	Percentuale	Frequenza	Percentuale
German Credit					
Originale	1000	375	37.5%	625	62.5%
Sintetico L1 All-to-All	700	416	59.4%	284	40.6%
Sintetico L1 Lineare	700	333	47.6%	367	52.4%
Sintetico L2 All-to-All	700	353	50.4%	347	49.6%
Sintetico L2 All-to-All Re-Upload	700	314	44.9%	386	55.1%
Sintetico L2 Lineare	700	307	43.9%	393	56.1%
Sintetico L2 Lineare Re-Upload	700	327	46.7%	373	53.3%
Heart Disease					
Originale	297	195	65.7%	102	34.3%
Sintetico L1 All-to-All	207	89	43.0%	118	57.0%
Sintetico L1 Lineare	207	101	48.8%	106	51.2%
Sintetico L2 All-to-All	207	117	56.5%	90	43.5%
Sintetico L2 All-to-All Re-Upload	207	131	63.3%	76	36.7%
Sintetico L2 Lineare	207	104	50.2%	103	49.8%
Sintetico L2 Lineare Re-Upload	207	107	51.7%	100	48.3%
Student Performance					
Originale	649	576	88.7%	73	11.3%
Sintetico L1 All-to-All	454	269	59.3%	185	40.7%
Sintetico L1 Lineare	454	229	50.4%	225	49.6%
Sintetico L2 All-to-All	454	110	24.2%	344	75.8%
Sintetico L2 All-to-All Re-Upload	454	350	77.0%	104	23.0%
Sintetico L2 Lineare	454	231	50.9%	223	49.1%
Sintetico L2 Lineare Re-Upload	454	222	48.9%	232	51.1%

Prevenzione del Collasso delle Classi Target ed Equilibrio Funzionale Un rischio intrinseco legato alla ri-generazione di campioni equi è il *mode collapse* (collasso di modo) o la drastica alterazione delle frequenze associate alla variabile target Y . Se l'algoritmo generatore alterasse eccessivamente la proporzione delle classi positive downstream per forzare l'equità, il dataset risultante perderebbe qualsiasi utilità predittiva. L'analisi descrittiva delle frequenze della variabile target esclude questo rischio di collasso categoriale nella nostra pipeline quantistica. Nel dominio *Student Performance*, dove il target `pass_fail` originale presenta un tasso di promozione del 84.6% (549 promossi e 100 bocciati), i relativi campioni variazionali mantengono una solida consistenza marginale: la configurazione `L1_linear` genera una media di 238 promossi (pari al 52.4% del campione ristretto di addestramento), garantendo al contempo una quota robusta di istanze negative (bocciati) pari a 216 record (47.6%). Questa redistribuzione del target assicura che i classificatori classici downstream dispongano di un quantitativo sufficiente di campioni di errore da cui apprendere una frontiera decisionale robusta, evitando un'ottimizzazione banale e cieca sulla sola classe maggioritaria.

In conclusione, questa analisi strutturale preliminare evidenzia le potenzialità e le limitazioni fisiche del paradigma variazionale quantistico. Sebbene la decodifica classica basata sui valori attesi confini matematicamente i dati sintetici entro i limiti fisici del dominio (escludendo outliers ed anomalie di scala), la sotto-dispersione riscontrata nelle varianti profonde non regolarizzate fa risaltare un limite di espressività intrinseco delle topologie lineari NISQ. Al tempo stesso, l'efficacia del meccanismo di ottimizzazione multi-obiettivo si manifesta nel profondo riallineamento demografico delle classi protette, gettando le basi per i miglioramenti di equità downstream esaminati nelle sezioni successive.

4.2 RQ1: Valutazione dell’Utilità Downstream (Performance Analysis)

In questa sezione presentiamo ed esaminiamo in dettaglio i risultati relativi alla prima Research Question (RQ1), valutando se i dataset tabulari sintetizzati tramite i circuiti quantistici variazionali (VQC) possano fungere da valide alternative ai dataset reali. Si rimanda alla Sezione 3.5.2.

4.2.1 Risultati dell’Audit in Cross-Validation (TSTR)

La Tabella 4.3 presenta i valori medi e le relative deviazioni standard di Accuracy ed F1-score ottenuti dai modelli addestrati sia sui dataset quantistici sintetici (nelle loro 6 varianti strutturali) sia sui dataset reali di riferimento.

In analogia con il protocollo metodologico di Voria et al. [1], le metriche prestazionali riportate per le varianti sintetiche quantistiche rappresentano valori aggregati calcolati su un totale di 9 valutazioni indipendenti per ciascuna configurazione sperimentale, derivanti dall’incrocio tra le tre repliche stocastiche (seed 7, 17, 27) e i tre classificatori downstream d’indagine. Queste aggregazioni permettono di isolare e valutare l’effetto complessivo della topologia del generatore quantistico sulla performance decisionale downstream, alleviando alla radice l’influenza o il bias di singoli algoritmi classici.

Analisi Inferenziale e Diagnosi delle Assunzioni Prima di procedere all’interpretazione comparativa dei risultati, i dati prestazionali grezzi sono stati sottoposti al protocollo statistico inferenziale descritto nella Sezione 3.6. Il vaglio diagnostico preliminare condotto tramite il test di Shapiro-Wilk (Fase 1) documenta una sistematica violazione delle assunzioni di normalità gaussiana per le distribuzioni delle metriche in molteplici configurazioni, registrando valori significativi di $p < 0.05$ (ad esempio, per la metrica F1 nella variante L1 Lineare su Heart Disease, $p = 0.0010$, o per la variante L2 Lineare su Student Performance, $p = 0.0865$). Tale evidenza diagnostica convalida formalmente l’adozione obbligata di un impianto inferenziale non parametrico.

Tabella 4.3: Medie e deviazioni standard di Accuracy e F1-score (riferito alla classe positiva $Y = 1$) per i dataset reali di baseline e tutte le configurazioni sintetiche quantistiche associate. Le celle colorate in grigio indicano i baseline reali. I valori sono mediati sui tre seed stocastici e sui tre modelli downstream.

Dominio / Configurazione	Accuracy		F1-Score ($Y = 1$)	
	Media	Dev. Std.	Media	Dev. Std.
German Credit Baseline Reale	0.673	0.064	0.785	0.049
Sintetico L1 All-to-All	0.509	0.130	0.511	0.289
Sintetico L1 Lineare	0.496	0.118	0.495	0.277
Sintetico L2 All-to-All	0.522	0.126	0.532	0.285
Sintetico L2 All-to-All Re-Upload	0.528	0.107	0.591	0.191
Sintetico L2 Lineare	0.494	0.119	0.503	0.262
Sintetico L2 Re-Upload	0.491	0.119	0.499	0.242
Heart Disease Baseline Reale	0.598	0.024	0.596	0.022
Sintetico L1 All-to-All	0.504	0.060	0.262	0.259
Sintetico L1 Lineare	0.483	0.079	0.460	0.231
Sintetico L2 All-to-All	0.472	0.115	0.402	0.248
Sintetico L2 All-to-All Re-Upload	0.447	0.070	0.400	0.235
Sintetico L2 Lineare	0.488	0.109	0.369	0.192
Sintetico L2 Re-Upload	0.470	0.068	0.352	0.286
Student Performance Baseline Reale	0.922	0.011	0.923	0.012
Sintetico L1 All-to-All	0.422	0.206	0.480	0.292
Sintetico L1 Lineare	0.533	0.282	0.592	0.343
Sintetico L2 All-to-All	0.435	0.245	0.484	0.306
Sintetico L2 All-to-All Re-Upload	0.537	0.243	0.601	0.312
Sintetico L2 Lineare	0.394	0.305	0.429	0.371
Sintetico L2 Re-Upload	0.514	0.201	0.598	0.258

Proseguendo con il test omnibus di Friedman (Fase 2) su 9 blocchi ($3 \text{ seed} \times 3 \text{ model}$), la sua applicazione, per i tre i dataset d'indagine, non ha rilevato differenze statisticamente significative per le metriche prestazionali tra le 6 configurazioni VQC:

- *German Credit*: F1-score ($p\text{-value} = 0.5761$), Accuracy ($p\text{-value} = 0.7796$);
- *Heart Disease*: F1-score ($p\text{-value} = 0.1934$), Accuracy ($p\text{-value} = 0.3883$);
- *Student Performance*: F1-score ($p\text{-value} = 0.3697$), Accuracy ($p\text{-value} = 0.2968$).

Ottenendo un valore di significatività superiore alla soglia critica ($\alpha = 0.05$) si accetta l'ipotesi nulla H_0 di equivalenza prestazionale globale tra i circuiti. Sotto il profilo dell'ingegneria del software, questo risultato dimostra che **tutte le 6 configurazioni d'ansatz studiate garantiscono un'elevata robustezza d'utilità predittiva**, posizionandosi su un livello di efficacia statistica omogeneo e statisticamente indistinguibile, a prescindere dalle variazioni di profondità o topologia di entanglement del circuito. Di conseguenza, il test post-hoc pairwise di Nemenyi (Fase 3), i cui p-value corretti con Holm-Bonferroni e Benjamini-Hochberg sono visualizzati nelle heatmap in Figura 4.1, conferma l'**assenza di coppie di configurazioni quantistiche caratterizzate da discrepanze statisticamente significative** (con tutti i p-value a coppie superiori a 0.05, ad esempio, il confronto tra la topologia `L1_linear` e `L2_all_to_all_re_upload` registra un p-value di 0.950 su *Student Performance*).




Figura 4.1: Matrici post-hoc del test di Nemenyi (p-value pairwise corretti per test multipli) per la valutazione della significatività dell'utilità predittiva (RQ1).

Discussione dei Trend Prestazionali per Dominio Sebbene il framework statistico inferenziale attesti l'equivalenza prestazionale interna tra i diversi circuiti quantistici (non rilevando differenze nei ranghi medi), il confronto diretto con il baseline reale (in grigio nella Tabella 4.3) rivela un marcato divario nell'utilità downstream, fortemente condizionato dalla stocasticità del processo variazionale:

- **German Credit:** Nel dominio creditizio, caratterizzato da variabili prettamente categoriche e a bassa cardinalità, i dati sintetici mostrano una competitività eccellente. La configurazione quantistica `L2_all_to_all_re_upload` raggiunge una media di F1-score pari a 0.591 ± 0.191 , limitando il gap rispetto al baseline reale (0.785 ± 0.049). La bassa dimensionalità nativa del dominio facilita la mappatura delle relazioni probabilistiche da parte del registro quantistico, consentendo al VQC di sintetizzare campioni stabili;
- **Heart Disease:** Il dominio clinico si conferma lo scenario più ostico per la sintesi dei dati. La configurazione `L1_linear` registra la prestazione media migliore con un F1-score di 0.460 ± 0.231 , a fronte di una perdita sistematica rispetto al baseline reale (0.596 ± 0.022). Le complesse interdipendenze non lineari e le correlazioni incrociate tra le feature cliniche continue (quali la pressione arteriosa `trestbps` o il colesterolo `chol`) si rivelano difficili da apprendere per ansatz operanti a bassa profondità ($L = 1$ o $L = 2$) senza incorrere in sostanziali distorsioni della densità di probabilità congiunta;
- **Student Performance:** Nel dominio educativo osserviamo come le varianti regolarizzate tramite data re-uploading `L2_all_to_all_re_upload` e `L2_re_upload` si dimostrino nettamente superiori, registrando rispettivamente F1-score medi di 0.601 ± 0.312 e 0.598 ± 0.258 rispetto a 0.484 ± 0.306 e 0.429 ± 0.371 delle rispettive varianti a doppio layer non regolarizzate `L2_all_to_all` e `L2_linear`. Queste ultime subiscono un severo decadimento della predittività (con l'Accuracy media di `L2_linear` che si attesta ad appena 0.394 ± 0.305). In assenza di reiterazione del dato classica (data re-uploading), l'ottimizzatore stocastico risulta altamente sensibile alle condizioni iniziali e cade frequentemente in minimi locali sub-ottimali o in barren plateaus, provocando un'elevata volatilità delle prestazioni downstream.

4.2.2 Audit Empirico nel Mondo Reale (Generalizzazione TSTR)

Al fine di esaminare la reale applicabilità industriale dei dataset sintetizzati quantistici, si è proceduto alla valutazione della capacità di generalizzazione dei singoli classificatori downstream addestrati esclusivamente sui dati sintetici e testati sul test set reale ($\mathcal{D}_{\text{test}}$). La Tabella 4.4 riporta il profilo prestazionale dei migliori classificatori addestrati per ciascuna delle 6 configurazioni e per ciascun dominio di indagine.

Lo scrutinio analitico delle massime performance registrate dai singoli classificatori downstream ci permette di avanzare tre osservazioni di rilevanza metodologica:

1. **La Superiorità dei Modelli Quantistici su Heart Disease (Sintesi come Regolarizzatore):** Nel dominio medico *Heart Disease* un modello Random Forest addestrato esclusivamente sui dati sintetizzati dalla configurazione `L2_all_to_all` (Seed 7) raggiunge un F1-score di 0.675 ed un’Accuracy di 0.722. Questo risultato non solo è straordinariamente competitivo, ma **supera nettamente tutte le controparti reali di baseline** (in cui la Random Forest addestrata su dati reali registra un F1-score di appena 0.603 ed un’Accuracy di 0.603). Questo comportamento ci permette di osservare che il campionamento dello stato quantistico misto attraverso una topologia ad entanglement completo (All-to-All) agisce come un potente **filtro di regolarizzazione e rimozione del rumore statistico**. Eliminando le fluttuazioni spurie del campione reale, il VQC sintetizza frontiere di densità stabili, consentendo all’algoritmo ad alberi classici downstream di apprendere partizioni generali ed esenti da overfitting;
2. **La Preservazione del Baseline MLP su German Credit e Student Performance:** Un comportamento di rilievo si registra per il classificatore Multi-Layer Perceptron (MLP) nei restanti due domini. Nel dominio *German Credit*, la rete MLP addestrata sui dati sintetici quantistici (Seed 27) registra un F1-score di 0.798, superando il baseline MLP addestrato su dati reali (0.729). Nel dominio *Student Performance*, la medesima rete MLP addestrata sulle varianti quantistiche regolarizzate `L2_all_to_all_re_upload` e `L2_re_upload` (Seed 27) tocca un F1-score di 0.929, competitivo con il baseline MLP reale pari a 0.912. Tuttavia, si evidenzia che a questa preservazione dell’F1-score si accompagna

una contrazione dell'Accuracy di picco, che si attesta a 0.867 rispetto al baseline reale medio di 0.922. Questo disallineamento prestazionale non costituisce un fallimento del generatore, bensì l'inevitabile costo numerico (utility trade-off) imposto dalla loss multi-obiettivo: per soddisfare il vincolo di fairness demografica e riallineare la classe protetta minoritaria (dal 11.3% al 50% simmetrico, come documentato in Tabella 4.2), l'ansatz quantistico altera la prevalenza nativa delle etichette, incidendo sull'accuratezza globale del classificatore classico downstream ma sbloccando la parità di trattamento verificata nella RQ2.

3. **Semplicità ed Efficacia delle Strategie d'ansatz:** L'audit conferma che **l'incremento di complessità architetturale quantistica non garantisce necessariamente un incremento di utilità**. Circuiti quantistici a singolo layer d'ansatz ($L = 1$) combinati con topologie di entanglement lineare (quali L1 Lineare nel dominio Student Performance, in grado di garantire un F1-score di 0.920) si rivelano strutturalmente idonei ad assicurare prestazioni downstream ad alta generalizzazione, riducendo drasticamente il costo computazionale e i tempi fisici di addestramento variazionale.

Tabella 4.4: Profilo prestazionale dei migliori modelli classificatori classici downstream addestrati in regime TSTR (I valori rappresentano il picco prestazionale registrato sul seed stocastico ottimale).

Dominio / Configurazione	Miglior Classificatore Downstream	Seed	Accuracy	F1-Score
German Credit				
L1 All-to-All	Multi-Layer Perceptron (MLP)	27	0.663	0.798
L1 Lineare	Multi-Layer Perceptron (MLP)	27	0.663	0.798
L2 All-to-All	Multi-Layer Perceptron (MLP)	27	0.663	0.798
L2 All-to-All Re-Upload	Multi-Layer Perceptron (MLP)	27	0.663	0.798
L2 Lineare	Multi-Layer Perceptron (MLP)	27	0.663	0.798
L2 Re-Upload	Multi-Layer Perceptron (MLP)	27	0.663	0.798
Heart Disease				
L1 All-to-All	Multi-Layer Perceptron (MLP)	27	0.433	0.605
L1 Lineare	Gradient Boosting (XGBoost_stub)	17	0.467	0.613
L2 All-to-All	Random Forest	7	0.722	0.675
L2 All-to-All Re-Upload	Multi-Layer Perceptron (MLP)	27	0.433	0.605
L2 Lineare	Multi-Layer Perceptron (MLP)	27	0.433	0.605
L2 Re-Upload	Gradient Boosting (XGBoost_stub)	17	0.500	0.657
Student Performance				
L1 All-to-All	Gradient Boosting (XGBoost_stub)	27	0.723	0.831
L1 Lineare	Multi-Layer Perceptron (MLP)	27	0.851	0.920
L2 All-to-All	Multi-Layer Perceptron (MLP)	17	0.821	0.901
L2 All-to-All Re-Upload	Multi-Layer Perceptron (MLP)	27	0.867	0.929
L2 Lineare	Multi-Layer Perceptron (MLP)	27	0.836	0.911
L2 Re-Upload	Multi-Layer Perceptron (MLP)	27	0.867	0.929

Q Finding 1. Mentre i modelli addestrati su dati quantistici variazionali registrano, a livello medio aggregato, un calo di utilità predittiva (evidenziando un severo trade-off di utilità per le configurazioni profonde non regolarizzate), l'indagine nel mondo reale (generalizzazione TSTR) documenta performance di picco altamente soddisfacenti. Nei domini clinico ed educativo, in scenari ottimali di sintonizzazione stocastica (Seed 27), i modelli downstream addestrati su dati generati da VQC regolarizzati preservano l'utilità originaria del dominio, allineandosi o superando i rispettivi baseline di riferimento (toccando un F1-score di picco pari a 0.675 in Heart Disease e a 0.929 in Student Performance). Le evidenze raccolte confermano che la codifica angolare accoppiata al data re-uploading opera come un naturale regolarizzatore geometrico nello spazio di Hilbert, consentendo di preservare l'espressività informativa del dato sintetico pur sotto l'azione di rigidi vincoli di equità demografica.

4.3 RQ2: Mitigazione del Bias ed Equità Algoritmica

In questa sezione presentiamo ed esaminiamo in dettaglio i risultati relativi alla seconda Research Question (RQ2), volta a quantificare l'efficacia di mitigazione del bias demografico ed intersezionale all'interno dei dataset sintetizzati tramite la pipeline quantistica. Si rimanda alla Sezione 3.5.3.

4.3.1 Risultati dell'Audit di Fairness Downstream

La Tabella 4.5 presenta i valori medi e le deviazioni standard delle metriche di equità downstream (SPD, EOD, AOD) registrati dai classificatori classici (Random Forest, XGBoost, MLP) addestrati in regime TSTR per ciascuna delle 6 configurazioni quantistiche e per i tre attributi sensibili di riferimento.

Ciascun valore rappresenta una media aritmetica calcolata su un totale di 9 valutazioni indipendenti per combinazione (3 seed stocastici $\times$ 3 classificatori classici downstream), consentendo di mappare l'effetto etico strutturale indotto dal generatore quantistico limando le fluttuazioni stocastiche dei singoli modelli classici.

Tabella 4.5: Medie e deviazioni standard delle metriche di fairness (SPD, EOD, AOD) per tutte le varianti sintetiche quantistiche, disaggregate per attributo sensibile (A_{age} , A_{sex} , $A_{overall}$) su tutti e tre i domini sperimentali. I valori rappresentano le medie calcolate su 9 run indipendenti.

Dominio / Attributo	Configurazione VQC	SPD		EOD		AOD	
		Media	Dev. Std.	Media	Dev. Std.	Media	Dev. Std.
German Credit							
A_{age} (Età)	L1 All-to-All	0.0902	0.0858	0.0778	0.1050	0.0966	0.0882
	L1 Lineare	-0.0106	0.0977	-0.0052	0.1094	-0.0090	0.1042
	L2 All-to-All	0.0393	0.0687	0.0537	0.0831	0.0363	0.0688
	L2 All-to-All Re-Upload	0.0725	0.1041	0.0741	0.1027	0.0800	0.1110
	L2 Lineare	0.0765	0.1087	0.0905	0.1256	0.0844	0.1099
	L2 Re-Upload	0.0240	0.0915	0.0202	0.1139	0.0320	0.0931
A_{sex} (Genere)	L1 All-to-All	0.0804	0.0906	0.0919	0.1059	0.0785	0.0855
	L1 Lineare	-0.0286	0.1031	-0.0312	0.1538	-0.0234	0.0908
	L2 All-to-All	0.0269	0.0719	0.0160	0.1030	0.0302	0.0649
	L2 All-to-All Re-Upload	0.0635	0.0652	0.0734	0.0817	0.0658	0.0671
	L2 Lineare	0.0253	0.0837	0.0319	0.0872	0.0290	0.0876
	L2 Re-Upload	0.0455	0.0747	0.0637	0.0787	0.0455	0.0750
$A_{overall}$ (Intersez.)	L1 All-to-All	0.0865	0.0916	0.0918	0.0961	0.0883	0.0906
	L1 Lineare	-0.0217	0.1104	-0.0229	0.1335	-0.0181	0.1056
	L2 All-to-All	0.0395	0.0781	0.0382	0.0987	0.0395	0.0726
	L2 All-to-All Re-Upload	0.0693	0.0702	0.0705	0.0813	0.0754	0.0725
	L2 Lineare	0.0283	0.1058	0.0445	0.0940	0.0294	0.1136
	L2 Re-Upload	0.0416	0.0725	0.0533	0.0858	0.0441	0.0713
Heart Disease							
A_{age} (Età)	L1 All-to-All	0.0219	0.0962	0.0761	0.1374	0.0308	0.0922
	L1 Lineare	-0.0041	0.1054	-0.0088	0.1861	-0.0045	0.1227
	L2 All-to-All	-0.0384	0.1441	-0.0867	0.1204	-0.0377	0.0971
	L2 All-to-All Re-Upload	-0.0109	0.1279	0.0310	0.1848	0.0109	0.1236
	L2 Lineare	-0.0346	0.1135	-0.0155	0.1113	-0.0274	0.0914
	L2 Re-Upload	-0.0469	0.0706	-0.0269	0.1190	-0.0317	0.0844
A_{sex} (Genere)	L1 All-to-All	0.0137	0.0279	-0.0567	0.1365	0.0019	0.0477
	L1 Lineare	0.0105	0.0667	0.0100	0.1647	0.0069	0.0666
	L2 All-to-All	0.0126	0.0491	0.0635	0.1758	0.0366	0.0846
	L2 All-to-All Re-Upload	-0.0383	0.0552	-0.0254	0.0981	-0.0245	0.0746
	L2 Lineare	0.0202	0.1061	-0.0485	0.1397	0.0157	0.0788

Continua nella pagina successiva. . .

Tabella 4.5 – Continua dalla pagina precedente

Dominio / Attributo	Configurazione VQC	SPD		EOD		AOD	
		Media	Dev. Std.	Media	Dev. Std.	Media	Dev. Std.
A_{overall} (Intersez.)	L2 Re-Upload	0.0169	0.0725	0.0152	0.0718	0.0297	0.0641
	L1 All-to-All	0.0298	0.0714	0.0297	0.0441	0.0356	0.0531
	L1 Lineare	0.0092	0.0830	0.0101	0.0804	0.0122	0.0734
	L2 All-to-All	-0.0296	0.0984	-0.0369	0.0753	-0.0141	0.0592
	L2 All-to-All Re-Upload	-0.0271	0.1117	0.0099	0.1317	-0.0100	0.0948
	L2 Lineare	-0.0292	0.1302	-0.0277	0.1111	-0.0156	0.0912
Student Performance	L2 Re-Upload	-0.0261	0.0542	-0.0083	0.0708	-0.0076	0.0451
	A_{age} (Età)						
	L1 All-to-All	0.0191	0.0907	0.0226	0.0859	0.0148	0.1182
	L1 Lineare	-0.0152	0.0585	-0.0301	0.0622	-0.0013	0.0522
	L2 All-to-All	0.0928	0.1003	0.0819	0.0997	0.1180	0.1379
	L2 All-to-All Re-Upload	-0.0009	0.0645	0.0081	0.0665	0.0004	0.0817
A_{sex} (Genere)	L2 Lineare	0.0922	0.1479	0.0622	0.1350	0.0788	0.1237
	L2 Re-Upload	-0.0337	0.1121	-0.0364	0.1270	-0.0057	0.0687
	L1 All-to-All	0.0208	0.0782	0.0191	0.0745	0.0240	0.1092
	L1 Lineare	0.0054	0.1045	-0.0075	0.0938	0.0288	0.1366
	L2 All-to-All	0.0401	0.0531	0.0504	0.0552	0.0150	0.0626
	L2 All-to-All Re-Upload	0.0245	0.0516	0.0365	0.0490	0.0198	0.0710
A_{overall} (Intersez.)	L2 Lineare	0.0364	0.0670	0.0168	0.0425	0.0425	0.0672
	L2 Re-Upload	-0.0307	0.0784	-0.0273	0.0718	-0.0303	0.0989
	L1 All-to-All	0.0350	0.0917	0.0590	0.0733	0.0100	0.1390
	L1 Lineare	0.0144	0.0997	-0.0072	0.1088	0.0321	0.0889
	L2 All-to-All	0.1302	0.1256	0.1307	0.1244	0.1311	0.1426
	L2 All-to-All Re-Upload	0.0112	0.0610	0.0315	0.0609	0.0107	0.0642
	L2 Lineare	0.0853	0.1687	0.0662	0.1326	0.0438	0.1384
	L2 Re-Upload	-0.0401	0.1231	-0.0692	0.1007	0.0053	0.1019

L'esame comparativo dei dati di fairness downstream, pur evidenziando una sistematica contrazione nominale dei vettori di bias rispetto ai baseline storici reali, delinea un quadro caratterizzato da una forte variabilità stocastica, smentendo l'ipotesi di una convergenza etica intrinsecamente stabile dell'algoritmo quantistico. I valori medi prossimi allo zero ideale (parità demografica perfetta) convivono infatti con deviazioni standard di rilievo, segno che la mitigazione agisce in modo disomogeneo al variare dei classificatori classici downstream e delle inizializzazioni casuali.

Nel dominio *German Credit*, ad esempio, sebbene la configurazione `L1_linear` attenui nominalmente il bias portando la Statistical Parity Difference (SPD) media dell'età a -0.0106 e del genere a -0.0286 , tali metriche sono accompagnate da deviazioni standard pari rispettivamente a 0.0977 e 0.1031 . Sotto il profilo metodologico, l'ampiezza di queste oscillazioni (fino a dieci volte superiore al valore medio) indica che l'azzeramento del bias è di natura algebrica ed è frutto della compensazione reciproca tra run positive e negative, piuttosto che di una regolarizzazione geometrica coerente e ripetibile. Al contrario, nel dominio clinico *Heart Disease*, l'adozione della variante `L2_re_upload` per l'attributo intersezionale (A_{overall}) mostra un comportamento decisamente più controllato: la SPD si attesta a -0.0261 con una deviazione standard di 0.0542 , dimezzata rispetto alla variante ad entanglement completo `L2_all_to_all` (0.0984). Questa evidenza documenta come la connettività lineare, agendo da naturale regolarizzatore nello spazio di Hilbert, riesca a stabilizzare parzialmente l'azione mitigatrice della loss. Infine, nel dominio *Student Performance*, l'azione combinata del re-uploading e dell'entanglement All-to-All (configurazione `L2_all_to_all_re_upload`) stabilizza la SPD dell'età al valore registrato più basso di -0.0009 ± 0.0645 . Tuttavia, la bontà di questo specifico risultato non deve indurre a generalizzazioni fuorvianti: lo scrutinio del medesimo dataset sotto l'attributo intersezionale (A_{overall}) evidenzia un severo incremento delle disparità per la configurazione `L2_all_to_all` priva di re-uploading, la quale tocca una SPD di 0.1302 ± 0.1256 e una EOD di 0.1307 ± 0.1244 , superando ampiamente le soglie etiche di tolleranza comunemente accettate in letteratura. Tale comportamento conferma che l'equità quantistica downstream è un equilibrio estremamente fragile, governato in modo causale e non lineare dalla combinazione tra la topologia dell'ansatz e la tecnica di caricamento dei dati (tra cui data reuploading).

4.3.2 Audit Inferenziale e Localizzazione del Rango

Al fine di validare la consistenza scientifica dell'equità downstream ed escludere che l'abbattimento delle metriche di bias fosse dovuto a fluttuazioni casuali dei campioni sintetici, si è applicato il framework statistico a due stadi dettagliato nella Sezione 3.6. Il vaglio diagnostico preliminare di Shapiro-Wilk (Fase 1) con-

ferma la sistematica violazione della normalità gaussiana per le distribuzioni delle metriche di fairness in molteplici varianti (registrando, ad esempio, un valore significativo di $p < 0.05$ per l'EOD overall su Student Performance nella configurazione L2_all_to_all), imponendo l'uso dei test non parametrici.

L'applicazione del test omnibus di Friedman (Fase 2) su 9 blocchi (3 seed $\times$ 3 model) ha documentato scenari altamente differenziati, svelando i limiti strutturali della pipeline quantistica al variare della complessità degli attributi:

- **Inconsistenza per gli Assi Sensibili Singoli:** Per i domini in cui viene esaminato un singolo attributo isolato (genere o età), il test omnibus di Friedman non rileva alcuna differenza statisticamente significativa tra le 6 configurazioni quantistiche, registrando valori di p -value ampiamente superiori alla soglia critica $\alpha = 0.05$ (ad esempio, per il dataset Student Performance e l'attributo sensibile A_{sex} , si rileva per la SPD, $p = 0.6625$, per la EOD, $p = 0.2540$, e per la AOD, $p = 0.6735$). Sotto il profilo metodologico, questa evidenza indica che le variazioni nominali registrate nella Tabella 4.5 per genere ed età sono fluttuazioni puramente stocastiche, sancendo l'equivalenza statistica di tutti gli ansatz quantitativi su variabili demografiche disaggregate;
- **Significatività nel Setting Intersezionale (EOD Overall):** Al contrario, quando l'analisi si sposta sul setting intersezionale congiunto (A_{overall}), il test di Friedman documenta l'insorgenza di discrepanze statisticamente significative. Nel dataset *Student Performance*, l'ipotesi nulla di equivalenza per la metrica Equal Opportunity Difference (EOD) viene nettamente rifiutata, registrando un valore di statistica $\chi^2_F = 15.108$ ed un p -value raw pari a 0.0099 ($p_{\text{FDR}} = 0.0248$). Tale risultato attesta che la scelta dell'ansatz quantistico governa in modo causale la capacità del modello di mitigare i bias congiunti più complessi, prevenendo il rischio di *fairness gerrymandering* [60].

L'analisi post-hoc pairwise condotta tramite il test di Nemenyi (Fase 3), applicata esclusivamente al dominio *Student Performance* nel setting intersezionale (in quanto unico scenario autorizzato dal rigetto dell'ipotesi nulla di Friedman), localizza con precisione i deficit etici delle topologie profonde non regolarizzate:

- **Inadeguatezza Statistica di L2_all_to_all (EOD Intersezionale):** Lo scrutinio pairwise (Figura 4.2, destra) mostra che la variante L2_all_to_all (0.1307 ± 0.1244) è statisticamente e significativamente peggiore sia di L1_linear ($p = 0.008$) sia di L2_re_upload ($p = 0.003$). Questo andamento, riscontrato anche nel confronto tra L1 All-to-All e L2_re_upload ($p = 0.014$), supporta l'ipotesi critica secondo cui un ansatz profondo ad entanglement totale (all-to-all), se privo di data re-upload, subisce un collasso di generalizzazione etica downstream;
- **Deficit Geometrico Speculare (SPD Intersezionale):** L'analisi pairwise (Figura 4.2, sinistra) conferma questo trend penalizzante. La configurazione L2_all_to_all (0.1302 ± 0.1256) registra un bias significativamente peggiore sia rispetto a L1_linear ($p = 0.023$) sia a L2_re_upload ($p = 0.020$), evidenziando la fragilità etica di questa specifica famiglia architetturale.

Per rigore scientifico, si evidenzia che per i domini *German Credit* e *Heart Disease* nel setting intersezionale, l'accettazione dell'ipotesi nulla del test di Friedman ($p \geq 0.1402$) preclude ex-ante l'esecuzione e l'interpretazione del test post-hoc di Nemenyi. In questi due benchmark, le oscillazioni nominali riportate in Tabella 4.5 non possiedono alcuna significatività statistica.




Figura 4.2: Matrici post-hoc del test di Nemenyi (p-value pairwise corretti per test multipli) per valutare la significatività dell'abbattimento del bias nel setting intersezionale.

Queste discrepanze statistiche smentiscono l'ipotesi di una correlazione lineare tra complessità del circuito ed equità, rivelando un severo bottleneck di ottimizzazione. Sotto il profilo della fisica quantistica computazionale, l'insuccesso dell'ansatz profondo `L2_all_to_all` (0.1302 ± 0.1256) è riconducibile alla suscettibilità verso i *barren plateaus*: l'elevata densità di entanglement globale, senza un refreshing dei dati (date re-upload), appiattisce il paesaggio energetico della loss, intrappolando l'ottimizzatore in minimi locali sub-ottimali incapaci di minimizzare $\mathcal{L}_{\text{fairness}}$. Al contrario, la variante `L2_all_to_all_re_upload` rinfresca la proiezione delle feature nello spazio di Hilbert ad ogni layer, garantendo l'espressività non lineare necessaria per aggirare i plateaus e contraendo la SPD intersezionale al valore minimo di 0.0112 ± 0.0610 . Ciò dimostra che l'equità downstream non dipende dalla pura capacità di correlazione quantistica (entanglement), ma dal bilanciamento geometrico tra l'espressività dell'ansatz e l'adozione di caricamenti sequenziali di dati.

4.3.3 Analisi delle Metriche di Diagnostica Quantistica

Per collegare le logiche fisiche del calcolo quantistico al comportamento etico downstream, estraiamo dallo stato simulato la **Trace Distance d'input** ($D_{\text{tr}}(\hat{\rho}_1, \hat{\rho}_0)$) e la **differenza di parità statistica quantistica** (QSP_{diff}) di output (si rimanda alla Sezione 3.5.3). Trattandosi di metriche quantum-native indipendenti dai classificatori classici, l'analisi omnibus di Friedman sulle 18 run sperimentali (6 configurazioni $\times$ 3 seed) rileva:

- **Significatività di QSP_{diff} :** Differenze statisticamente altamente significative in tutti i domini: *German Credit* ($\chi_F^2 = 12.714$, $p = 0.0262$), *Heart Disease* ($\chi_F^2 = 12.143$, $p = 0.0329$) e *Student Performance* ($\chi_F^2 = 13.857$, $p = 0.0165$);
- **Comportamento di D_{tr} :** Discrepanze significative esclusivamente nel dominio *Heart Disease* ($\chi_F^2 = 12.524$, $p = 0.0283$), a fronte di un'accettazione dell'ipotesi nulla in *German Credit* ($p = 0.7585$) e *Student Performance* ($p = 0.6706$).

I valori medi evidenziano una chiara impronta geometrica legata alle topologie di entanglement. In tutti i domini, le **topologie ad entanglement Lineare** (`L1_linear`, `L2_linear`, `L2_re_upload`) registrano valori di QSP_{diff} estremamente contratti

($QSP_{\text{diff}} \leq 0.02$, con record minimi di 0.0029 per `L1_linear` in *Student* e 0.0032 in *German*). Al contrario, le varianti ad **entanglement completo All-to-All** (specialmente con re-uploading) manifestano asimmetrie quantistiche marcate, con valori di QSP_{diff} che salgono a 0.1480 (`L2_all_to_all_re_upload` su *Student Performance*) e 0.1973 (su *Heart Disease*).

Ciò conferma empiricamente che la connettività lineare dei qubit agisce da regolarizzatore geometrico naturale nello spazio di Hilbert. Limitando la propagazione incontrollata dell'entanglement multipartito lungo il circuito, l'ansatz lineare impedisce allo stato misto di accumulare divergenze asimmetriche sul qubit target, garantendo misurazioni proiettive finali bilanciate che si traducono, a livello classico downstream, nei ridotti valori di bias (SPD ed EOD) documentati in Tabella 4.5.

Analisi dei Bias Pairs (Equità Individuale Quantistica) A completamento del quadro diagnostico nello spazio di Hilbert, si è condotta un'indagine sul bias individuale quantistico mappando le coppie di bias (*bias pairs*) secondo la formulazione di Guan et al. [48] discussa nella Sezione 2.4.2. Lo scrutinio sistematico del database complessivo delle run (486 osservazioni) documenta un comportamento di ottima stabilità etica locale: la presenza di coppie di bias viene infatti registrata in appena 18 righe (pari a sole 2 run fisiche del circuito su 54 totali, il 3.7%), convalidando nel restante 96.3% dei casi la perfetta tenuta del generatore rispetto alla fairness individuale.

Le uniche due anomalie in cui la funzione `bias_pair_diagnostic()` (imposta con tolleranze operative $\varepsilon = 0.1$ e $\delta = 0.1$) ha intercettato coppie di bias si concentrano in due scenari specifici:

- **German Credit (seed 27, `L2_all_to_all_re_upload`):** in cui a fronte di una ridotta Trace Distance d'ingresso pari a $0.0889 \leq \varepsilon$, si è registrata una differenza di parità quantistica d'uscita pari a $0.1427 > \delta$;
- **Heart Disease (seed 7, `L1_all_to_all`):** in cui gli stati demografici d'ingresso, pur risultando geometricamente quasi identici ($D_{\text{tr}} = 0.0683 \leq \varepsilon$), hanno prodotto una divergenza proiettiva d'uscita pari a $0.1227 > \delta$.

Nel dominio *Student Performance*, al contrario, non è stata rilevata alcuna violazione dell'equità individuale quantistica su nessuna delle configurazioni saggiate. Sotto il

profilo computazionale, questa evidenza certifica che la pipeline variazionale non si limita a comprimere il bias macroscopico a livello di intero dataset, ma riesce, nella quasi totalità delle run, a preservare l'omogeneità di trattamento locale a livello di singoli vettori di stato.

🔍 Finding 2. La sperimentazione dimostra che i VQC riducono nominalmente il bias downstream, ma evidenzia una forte instabilità stocastica (ampie deviazioni standard) che rende la fairness macroscopica un equilibrio sensibile alle condizioni di ottimizzazione. Tuttavia, questo comportamento si stabilizza efficacemente mitigando l'esplosione dei *barren plateaus* tramite topologie lineari o meccanismi di data re-uploading, consentendo alla variante `L2_all_to_all_re_upload` di contrarre la SPD intersezionale al record minimo di 0.0112 ± 0.0610 . L'audit quantistico nativo conferma con significatività statistica ($p \leq 0.0329$) che la topologia lineare dei qubit agisce da regolarizzatore geometrico nello spazio di Hilbert, limitando le asimmetrie sul qubit target e influenzando l'equità del dato campionato downstream. Questa regolarizzazione preserva l'equità locale a livello di singoli stati quantistici, garantendo l'assenza di coppie di bias (*bias pairs*) nel 96.3% delle valutazioni complessive.

4.4 RQ3: Analisi della Explainability (SVQX), Entanglement e Complessità

In questa sezione viene esaminata la terza Research Question (RQ3), finalizzata a comprendere i meccanismi causali interni del generatore attraverso l'interazione tra spiegabilità quantistica, dinamiche di entanglement nello spazio di Hilbert e complessità architetturale del circuito. L'analisi si articola in quattro stadi sequenziali: lo scrutinio causale dei Quantum Shapley Values (SVQX) a livello di singoli blocchi di gate, la verifica della stabilità inter-seed delle spiegazioni, la caratterizzazione inferenziale delle metriche fisiche globali (entanglement ed estimatori di purezza tramite `qsalto` [27]) e, infine, la mappatura delle correlazioni strutturali di complessità.

4.4.1 Explainability tramite Quantum Shapley Values (SVQX)

L'applicazione del framework SVQX formalizzato nella Sezione 3.5.4 consente di quantificare l'influenza marginale di ciascun gruppo di gate sull'indice di equità della pipeline, definito dalla funzione di utilità $v(S) = 1 - |SPD|$. Lo scrutinio dei valori medi di SVQX disaggregati per gate-group rivela una dinamica geometrica importante per l'interpretabilità fisica del modello:

- **Il Ruolo Predominante e Penalizzante delle CNOT:** In tutti e tre i domini sperimentali e per tutte le configurazioni d'ansatz analizzate, il gruppo di gate di entanglement globale `entangling_CNOT` registra sistematicamente il valore di SVQX con modulo più elevato, assumendo un segno costantemente negativo. Nel dominio *German Credit* (configurazione `L2_re_upload`), esso si attesta a -0.2135 ± 0.0520 ; nel dominio *Heart Disease* (configurazione `L2_all_to_all_re_upload`) tocca -0.2134 ± 0.1657 ; e nel dominio *Student Performance* (configurazione `L2_re_upload`) registra il picco di -0.3225 ± 0.0701 . Sotto il profilo fisico-teorico, questo risultato fornisce la prova causale del meccanismo di propagazione del bias: la loss function etica tenta di comprimere le asimmetrie, ma l'inserimento di layer di entanglement non locali agisce da primario canale di iniezione e diffusione della disparità demografica tra i qubit del registro quantistico;

- **Ininfluenza delle Rotazioni Locali:** Al contrario, i blocchi di rotazione a singolo qubit (`qubit_i_rot`) esibiscono sistematicamente valori di SVQX prossimi allo zero ideale (ad esempio, qubit dal 0 al 5 registrano valori identici a 0.0000 in tutte le configurazioni All-to-All su *German Credit* e *Student Performance*). Questo comportamento evidenzia come i gate di rotazione classica, agendo esclusivamente come codificatori locali di feature isolate, non partecipano in modo diretto all'amplificazione o alla mitigazione del bias etico macroscopico downstream, il quale resta governato unicamente dalle interconnessioni geometriche del circuito.

Analisi di Concentrazione Gini delle Spiegazioni A completamento dell'indagine causale, si analizza l'andamento dell'indice di concentrazione Gini delle spiegazioni (`svqx_concentration`). Sebbene il test omnibus di Friedman non rilevi differenze inferenzialmente significative tra i ranghi globali della concentrazione ($p \geq 0.0981$ in tutti i domini), l'esame descrittivo dei valori medi evidenzia un trend architetturale: le varianti prive di meccanismi di regolarizzazione classica, come `L1_all_to_all`, esibiscono un'elevata polarizzazione causale, registrando valori di concentrazione Gini pari a 0.622 ± 0.329 in *German Credit* e a 0.558 ± 0.178 in *Heart Disease*; al contrario, l'introduzione delle strategie di data re-uploading contrae sistematicamente la concentrazione, portandola rispettivamente a 0.363 ± 0.027 e 0.368 ± 0.098 nelle configurazioni `L2_all_to_all_re_upload`. Questa contrazione evidenzia come la reiterazione sequenziale delle feature classiche lungo i layer successivi distribuisce in modo omogeneo il carico causale dell'apprendimento su tutto l'ansatz.

4.4.2 Verifica della Stabilità Inter-Seed delle Spiegazioni

Per garantire che le attribuzioni di importanza fornite dai Quantum Shapley Values non risentano del rumore di inizializzazione stocastica, si è valutata la stabilità inter-seed calcolando il coefficiente di correlazione di rango di Spearman (ρ) tra le run fisiche su seed differenti (7, 17 e 27). I risultati documentano che la stabilità è fortemente mediata dall'architettura variazionale quantistica.

Nel dominio *German Credit*, la topologia `L2_re_upload` stabilizza in modo ottimale il profilo di spiegabilità, con coefficiente medio di stabilità pari a $\rho = 0.7131$;




Figura 4.3: Stabilità inter-seed delle spiegazioni SVQX su German Credit.

Nel dominio *Student Performance*, le topologie `L2_all_to_all_re_upload` e `L1_all_to_all` registrano alta stabilità, rispettivamente $\rho = 0.7622$ e $\rho = 0.9704$;




Figura 4.4: Stabilità inter-seed delle spiegazioni SVQX su Student Performance.

Nel dominio clinico *Heart Disease*, caratterizzato da relazioni funzionali complesse e continue, la stabilità si contrae sensibilmente, con un valore massimo di appena $\rho = 0.4768$ nella configurazione `L2_all_to_all_re_upload`, mentre la variante `L2_linear` mostra assenza di consistenza inter-seed con $\rho = -0.0303$.




Figura 4.5: Stabilità inter-seed delle spiegazioni SVQX su Heart Disease.

Questa analisi suggerisce che l’inserimento di strategie strutturate di data re-uploading funge da regolarizzatore numerico, non solo stabilizzando il gradiente durante l’ottimizzazione variazionale, ma conferendo coerenza geometrica e riproducibilità ai Quantum Shapley Values. Nello specifico, la reiterata proiezione delle variabili classiche lungo i successivi layer quantistici previene il decadimento esponenziale del gradiente (barren plateaus) tipico dei circuiti variazionali profondi, riducendo la sensibilità dell’algoritmo di ottimizzazione stocastico alle condizioni iniziali e limitando la dispersione dei parametri ottimi. Al contrario, l’elevata stabilità inter-seed registrata dall’ansatz monostrato `L1_all_to_all` sui domini *Student Performance* e *German Credit* non deriva da un reale processo di apprendimento robusto, ma dalla ridotta dimensionalità dello spazio dei parametri, che costringe l’ottimizzatore a convergere nello stesso minimo locale sub-ottimale indipendentemente dal seed di partenza.

4.4.3 Caratterizzazione Inferenziale di Entanglement e Purity (qsalto)

Per valutare le proprietà fisiche di ciascun ansatz, vengono misurati l'entanglement di Meyer-Wallach (*entanglement_score*) e la purezza dello stato stimata tramite la libreria *qsalto* (*qsalto_a1_estimate*). L'analisi inferenziale tramite test omnibus di Friedman sulle 3 run stocastiche rileva variazioni sistematiche nei diversi domini:

- **Entanglement di Meyer-Wallach:** Differenze altamente significative nei domini *German Credit* ($\chi_F^2 = 13.095$, $p = 0.0225$) e *Heart Disease* ($\chi_F^2 = 13.667$, $p = 0.0179$), mentre il dominio *Student Performance* si attesta sulla soglia di significatività ($\chi_F^2 = 10.810$, $p = 0.0553$);
- **Stima della purezza con qsalto (a_1):** Variazioni statisticamente significative sia in *Heart Disease* ($\chi_F^2 = 14.238$, $p = 0.0142$) sia in *Student Performance* ($\chi_F^2 = 11.952$, $p = 0.0354$). Non si può dire lo stesso per il dominio *German Credit* che non raggiunge la significatività formale ($\chi_F^2 = 10.619$, $p = 0.0595$).

Il test post-hoc di Nemenyi localizza l'origine di queste divergenze nell'incremento della profondità variazionale ($L = 1 \rightarrow L = 2$), che espande l'entanglement globale dello stato preparato con elevata significatività statistica ($p < 0.005$):

- **German Credit:** Le varianti a doppio layer *L2_linear* (0.395 ± 0.035) e *L2_re_upload* (0.386 ± 0.045) registrano un entanglement di Meyer-Wallach superiore rispetto alla controparte monostrato *L1_all_to_all* (0.207 ± 0.016), con p-value pari rispettivamente a $p = 0.0022$ e $p = 0.0045$;
- **Heart Disease:** Le varianti a doppio layer *L2_linear* (0.431 ± 0.060) e *L2_re_upload* (0.425 ± 0.021) registrano un entanglement di Meyer-Wallach superiore rispetto alla controparte monostrato *L1_all_to_all* (0.302 ± 0.029), con p-value pari rispettivamente a $p = 0.0045$ e $p = 0.0022$;

Questa espansione trova perfetta corrispondenza analitica con le stime di purezza calcolate tramite *qsalto*, dove i medesimi confronti pairwise confermano la significatività statistica ($p = 0.0022$ e $p = 0.0045$).

Poiché il test omnibus di Friedman sull'entanglement score per il dataset *Student Performance* ha restituito un valore borderline non significativo ($p = 0.0553 > 0.05$),

per rigorosa coerenza metodologica e per prevenire l'inflazione dell'errore di Tipo I, non è stato condotto il test post-hoc di Nemenyi su questo specifico dominio, limitando l'indagine pairwise a German Credit e Heart Disease, dove l'ipotesi nulla è stata rigettata con significatività.

4.4.4 Mappatura delle Correlazioni Strutturali di Complessità

Per comprendere se la complessità hardware del circuito quantistico (cnot_count, n_params, n_layers) influenzi l'andamento della fairness macroscopica del dato (il comportamento etico del modello), si analizzano le relazioni di rango di Spearman:

- **Relazione Complessità-Entanglement:** Si rileva una significativa correlazione positiva tra il numero di parametri (coincidente con la profondità del circuito) e l'entanglement score di Meyer-Wallach. Tale associazione si attesta a $\rho = 0.6133$ ($p = 0.0068$) in *German Credit* e a $\rho = 0.4770$ ($p = 0.0453$) in *Student Performance*. Più aumentano la complessità parametrica dell'ansatz e la profondità dell'ansatz, più il circuito tende a generare entanglement globale di Meyer-Wallach in modo coerente e misurabile. Questo mostra che il modello sta effettivamente sfruttando le risorse dello spazio di Hilbert per elaborare le informazioni, escludendo che il generatore quantistico si comporti come un semplice modello classico mascherato.
- **Relazione CNOT-Bias Downstream:** Sotto il profilo etico, il risultato di maggiore rilievo dell'indagine strutturale si registra nel dominio *Student Performance*, dove viene documentata una forte e statisticamente significativa correlazione positiva tra il numero fisico di gate CNOT presenti nel circuito e il livello di Equal Opportunity Difference (EOD) medio downstream ($\rho = 0.5230$, $p = 0.0259$). Al contrario, tale associazione non raggiunge la soglia di significatività statistica nei domini *German Credit* ($\rho = 0.2808$, $p = 0.2588$) e *Heart Disease* ($\rho = 0.1065$, $p = 0.6739$). Questo comportamento differenziato suggerisce che la propagazione del bias mediata dalle porte di entanglement sia strettamente legata alla dimensionalità del registro quantistico e alla connettività nativa delle variabili del dataset.




Figura 4.6: Analisi di complessità nel dominio *Student Performance*: correlazione positiva tra la densità fisica di porte CNOT nell’ansatz e la degradazione dell’equità downstream (sinistra) e accumulo sistematico di entanglement di Meyer-Wallach all’aumentare del numero di parametri variazionali (destra).

Questi risultati vanno a sostegno dell’ipotesi secondo cui le porte CNOT influenzano sistematicamente la degradazione dell’equità algoritmica. Sotto il profilo fisico, l’inserimento di un numero elevato di CNOT, favorendo la diffusione delle asimmetrie demografiche presenti nei dataset originali lungo il registro di qubit, agisce come primario vettore di propagazione del bias demografico classico. La conclusione logica che ne deriva è che non serve aumentare a dismisura la complessità del circuito quantistico; al contrario, alla luce di questi risultati, per generare dati sintetici equi è necessario limitare chirurgicamente l’entanglement riducendo il numero di CNOT, adottando topologie di connessione lineari e regolarizzando il flusso di dati tramite strategie strutturate di data re-uploading. Sotto il profilo della complessità hardware, il passaggio dalla connettività completa a quella lineare comporta un abbattimento drastico delle risorse fisiche: nei domini a 10 qubit (*Student Performance* e *Heart Disease*) il numero di porte CNOT scende da 90 a 18, registrando una contrazione esatta dell’80% (riduzione pari al 77.8% nel dominio *German Credit* a 9 qubit, dove le CNOT si contraggono da 72 a 16).

Q Finding 3. L'indagine strutturale mappa con rigore inferenziale il comportamento geometrico interno dei VQC. Lo scrutinio dei Quantum Shapley Values (SVQX) individua nei gate ad entanglement globale (CNOT) il primario vettore fisico quantistico di iniezione del bias demografico (con valori medi di SVQX fino a -0.3225). Inoltre, l'analisi dell'indice Gini dimostra che l'integrazione del *data re-uploading* distribuisce il carico causale lungo tutto l'ansatz, contraendo la polarizzazione delle spiegazioni (fino a 0.363 ± 0.027 rispetto a 0.622 ± 0.329 delle configurazioni non regolarizzate). L'audit delle correlazioni architetturali rivela una diretta e significativa associazione positiva tra la densità delle CNOT e la degradazione dell'equità downstream ($\rho = 0.5230$, $p = 0.0259$ per l'EOD in Student Performance). Infine, le stime di purezza ridotta calcolate tramite `qsalto` e l'indice di Meyer-Wallach provano con significatività statistica ($p < 0.005$) che l'incremento di profondità variazionale quantistica espande coerentemente l'entanglement globale dello stato preparato. Il trend mostrato dai risultati evidenzia una linea guida per il co-design etico-hardware quantistico: per sintetizzare dataset equi, è importante limitare la connettività globale dei qubit riducendo le CNOT ed adottando topologie lineari regolarizzate da meccanismi strutturati di data re-uploading.

CAPITOLO 5

Minacce alla Validità

In accordo con le linee guida metodologiche per l'Ingegneria del Software Empirica [9], in questo capitolo vengono analizzate le principali minacce che potrebbero inficiare la validità, la generalizzabilità e la riproducibilità dei risultati ottenuti, riportando al contempo le strategie di mitigazione adottate.

5.1 Validità Interna (Internal Validity)

La validità interna riguarda la misura in cui i fattori identificati e analizzati nel corso dell'esperimento supportino realmente le conclusioni tratte, escludendo l'influenza di variabili confondenti o artefatti software non controllati.

In studi sperimentali che coinvolgono lunghe simulazioni ad alto costo computazionale su più configurazioni, una delle minacce è l'instabilità del runtime energetico o hardware, e la perdita di atomicità nella persistenza dei risultati intermedi, che potrebbe generare record duplicati, incompleti o corrotti.

Strategie di Mitigazione Questi rischi sono stati mitigati adottando alcuni accorgimenti:

- **Persistenza Atomica:** L'orchestratore della pipeline (`pipeline_orchestrator.py`) gestisce la scrittura dei risultati intermedi tramite il manifest transazionale JSON descritto nella Sezione 3.7. Questo approccio transazionale garantisce l'idempotenza del resume in caso di interruzioni arbitrarie del calcolo, escludendo la presenza di record incompleti o corrotti. Ciò è possibile anche grazie al seeding deterministico adottato;
- **Data Quality Gate:** Prima di sottoporre i dati grezzi all'analisi statistica, il sistema esegue un audit automatico tramite lo script `validation_suite.py` già introdotto nella Sezione 3.7, certificando l'integrità dimensionale del database finale dei risultati.

5.2 Validità di Costrutto (Construct Validity)

La validità di costrutto esamina la coerenza tra la definizione teorica delle metriche e delle variabili analizzate e la loro effettiva operazionalizzazione empirica all'interno del disegno sperimentale.

Strategie di Mitigazione Questo rischio è stato mitigato legando ogni fase dell'audit XQML alle metriche e alle metodologie consolidate in letteratura:

- **Operazionalizzazione Coerente di SVQX:** L'equità algoritmica viene attribuita ai singoli gruppi di gate quantistici estendendo l'impianto assiomatico di Heese et al. [25] mediante la specifica funzione di valore $v(S)$ già formulata nell'Equazione 3.5.6 della Sezione 3.5.4. Questo approccio consente di vincolare l'analisi di spiegabilità strutturale direttamente all'impatto etico downstream del generatore, garantendo che le attribuzioni di Shapley abbiano un chiaro significato fisico ed etico;
- **Standardizzazione delle Metriche di Fairness:** Per quantificare il bias demografico e intersezionale dei classificatori downstream si adottano la Statistical Parity Difference (SPD), l'Equal Opportunity Difference (EOD) e l'Average Odds Difference (AOD). Tali metriche rispecchiano fedelmente gli standard operativi della libreria di riferimento *AI Fairness 360* [31], garantendo l'affidabilità delle stime.

5.3 Validità Esterna (External Validity)

La validità esterna analizza il grado di generalizzabilità delle conclusioni sperimentali a dataset o architetture fisiche differenti da quelli direttamente simulati nello studio.

Strategie di Mitigazione Le limitazioni intrinseche alla generalizzazione sono state affrontate definendo con trasparenza lo scope dello studio:

- **Simulazione Controllata:** Come già riportato nelle delimitazioni di scope della Sezione 3.8, l'esecuzione dei circuiti quantistici su simulatori esatti (*statevector*, cioè in ambiente ideale) esclude gli effetti del rumore fisico dei dispositivi NISQ reali. Questa limitazione controllata consente di isolare ed analizzare l'espressività geometrica pura delle topologie d'ansatz senza l'interferenza di variabili confondenti non controllabili legate al rumore termico e di rilassamento dell'hardware quantistico;
- **Diversificazione dei Domini Applicativi:** Al fine di escludere che l'efficacia dei VQC fosse legata a un singolo scenario fortunato, la sperimentazione adotta

sistematicamente lo stesso set di benchmark di Voria et al. [1], coprendo tre dataset reali sensibili caratterizzati da tassi di base e sbilanciamenti complessi in tre settori critici: finanziario (*German Credit*), clinico (*Heart Disease*) ed educativo (*Student Performance*);

- **Diversificazione Modelli per TSTR:** Una potenziale minaccia alla generalizzabilità è legata alla dipendenza dei dati generati da uno specifico algoritmo predittivo classico. Questa limitazione è stata mitigata validando le metriche di utilità (RQ1) e fairness (RQ2) su una suite diversificata di classificatori downstream caratterizzati da paradigmi di apprendimento differenti (tra cui *Multi-Layer Perceptron*, *Random Forest* e *XGBoost*), dimostrando la robustezza e l'agnosticismo del dato generato rispetto al modello predittivo finale.

5.4 Validità di Conclusione (Conclusion Validity)

La validità di conclusione riguarda la correttezza delle relazioni matematiche ed empiriche identificate dal disegno sperimentale, garantendo che le differenze prestazionali o di equità rilevate tra le configurazioni d'ansatz non siano interpretate erroneamente a causa di fluttuazioni casuali, deviazioni standard elevate o anomalie di campionamento.

Strategie di Mitigazione Allo scopo di isolare l'analisi degli effetti dell'architettura dei VQC dalla variabilità stocastica documentata nel Capitolo 4, l'affidabilità delle conclusioni empiriche è tutelata dall'applicazione sistematica del protocollo inferenziale adottato, in conformità con le linee guida di Demšar [2]. Come dettagliato nella Sezione 3.6, questo approccio non parametrico a due stadi (test di Friedman accoppiato a confronti post-hoc di Nemenyi con rigido controllo del tasso di falsi positivi) consente di discriminare in modo matematicamente rigoroso i reali trend di ottimizzazione geometrica dal rumore di fondo indotto dai seed di addestramento, blindando la significatività dei risultati presentati.

Conclusioni e Sviluppi Futuri

In questo capitolo conclusivo vengono riassunti e discussi criticamente i contributi teorici e progettuali introdotti nel presente lavoro di tesi. La trattazione è strutturata per delineare le implicazioni empiriche del paradigma quantistico variazionale attraverso tre messaggi chiave (*Take-Away Messages*) incentrati sui trade-off di utilità ed equità, sulla complessità dell'ansatz quantistico e sul posizionamento di questi strumenti all'interno dei processi di Quality Assurance (QA) del software orientato all'Intelligenza Artificiale. Infine, si esplicitano le limitazioni strutturali dello studio e si delineano le direzioni della ricerca futura.

6.1 Discussione e Take-Away Messages

L'intero percorso sperimentale condotto nei tre domini sensibili (*German Credit*, *Heart Disease* e *Student Performance*) consente di superare l'ingenua narrativa secondo cui i computer quantistici offrano una scorciatoia intrinseca verso l'equità algoritmica. Come evidenziato nell'impianto metodologico, un modello quantistico variazionale (VQC), se addestrato su una popolazione storica affetta da asimmetrie sistematiche, apprende ed eredita deterministicamente tali distorsioni probabilistiche allo stesso modo di un algoritmo classico. Il vero progresso introdotto dal paradigma variaziona-

le poggia su basi interamente matematiche e strutturali: la possibilità di modellare la fairness non come un correttivo esterno o una proprietà semantica emergente, bensì come un vincolo geometrico rigido integrato direttamente all'interno della funzione di loss multi-obiettivo del generatore, supportato da un'ispezionabilità analitica del contributo causale dei singoli parametri del circuito.

6.1.1 Sul Trade-off tra Utilità Downstream e Mitigazione del Bias

La **dimensione sistemica** dello studio (RQ1 e RQ2) ha mappato la relazione causale che lega la qualità informativa del dato sintetico e il livello di equità di gruppo riscontrato sui classificatori classici downstream addestrati in regime TSTR (*Train on Synthetic, Test on Real*). I risultati documentano l'esistenza di un severo trade-off di utilità, particolarmente evidente in assenza di meccanismi di regolarizzazione (es. data re-uploading). Nel dominio educativo *Student Performance*, la configurazione profonda `L2_linear` subisce una drastica perdita di utilità predittiva, registrando un F1-score medio aggregato di appena 0.429 ± 0.371 (con un'Accuracy di 0.394 ± 0.305) a fronte di un baseline reale pari a 0.923 ± 0.012 . Questa perdita, unita alle ampie deviazioni standard osservate su tutte le metriche di equità downstream, dimostra che la mitigazione macroscopica del bias (es. l'azzeramento nominale della SPD) in regime puramente lineare è spesso un equilibrio instabile, influenzato dalla non-convessità dello spazio di ottimizzazione dei VQC nell'era NISQ. Tuttavia, l'introduzione strategica del meccanismo classico di *data re-uploading* stabilizza in modo ottimale questa frontiera. Le varianti quantistiche regolarizzate, come `L2_re_upload` e `L2_all_to_all_re_upload`, non solo recuperano l'utilità predittiva originaria (riportando l'F1-score medio a 0.598 ± 0.258 e 0.601 ± 0.312 su *Student Performance*), ma garantiscono performance di picco straordinarie in regime di generalizzazione nel mondo reale. In scenari di inizializzazione ottimali (`Seed 27`), la rete MLP addestrata sui dati di `L2_re_upload` raggiunge un F1-score di 0.929, allineandosi o superando il baseline reale MLP (0.912). Questo riallineamento prestazionale si accompagna a una contrazione dell'Accuracy di picco a 0.867, configurando il costo matematico necessario imposto dalla loss di fairness per redistribuire simmetricamente la popolazione protetta minoritaria (passata dall'11.3% originale a

una quota bilanciata pari al 51.1% in Tabella 4.2).

🗨 **Take-away Message #1.** I circuiti quantistici variazionali non eliminano intrinsecamente il bias, poiché se il training set è distorto, il VQC ne apprende la distribuzione; tuttavia, la capacità di integrare vincoli etici direttamente nella loss function multi-obiettivo, governata da un co-design architetturale dell'ansatz (tramite data re-uploading e connettività lineare), consente di modellare proattivamente il trade-off utilità-fairness, definendo un paradigma Pareto-efficiente per domini ad alta criticità etica.

6.1.2 Il Ruolo della Complessità e del Co-Design Etico-Hardware

La **dimensione strutturale** dello studio (RQ3) si è focalizzata sull'ispezione dell'architettura interna dell'ansatz quantistico per mappare la relazione tra la complessità circuitale e l'outcome etico downstream. L'estrazione analitica dei Quantum Shapley Values (SVQX) individua nei gate ad entanglement globale (porte CNOT) la sorgente primaria di iniezione e propagazione del bias demografico (con valori medi di SVQX fino a -0.3225). L'ispezione delle correlazioni architetture evidenzia questa dinamica governata a livello di singoli gate, documentando nel dominio *Student Performance* una forte e statisticamente significativa correlazione positiva tra la densità delle CNOT e la degradazione dell'equità downstream (con coefficiente di Spearman pari a $\rho = 0.5230$, $p = 0.0259$ per la metrica EOD). In questo contesto, la variante `L2_re_upload` si configura come la sintesi ottimale del paradigma di co-design etico-hardware proposto. Riducendo dell'80% il numero di porte fisiche CNOT rispetto alle configurazioni ad entanglement completo (come dettagliato nella Sezione 4.4.4), questo modello limita la propagazione incontrollata del bias lungo il registro quantistico. Ciononostante, l'efficace regolarizzazione introdotta dal data re-uploading preserva l'espressività non lineare dello stato preparato nello spazio di Hilbert (confermata da indici di Meyer-Wallach competitivi fino a 0.4182), consentendo a `L2_re_upload` di eguagliare l'utilità downstream delle varianti più complesse e di superarle in modo statisticamente significativo in termini di stabilità e mitigazione del bias etico. Sebbene la configurazione `L2_all_to_all_re_upload` si presenti come un'alternativa (a livello puramente descrittivo) superiore in termini di utilità di picco (RQ1) e di riduzione della SPD (RQ2), l'analisi inferenziale tramite test

post-hoc di Nemenyi certifica l'equivalenza statistica tra le due architetture (con valori di p non significativi, come $p = 0.7055$ per l'utilità e $p = 0.1306$ per la fairness nel dominio *Student Performance*). Sotto il profilo della progettazione software quantistica, l'adozione di un ansatz ad accoppiamento completo introduce una severa penalità in termini di scalabilità fisica, nota come collo di bottiglia NISQ (*NISQ Bottleneck*). Un circuito operante in topologia All-to-All richiede infatti fino a 90 porte CNOT (su un registro a 10 qubit) rispetto alle sole 18 porte della variante lineare. Su processori quantistici reali (*QPU*), tipicamente privi di connettività nativa totale (All-to-All), il compilatore quantistico è costretto a inserire una sequenza densa di porte SWAP (ognuna composta da 3 porte CNOT fisiche) per instradare gli stati dei qubit geometricamente distanti. Questo processo aumenta drammaticamente la profondità fisica del circuito e accumula rumore sistematico oltre la soglia di decoerenza del chip. Di conseguenza, `L2_re_upload` emerge come l'unico vero paradigma architetturale Pareto-efficiente per il deployment su hardware NISQ reale, contraendo drasticamente il costo computazionale del circuito senza alcun compromesso statisticamente significativo sulle metriche predittive ed etiche downstream.

Infine, l'analisi dell'indice Gini sulle attribuzioni SVQX (corrispondente alla colonna `svqx_concentration` nella RQ3) rivela che l'azione regolarizzatrice del data re-uploading contrae sistematicamente la polarizzazione causale dei gate (con l'indice Gini che scende a 0.363 ± 0.027 in *German Credit* rispetto al 0.622 ± 0.329 delle varianti non regolarizzate). Questo prova che la reiterazione delle feature classiche lungo i layer quantistici distribuisce in modo omogeneo il carico causale dell'apprendimento lungo tutto l'ansatz, mitigando colli di bottiglia informativi ed evitando spiegazioni strutturalmente rigide.

🗨 **Take-away Message #2.** L'aumento indiscriminato della complessità dell'ansatz (profondità e densità di entanglement) degrada la stabilità etica e predittiva. Come documentato in simulazione ideale (*statevector*), l'insorgenza di barren plateaus e instabilità stocastiche costituisce un limite matematico-algoritmico intrinseco dello spazio di Hilbert, indipendente dal rumore dell'hardware fisico. In questo scenario, la sinergia tra topologia lineare (nearest-neighbor) e data re-uploading agisce da regolarizzatore geometrico, ottimizzando l'entanglement e stabilizzando le attribuzioni causali SVQX.

6.1.3 Integrazione nei Processi di Quality Assurance (QA)

L'adozione di un generatore basato su VQC, inquadrata nella prospettiva dell'Ingegneria del Software per sistemi orientati all'Intelligenza Artificiale (SE4AI), introduce un cambio di paradigma radicale rispetto ai tradizionali metodi reattivi di mitigazione del bias (operanti ex-post come post-processing sulle predizioni o pre-processing sul dato reale). Sostituendo la conoscenza semantico-linguistica degli LLM con l'ottimizzazione matematico-circuitale nello spazio di Hilbert, la fairness viene incorporata in modo proattivo ed esplicito (*fairness-by-design*) fin dalla fase di concezione del dato sintetico. Questo approccio definisce un canale d'integrazione diretto all'interno dei processi di Quality Assurance (QA) del software. L'ispezionabilità strutturale dei circuiti quantistici variazionali consente di superare l'opacità dei tradizionali modelli di deep learning o dei Large Language Models, circoscrivendo rigorosamente il rischio di allucinazioni o di generazione di istanze fuori dominio. Inoltre, l'applicazione dei protocolli di *Bell sampling* a due copie, implementata tramite il protocollo di Bell sampling a due copie per la stima del coefficiente a_1 con `qsalto` [27] e la parità statistica quantistica (QSP_{diff}), consente di validare formalmente la simmetria geometrica dello stato preparato, evitando il costo esponenziale di una tomografia (diagnostica) di stato completa. Questo protocollo dimostra con significatività statistica ($p \leq 0.0329$ in tutti i domini) come la topologia lineare dei qubit agisca da regolarizzatore geometrico dello stato. Tale validazione formale attesta la conformità geometrica locale, garantendo l'assenza di coppie sbilanciate (*bias pairs*) nel 96.3% delle valutazioni complessive. In termini applicativi, questo meccanismo fornisce agli ingegneri del software uno strumento matematicamente controllabile per verificare e certificare l'equità locale dei record generati, agendo come un filtro di sicurezza proattivo prima della loro effettiva ingestione nella pipeline di addestramento classico.

🗨 **Take-away Message #3.** La generazione quantistica variazionale supera l’approccio reattivo della mitigazione del bias classico, integrandola come strategia di *fairness-by-design* proattiva, robusta e strutturalmente verificabile. L’ispezionabilità dell’ansatz tramite i *Quantum Shapley Values* (SVQX) e la validazione dello stato preparato via *Bell sampling* (implementato tramite la libreria `qsalto`) abilitano un paradigma di *Quality Assurance* quantistico nativo, superando l’opacità strutturale e i rischi di allucinazione tipici dei modelli generativi classici ad alta dimensionalità.

6.2 Sviluppi Futuri

L’agenda di ricerca futura si propone di approfondire il presente studio sviluppando tre aree di ricerca:

1. **Deployment su Hardware NISQ Reale:** L’esecuzione della variante Pareto-efficiente `L2_re_upload` individuata su hardware quantistico (es. architetture IBM Quantum Falcon o Heron) per mappare l’impatto del rumore hardware reale sull’utilità e sulla stabilità della fairness, applicando la mitigazione a due copie per proteggere l’equità dello stato e la stabilità di SVQX dal rumore fisico;
2. **Generalizzazione delle Porte di Rotazione e dell’Ansatz:** Il superamento del vincolo dell’ansatz fisso basato su sole porte R_y attraverso l’integrazione di gate di rotazione alternativi o combinati (come R_x , R_z o rotazioni universali U_3). Questa estensione permetterà di mappare i dati tabulari nell’intero spazio di Hilbert a valori complessi, valutando il trade-off tra l’incremento di espressività del circuito e il rischio di accentuare l’insorgenza di barren plateaus;

Bibliografia

- [1] G. Voria, B. Scala, L. Todisco, C. Venditto, G. Giordano, G. Catolino, and F. Palomba, “Fair and square? Evaluating fairness of LLM-generated synthetic datasets,” *Information and Software Technology*, vol. 176, p. 107715, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0950584925003192> (Citato alle pagine ii, v, vii, 2, 3, 4, 11, 16, 17, 45, 46, 47, 49, 53, 66, 68, 86 e 114)
- [2] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006. [Online]. Available: <https://jmlr.org/papers/v7/demsar06a.html> (Citato alle pagine iii, 73, 74, 75 e 114)
- [3] F. Sisini, *Qubits in azione: le operazioni elementari dell’informatica quantistica*. Bologna, Italia: in riga edizioni, 2023. (Citato alle pagine v, 18, 19, 20, 22, 23 e 35)
- [4] I. O. Gallegos, R. A. Rossi, J. Barrow, M. M. Tanjim, S. Kim, F. Dernoncourt, T. Yu, R. Zhang, and N. K. Ahmed, “Bias and fairness in large language models: A survey,” *Computational Linguistics*, vol. 50, no. 3, pp. 1079–1157, 2024. (Citato alle pagine v, 3, 17 e 45)

-
- [5] L. Schiavo, "VQC Generator-Fair-Interpretable-Data," https://github.com/KLS-01/VQC_Generator-Fair-Interpretable-Data, 2026. (Citato alle pagine vi, 5, 52, 79 e 80)
- [6] P. Bhardwaj, C. Jones, L. Dierich, and A. Vučković, "TabularQGAN: A quantum generative model for tabular data," *arXiv preprint arXiv:2505.22533*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.22533> (Citato alle pagine vii, 3, 4, 24, 43 e 46)
- [7] K. Sabbagh, H. Salloum, and Y. Kholodov, "RepFair-QGAN: Alleviating representation bias in quantum generative adversarial networks using gradient clipping," in *ICLR 2025 Workshop on Data Problems for Foundation Models*, 2025. [Online]. Available: <https://openreview.net/forum?id=ccZMAqkZge> (Citato alle pagine vii, 4, 25, 26, 46 e 47)
- [8] F. J. Sarmin, A. R. Rahman, C. J. Henry, and N. Mohammed, "Privacy-preserving fair synthetic tabular data," *arXiv preprint arXiv:2503.02968*, 2025. (Citato alle pagine vii, 15, 16, 46 e 64)
- [9] S. Martínez-Fernández, J. Bogner, X. Franch, M. Oriol, J. Siebert, A. Trendowicz, A. M. Vollmer, and S. Wagner, "Software engineering for AI-based systems: A survey," *ACM Transactions on Software Engineering and Methodology*, vol. 31, no. 2, pp. 1–59, 2022. (Citato alle pagine 1, 47 e 111)
- [10] J. Zhou and F. Chen, Eds., *Human and Machine Learning*, ser. Human-Computer Interaction Series. Cham, Switzerland: Springer, 2018. (Citato a pagina 1)
- [11] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, and A. Galstyan, "A survey on bias and fairness in machine learning," *ACM Computing Surveys*, vol. 54, no. 6, pp. 1–35, 2021. (Citato alle pagine 1, 9, 10, 11, 12 e 53)
- [12] D. Pessach and E. Shmueli, "A review on fairness in machine learning," *ACM Computing Surveys*, vol. 55, no. 3, pp. 1–44, 2022. [Online]. Available: <https://dl.acm.org/doi/10.1145/3494672> (Citato alle pagine 1, 9, 10 e 12)

-
- [13] M. Hort, Z. Chen, J. M. Zhang, M. Harman, and F. Sarro, "Bias mitigation for machine learning classifiers: A comprehensive survey," *ACM Journal on Responsible Computing*, vol. 1, no. 2, pp. 1–52, 2024. (Citato a pagina 2)
- [14] S. Corbett-Davies, J. D. Gaebler, H. Nilforoshan, R. Shroff, and S. Goel, "The measure and mismeasure of fairness," *Journal of Machine Learning Research*, vol. 24, no. 1, pp. 14730–14846, 2023. [Online]. Available: <https://jmlr.org/papers/v24/22-1511.html> (Citato a pagina 2)
- [15] V. Borisov, T. Leemann, K. Seßler, J. Haug, M. Pawelczyk, and G. Kasneci, "Deep neural networks and tabular data: A survey," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, pp. 7499–7519, 2024. (Citato alle pagine 2, 12, 43 e 68)
- [16] A. Dandekar, R. A. M. Zen, and S. Bressan, "A comparative study of synthetic dataset generation techniques," in *Database and Expert Systems Applications (DEXA 2018), Part II*, ser. Lecture Notes in Computer Science, vol. 11030. Springer, 2018, pp. 387–395. (Citato alle pagine 2 e 12)
- [17] J. Zhang, G. Cormode, C. M. Procopiuc, D. Srivastava, and X. Xiao, "PrivBayes: Private data release via bayesian networks," *ACM Transactions on Database Systems*, vol. 42, no. 4, pp. 25:1–25:41, 2017. (Citato a pagina 2)
- [18] Z. Li, Y. Zhao, and J. Fu, "SynC: A copula based framework for generating synthetic data from aggregated sources," *arXiv preprint arXiv:2009.09471*, 2020. [Online]. Available: <https://arxiv.org/abs/2009.09471> (Citato a pagina 2)
- [19] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2672–2680. [Online]. Available: <https://arxiv.org/abs/1406.2661> (Citato alle pagine 2 e 12)
- [20] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," *arXiv preprint arXiv:1312.6114*, 2013. [Online]. Available: <https://arxiv.org/abs/1312.6114> (Citato alle pagine 2 e 14)

- [21] A. Abid, M. Farooqi, and J. Zou, “Persistent anti-muslim bias in large language models,” *arXiv preprint arXiv:2101.05783*, 2021. [Online]. Available: <https://arxiv.org/abs/2101.05783> (Citato alle pagine 3 e 17)
- [22] H. Kotek, R. Dockum, and D. Sun, “Gender bias and stereotypes in large language models,” in *Proceedings of The ACM Collective Intelligence Conference*, 2023, pp. 12–24. (Citato alle pagine 3 e 17)
- [23] X. Fang, W. Xu, F. A. Tan, J. Zhang, Z. Hu, Y. Qi, S. Nickleach, D. Socolinsky, S. Sengamedu, and C. Faloutsos, “Large language models (LLMs) on tabular data: Prediction, generation, and understanding — a survey,” *arXiv preprint arXiv:2402.17944*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.17944> (Citato alle pagine 3 e 17)
- [24] S. Kumari, R. Achutha, and V. Sivaraman, “QTabGAN: A hybrid quantum-classical GAN for tabular data synthesis,” *arXiv preprint arXiv:2602.12704*, 2026. [Online]. Available: <https://arxiv.org/abs/2602.12704> (Citato alle pagine 3, 4, 24 e 43)
- [25] R. Heese, T. Gerlach, S. Mücke, S. Müller, M. Jakobs, and N. Piatkowski, “Explaining quantum circuits with Shapley values: Towards explainable quantum machine learning,” *arXiv preprint arXiv:2301.09138*, 2023. [Online]. Available: <https://arxiv.org/abs/2301.09138> (Citato alle pagine 3, 5, 34, 37, 38, 39, 42, 43, 44, 46, 50, 70 e 113)
- [26] L. Pira and C. Ferrie, “On the interpretability of quantum neural networks,” *Quantum Machine Intelligence*, vol. 6, no. 1, p. 52, 2024. [Online]. Available: <https://arxiv.org/abs/2308.11098> (Citato alle pagine 3, 39, 40 e 44)
- [27] D. Miller, K. Levi, L. Postler, A. Steiner, L. Bittel, G. A. L. White, Y. Tang, E. J. Kuehnke, A. A. Mele, S. Khatrri, L. Leone, J. Carrasco, C. D. Marciniak, I. Pogorelov, M. Guevara-Bertsch, R. Freund, R. Blatt, P. Schindler, T. Monz, M. Ringbauer, and J. Eisert, “Experimental measurement and a physical interpretation of quantum shadow enumerators,” *Phys. Rev. Res.*, vol. 8, no. 2, p. 023318, 2026. (Citato alle pagine 5, 33, 71, 72, 102 e 119)

-
- [28] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, and R. Zemel, “Fairness through awareness,” in *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference (ITCS)*, 2012, pp. 214–226. (Citato a pagina 10)
- [29] A. Agarwal, A. Beygelzimer, M. Dudík, J. Langford, and H. Wallach, “A reductions approach to fair classification,” in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018, pp. 60–69. [Online]. Available: <https://proceedings.mlr.press/v80/agarwal18a.html> (Citato a pagina 10)
- [30] M. Hardt, E. Price, and N. Srebro, “Equality of opportunity in supervised learning,” in *Advances in Neural Information Processing Systems*, vol. 29, 2016, pp. 3315–3323, extended version available on arXiv:1610.02413. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2016/hash/6a9659feb1216f14f7384ba499518b38-Abstract.html (Citato alle pagine 10 e 12)
- [31] R. K. E. Bellamy, K. Dey, M. Hind, S. C. Hoffman, S. Houde, K. Kannan, P. Lohia, J. Martino, S. Mehta, A. Mojsilovic *et al.*, “AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias,” *IBM Journal of Research and Development*, vol. 63, no. 4/5, pp. 4:1–4:15, 2019. (Citato alle pagine 11, 16, 54 e 113)
- [32] A. Chouldechova, “Fair prediction with disparate impact: A study of bias in recidivism prediction instruments,” *Big Data*, vol. 5, no. 2, pp. 153–163, 2017. [Online]. Available: <https://arxiv.org/abs/1610.07524> (Citato a pagina 11)
- [33] J. Kleinberg, S. Mullainathan, and M. Raghavan, “Inherent trade-offs in the fair determination of risk scores,” in *Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS)*, 2017. (Citato a pagina 11)
- [34] J. Chakraborty, S. Majumder, and T. Menzies, “Bias in machine learning software: Why? how? what to do?” in *Proceedings of the 29th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE)*, 2021, pp. 429–440. (Citato a pagina 15)

- [35] H. Hofmann, "Statlog (German credit data)," 1994. [Online]. Available: <https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data> (Citato alle pagine 16 e 53)
- [36] A. Janosi, W. Steinbrunn, M. Pfisterer, and R. Detrano, "Heart disease dataset," 1988. [Online]. Available: <https://archive.ics.uci.edu/dataset/45/heart+disease> (Citato alle pagine 16 e 53)
- [37] P. Cortez, "Student performance," 2014. [Online]. Available: <https://archive.ics.uci.edu/dataset/320/student+performance> (Citato alle pagine 16 e 53)
- [38] X. Hou, Y. Zhao, Y. Liu, Z. Yang, K. Wang, L. Li, X. Luo, D. Lo, J. Grundy, and H. Wang, "Large language models for software engineering: A systematic literature review," in *ACM Transactions on Software Engineering and Methodology*, vol. 33, no. 8, 2024, pp. 1–79. (Citato a pagina 17)
- [39] M. A. Nielsen and I. L. Chuang, *Quantum Computation and Quantum Information*, 10th ed. Cambridge, UK: Cambridge University Press, 2010. (Citato alle pagine 18, 19, 21, 27, 28, 33, 35, 53 e 70)
- [40] C. Zoufal, A. Lucchi, and S. Woerner, "Quantum generative adversarial networks for learning and loading random distributions," *npj Quantum Information*, vol. 5, no. 1, p. 103, 2019. (Citato alle pagine 18, 21 e 55)
- [41] J. Preskill, "Quantum computing in the NISQ era and beyond," *Quantum*, vol. 2, p. 79, 2018. (Citato alle pagine 18, 21, 22, 53 e 58)
- [42] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, and J. I. Latorre, "Data re-uploading for a universal quantum classifier," *Quantum*, vol. 4, p. 226, 2020. (Citato alle pagine 23 e 55)
- [43] M. Schuld, V. Bergholm, C. Gogolin, J. Izaac, and N. Killoran, "Evaluating analytic gradients on quantum hardware," *Physical Review A*, vol. 99, no. 3, p. 032331, 2019. (Citato a pagina 24)

- [44] P. J. Kenfack, D. D. Arapov, R. Hussain, S. A. Kazmi, and A. Khan, "On the fairness of generative adversarial networks (gans)," in *2021 International Conference "Nonlinearity, Information and Robotics" (NIR)*, 2021, pp. 1–7. (Citato a pagina 25)
- [45] D. Xu, Y. Wu, S. Yuan, L. Zhang, and X. Wu, "Achieving causal fairness through generative adversarial networks," in *Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI)*, 2019, pp. 1452–1458. [Online]. Available: <https://www.ijcai.org/proceedings/2019/0201.pdf> (Citato a pagina 25)
- [46] E. Perrier, "Quantum fair machine learning," in *Proceedings of the 2021 AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 2021, pp. 843–853. [Online]. Available: <https://arxiv.org/abs/2102.00753> (Citato alle pagine 27, 28, 29, 43, 47, 70 e 80)
- [47] M. J. Kusner, J. Loftus, C. Russell, and R. Silva, "Counterfactual fairness," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4066–4076. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/a486cd07e4ac3d270571622f4f316ec5-Abstract.html> (Citato a pagina 30)
- [48] J. Guan, W. Fang, and M. Ying, "Verifying fairness in quantum machine learning," in *Proceedings of the 34th International Conference on Computer-Aided Verification (CAV)*. Springer, 2022, pp. 408–429. [Online]. Available: <https://arxiv.org/abs/2207.11173> (Citato alle pagine 31, 32, 43, 46, 47, 70 e 100)
- [49] D. A. Meyer and N. R. Wallach, "Global entanglement in multiparticle systems," *Journal of Mathematical Physics*, vol. 43, no. 9, pp. 4273–4278, 2002. (Citato a pagina 33)
- [50] E. Gil-Fuster, J. R. Naujoks, G. Montavon, T. Wiegand, W. Samek, and J. Eisert, "Opportunities and limitations of explainability in quantum machine learning," *arXiv preprint arXiv:2412.14753*, 2024. [Online]. Available: <https://arxiv.org/abs/2412.14753> (Citato alle pagine 34, 35, 36 e 44)
- [51] W. K. Wootters and W. H. Zurek, "A single quantum cannot be cloned," *Nature*, vol. 299, pp. 802–803, 1982. (Citato a pagina 34)

- [52] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4765–4774. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html> (Citato alle pagine 36 e 37)
- [53] L. S. Shapley, "A value for n -person games," in *Contributions to the Theory of Games*, H. W. Kuhn and A. W. Tucker, Eds. Princeton University Press, 1953, vol. 2, pp. 307–317. (Citato alle pagine 36 e 37)
- [54] A. Daskin, "On the explainability of quantum neural networks based on variational quantum circuits," *arXiv preprint arXiv:2301.05549*, 2023. [Online]. Available: <https://arxiv.org/abs/2301.05549> (Citato a pagina 41)
- [55] M. Baker, "1,500 scientists lift the lid on reproducibility," *Nature*, vol. 533, no. 7604, pp. 452–454, 2016. (Citato a pagina 47)
- [56] J. Pineau, P. Vincent-Lamarre, K. Sinha, V. Larivière, A. Beygelzimer, F. d'Alché Buc, E. Fox, and H. Larochelle, "Improving reproducibility in machine learning research (a report from the NeurIPS 2019 reproducibility program)," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021. [Online]. Available: <https://jmlr.org/papers/v22/20-303.html> (Citato a pagina 47)
- [57] A. Fabris, S. Messina, G. Silvello, and G. A. Susto, "Algorithmic fairness datasets: the story so far," *Data Mining and Knowledge Discovery*, vol. 36, no. 6, pp. 2074–2152, 2022. (Citato alle pagine 53 e 54)
- [58] P. Cortez and A. M. G. Silva, "Using data mining to predict secondary school student performance," in *Proceedings of the 5th Annual Future Business Technology Conference (FUBUTEC)*, 2008, pp. 5–12. [Online]. Available: <https://hdl.handle.net/1822/8024> (Citato a pagina 53)
- [59] R. J. Chen, J. J. Wang, D. F. K. Williamson, T. Y. Chen, J. Lipkova, M. Y. Lu, S. Sahai, and F. Mahmood, "Algorithmic fairness in artificial intelligence for medicine and healthcare," *Nature Biomedical Engineering*, vol. 7, no. 6, pp. 719–

- 742, 6 2023. [Online]. Available: <https://doi.org/10.1038/s41551-023-01056-8>
(Citato a pagina 54)
- [60] E. Black, S. Yeom, and M. Fredrikson, “FlipTest: From individual fairness to subgroup fairness,” in *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT*)*. Barcelona, Spain: ACM, 2020, pp. 35–45. (Citato alle pagine 55 e 97)
- [61] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, no. 85, pp. 2825–2830, 2011. [Online]. Available: <https://jmlr.org/papers/v12/pedregosa11a.html> (Citato a pagina 68)

Questa tesi ha contribuito a piantare un albero in Madagascar tramite il progetto Treedom.

<https://www.treedom.net/it/user/sesalab/event/sesa-random-forest>